



Estudio de las Alucinaciones en LLMs

Grado en Ciencia e Ingeniería de Datos

Trabajo Fin de Grado

Autor:

Juan Andrés Álvarez Cascales

Tutor/es:

Ronghao Pan

Rafael Valencia

Salvador García Ortuño



Facultad
de Informática
UMU

Estudio de las Alucinaciones en LLMs

Aplicación en AMC Global

Autor

Juan Andrés Álvarez Cascales

Tutor/es

Ronghao Pan

Departamento de Informática y Sistemas

Rafael Valencia


Departamento de Informática y Sistemas

Salvador García Ortuño

AMC Global (Director de IT)



UNIVERSIDAD
DE MURCIA



Facultad
de Informática

Grado en Ciencia e Ingeniería de Datos

Murcia, 20 de Junio de 2026

Convocatoria de Junio 2026

Preámbulo

El presente Trabajo Fin de Grado surge de la creciente necesidad de las organizaciones por desplegar sistemas de inteligencia artificial conversacional que sean fiables, dada la enorme oportunidad competitiva que esto les supone a la hora de agilizar consultas y flujos de trabajo. Las alucinaciones, entendidas como respuestas factualmente incorrectas generadas con aparente confianza por los modelos de lenguaje de gran escala, representan uno de los principales obstáculos para la adopción de esta tecnología en entornos corporativos, donde la precisión de la información es crítica.

Este trabajo aborda dicha problemática desde un enfoque empírico, diseñando y evaluando un sistema de Generación Aumentada por Recuperación (RAG) aplicado a documentos internos de AMC Global, empresa líder en la fabricación de zumos y bebidas naturales. El alcance del proyecto comprende la construcción de un *golden dataset* de tripletas pregunta-respuesta-contexto generadas mediante modelos de lenguaje y revisadas por expertos humanos, la evaluación de modelos comerciales de distintos proveedores en un escenario *baseline* sin contexto externo, y la medición del impacto del sistema RAG sobre la forma de responder de estos grandes modelos del lenguaje, empleando el marco de evaluación RAGAS.

Este trabajo ha sido desarrollado en estrecha colaboración con AMC Global y con el apoyo continuo de los tutores académicos asignados, a quienes agradezco su orientación a lo largo de todo el proceso.

Agradecimientos

En primer lugar, quiero agradecer a D. Ronghao Pan y a D. Rafa Valencia su disposición para tutorizar este trabajo y por haber aceptado la colaboración con AMC Global, sin ellos esto no hubiera sido posible.

Un agradecimiento muy especial al equipazo de AMC Global. A Jose y a Dani, por su feedback constante y su implicación en cada fase del proyecto. A Fede, por aguantarme durante estos meses con una paciencia infinita y por enseñarme tantísimas cosas que hasta entonces me eran completamente desconocidas. A Salva, por confiar en mí y darme la oportunidad de comenzar mi carrera profesional con ellos. Y por supuesto a Javi, por ese “¿Cómo te podemos ayudar?” que, sin saberlo, fue el punto de partida de este trabajo.

Por último, a Jyts, “el influencer del dato”, a quien le prometí una mención y espero que valore el gesto.

A Nasim, Jota, Marcos, Jorge, Barea y Fernando.

*Nunca llegarás a tu destino si te detienes
a tirarle piedras a cualquier perro que ladre*

*Pasé más de la mitad de mi vida preocupándome
por cosas que jamás iban a ocurrir*

Winston Churchill.

Declaración firmada sobre originalidad del trabajo

D./Dña. **Juan Andrés Álvarez Cascales**, con DNI **58469474-R**, estudiante de la titulación de **Grado en Ciencia e Ingeniería de Datos** de la Universidad de Murcia y autor del TFG titulado “**Estudio de las Alucinaciones en LLMs**”.

De acuerdo con el Reglamento por el que se regulan los Trabajos Fin de Grado y de Fin de Máster en la Universidad de Murcia (aprobado C. de Gob. 30-04-2015, modificado 22-04-2016, 28-09-2018 y 28/06/2022), así como la normativa interna para la oferta, asignación, elaboración y defensa de los Trabajos Fin de Grado y Fin de Máster de las titulaciones impartidas en la Facultad de Informática de la Universidad de Murcia (aprobada en Junta de Facultad el 19-06-2025)

DECLARO:

Que el Trabajo Fin de Grado presentado para su evaluación es original y de elaboración personal. Todas las fuentes utilizadas han sido debidamente citadas. Así mismo, declara que no incumple ningún contrato de confidencialidad, ni viola ningún derecho de propiedad intelectual e industrial

Murcia, a 20 de Junio de 2026

A handwritten signature in black ink, appearing to read 'JAC', is written over a horizontal line.

Fdo.: Juan Andrés Álvarez Cascales
Autor del TFG

Resumen

Los grandes modelos de lenguaje (LLMs) ofrecen una oportunidad estratégica para la gestión del conocimiento corporativo, pero su despliegue en producción se ve comprometido por las alucinaciones, esto es, la generación de información factualmente incorrecta o inventada presentada con aparente coherencia y seguridad. Este trabajo, desarrollado en colaboración con AMC Global, aborda dos preguntas complementarias, en qué medida los LLMs actuales alucinan cuando se les consulta sobre contenido corporativo específico y hasta qué punto la arquitectura de generación aumentada por recuperación (RAG) permite mitigar ese problema. Como objetivo principal, el estudio cuantifica el impacto del acceso a contexto documental sobre el comportamiento de los modelos, comparando un escenario sin contexto externo (*baseline*) con un sistema RAG construido sobre la documentación interna de la empresa.

La metodología se articula en tres bloques. En primer lugar, se construyó un *golden dataset* de referencia sobre un corpus heterogéneo de documentos corporativos, compuesto por 133 preguntas de turno único, clasificadas en factuales directas, de razonamiento, con premisas incorrectas y fuera del dominio documental, y 17 conversaciones multiturno que siguen los cuatro patrones de interacción definidos en la literatura (*Follow-up*, *Expansion*, *Refinement* y *Recollection*). La generación de este dataset se apoyó en la API de OpenAI e incluyó una validación automática mediante *fuzzy matching* para comprobar que los contextos de los que procedía cada respuesta estaban realmente presentes en el documento original, seguida de una curación manual con el apoyo de expertos del dominio (empleados de AMC Global). En segundo lugar, se evaluó el comportamiento *baseline* de dos modelos comerciales de capacidades equiparables, GPT-4o y Gemini 2.5 Flash, sobre cuatro configuraciones de parámetros de generación que combinan temperatura y *top-p*, sin proporcionarles contexto documental alguno. Por último, se implementó y evaluó un sistema RAG completo, con segmentación semántica del corpus, representación vectorial mediante el modelo Qwen3-Embedding-0.6B, indexación en Azure AI Search con búsqueda híbrida (vectorial y léxica BM25 fusionadas con *Reciprocal Rank Fusion*) y reordenación mediante un *cross-encoder*. Toda la evaluación se sustenta en el marco RAGAS, complementado con métricas léxicas clásicas y métricas de recuperación.

Los resultados del *baseline* muestran que, sin acceso al corpus, ambos modelos alucinan, la corrección factual de sus respuestas no supera el 25 % en ninguna combinación de modelo y configuración, y la tasa de alucinación no desciende del 79,6 % en el mejor de los casos. La variación de los parámetros de generación no constituye una palanca efectiva para reducir las alucinaciones. Se observa además una disociación clara en-

tre similitud semántica, próxima al 75 %, y corrección factual, lo que indica que los modelos producen respuestas estilísticamente adecuadas al dominio corporativo, pero factualmente incorrectas. Las estrategias de fallo difieren entre ambos. GPT-4o tiende a abstenerse ante lo que desconoce, una respuesta honesta pero de escasa utilidad práctica. Gemini, por el contrario, responde con contenido inventado y bien redactado, lo que supone mayor riesgo porque transmite una seguridad que los datos no respaldan. En conversaciones de múltiples interacciones, las alucinaciones se propagan entre turnos, y un juez externo sin acceso a la documentación es incapaz de detectarlas precisamente por estar bien redactadas.

La evaluación del sistema RAG confirma que el acceso al corpus mitiga sustancialmente las alucinaciones, la corrección factual mediana asciende hasta el 80 % frente a valores inferiores al 25 % en el *baseline*, con una elevada fidelidad a sustentar las respuestas sobre contexto recuperado. La calidad de las respuestas depende de forma crítica del desempeño del recuperador, cuyos fallos repercuten de manera directa sobre la corrección factual. El estudio identifica además dos limitaciones estructurales relevantes, la dilución semántica del *embedding*, por la que la señal del fragmento relevante se atenúa al quedar embebida en *chunks* más extensos, y la degradación de la recuperación ante preguntas con referencias anafóricas al historial conversacional, agravada por la tendencia del generador a apoyarse en el contexto recuperado antes que en la conversación previa. Con ello, el trabajo valida el enfoque metodológico como proyecto piloto previo a una implementación RAG de mayor escala sobre la documentación de AMC Global.

Extended Abstract

Introduction and motivation

Large Language Models (LLMs) have transformed the way organisations conceive their knowledge management and user support systems. The possibility of deploying conversational assistants capable of answering complex questions about internal documentation represents a strategic opportunity, since it reduces response times, democratises access to corporate knowledge and improves the experience of both employees and customers. This opportunity, however, comes with a critical risk that has concentrated much of the recent research in natural language processing, namely hallucinations. A hallucination is the phenomenon by which an LLM generates information that is factually incorrect, fabricated or contradictory with the available sources, while presenting it with apparent confidence and linguistic coherence. The problem is particularly serious in corporate environments, where the accuracy of the information has direct consequences on decision making, user guarantees and the reputation of the organisation. An assistant that answers incorrectly about human resources policies, quality procedures or compliance regulations is not merely useless, it is potentially harmful.

This work originates from a collaboration with AMC Global, a leading company in the production and commercialisation of natural juices and beverages with operations in Spain and the Netherlands. The company maintains an extensive corpus of internal documentation, ranging from procedure manuals and human resources policies to sustainability reports, quality certifications, compliance regulations and product specifications, and raised the need to assess the feasibility of an AI-based conversational assistant over that documentation. Answering that need requires addressing a prior question, to what extent do current LLMs hallucinate when asked about specific corporate content, and how can this problem be mitigated through retrieval-augmented techniques. The collaboration was conceived as mutually beneficial, AMC Global provided the documentary corpus, access to commercial LLM APIs and the participation of its domain experts, while the project delivered a hallucination evaluation framework applicable to its own domain. The study described in this work constitutes a pilot project that validates the methodological approach before undertaking a larger production-grade RAG implementation.

Objectives

The main objective of this work is to quantify the impact of access to documentary context on the behaviour of LLMs, comparing a scenario without external context (the baseline) against a Retrieval-Augmented Generation (RAG) system, with regard to the mitigation of hallucinations. From this main goal, five specific objectives are derived. First, to compare the behaviour of commercial LLMs from different providers when asked about internal corporate information in the absence of external context. Second, to analyse the influence of the generation parameters, temperature and top-p, on the tendency of the evaluated models to hallucinate. Third, to study the behaviour of both the context-free models and the RAG system across different question types, namely direct factual questions, reasoning questions, questions containing false premises and questions outside the documentary domain, as well as across different multi-turn conversational patterns. Fourth, to evaluate the degradation that may occur when hallucinations accumulate along a conversation of multiple turns. Fifth, to identify and analyse the main failure patterns of the RAG system and how those failures affect the generated answers.

Golden dataset construction

The experimental design rests on a golden dataset, a reference set of question-answer-context triplets built on the internal documentation of AMC Global. The corpus is deliberately heterogeneous, it combines formal policies and regulations with numbered sections, staff manuals that mix procedural content with behavioural guidance, declarative documents such as the corporate Code of Ethics, and magazine-style reporting documents with a high density of visual elements. The documents differ in length, semantic density and structure, which introduces realistic variability into the extraction, chunking and retrieval stages.

Since the source documents are PDF files of very diverse nature, a page-level hybrid extraction pipeline was implemented. Each page is processed either with the PyMuPDF library or, when tables are detected or the extracted text fails a set of quality heuristics (minimum length, ratio of valid characters, presence of spaces, Shannon entropy and detection of fragmented columns), with the vision capabilities of GPT-4o through the OpenAI API. A two-level cleaning stage normalises typographic characters, removes page numbers, collapses redundant whitespace, tags URLs and email addresses, and detects recurrent headers and footers by combining frequency and position criteria. The result is a homogeneous JSON representation of every document that records the extraction method used for each page, guaranteeing the traceability of the whole process.

The dataset comprises two complementary subsets. The single-turn subset contains 133 self-contained questions classified into four categories, verifiable factual questions, reasoning questions that require inference or synthesis across different parts of a docu-

ment, trap questions containing a plausible false premise that the system must detect and correct, and out-of-domain questions whose correct answer is an informative abstention. The questions were generated with GPT-4.1, taking advantage of its context window of up to one million tokens to include the full text of each document in a single prompt. This decision avoids the chunk-level evaluation bias described in the literature, generating the questions over full documents guarantees that no specific chunking strategy applied later to the RAG system is artificially favoured by the evaluation set. An automatic validation based on fuzzy string matching (the Ratcliff/Obershelp algorithm with a similarity threshold of 0.85) verified that every reference context returned by the generator was actually contained in the original document, and the complete set was subsequently curated manually with the support of domain experts from AMC Global.

The multi-turn subset contains 17 conversations, with 71 turns in total, that follow the four interaction patterns defined in the MT-Eval benchmark, Follow-up, Expansion, Refinement and Recollection. Each conversation was generated from a seed question selected through an automatic scoring function that weighs the richness of the reference context, the question category, the density of named entities and the thematic diversity with respect to the seeds already chosen. The generated conversations underwent a human review that retained only those with full conversational coherence, factual correctness and absence of fabricated information.

Baseline evaluation design

The baseline phase quantifies how well two commercial models can answer questions about the AMC Global documentation relying exclusively on their parametric knowledge, with no access to any document at inference time. The selected models were GPT-4o and Gemini 2.5 Flash, two models of comparable base capabilities according to public benchmarks, whose APIs expose the temperature and top-p parameters, and neither of which participated in the generation of the golden dataset. Four generation configurations were defined, ranging from a deterministic setting (temperature 0.0, top-p 1.0) to a maximum-randomness setting (temperature 1.0, top-p 0.7), in order to determine whether the differences observed between models remain stable across the sampling space or depend on the generation configuration.

The evaluation relies on the RAGAS framework, which uses an LLM as a judge for the metrics that cannot be computed through lexical overlap or embedding similarity. The judge model was GPT-5-mini, which satisfies the two conditions established in the literature, it is more capable than the evaluated models in factual reasoning tasks and it belongs to a different model family, which avoids the self-preference bias of LLM judges. The metric set combines FactualCorrectness as the primary hallucination indicator, AnswerRelevancy, SemanticSimilarity and three classical lexical metrics (BLEU, ROUGE and ChrF), together with two holistic conversational metrics for the multi-

turn subset, a binary hallucination-free judgement over the complete conversation and a conversational consistency score on a 1 to 5 scale.

RAG system design

The RAG system incorporates a retrieval component that locates relevant fragments of the corpus at inference time and provides them to the generator as additional context. The corpus was segmented through semantic chunking, which places the cut points where the embedding similarity between consecutive sentences falls below the 85th percentile of the document distribution, producing 1,212 chunks after filtering extraction artefacts. The chunk embeddings were generated with Qwen3-Embedding-0.6B, an open model that outperforms the commercial alternative text-embedding-3-large in the multilingual MTEB benchmark despite its small size, a particularly relevant property given that the corpus is entirely in Spanish. The index was built on Azure AI Search, combining dense vector search over an HNSW graph with BM25 lexical search on a single hybrid index.

The inference pipeline retrieves twenty candidate chunks by fusing both search modalities through Reciprocal Rank Fusion, and a cross-encoder reranker (ms-marco-MiniLM-L-6-v2) reorders the candidates and keeps the five most relevant fragments, which are passed to the generator. GPT-4o was selected as the generator model on the basis of the baseline results, its more conservative response strategy, with a higher tendency to abstain rather than fabricate when information is missing, offers better guarantees that its answers will be anchored to the retrieved context. Generation temperature was fixed at 0.0 to ensure deterministic and reproducible answers. In the multi-turn setting, the conversational history is built with the answers actually generated by the system in previous turns, so that the experiment captures the propagation of errors that characterises real interactions, while the retriever operates exclusively on the current question.

Results and discussion

The baseline results show that, without access to the corpus, both models hallucinate systematically. FactualCorrectness does not exceed 0.25 in any combination of model and configuration, far below the deliberately permissive reference threshold of 0.5 adopted in the study, and the global hallucination rate never falls below 79.6 % of the answers, reaching 96.6 % in the worst case. Varying temperature and top-p within the studied range is not an effective lever to reduce hallucinations, both models are heavily aligned commercial products whose internal calibration absorbs moderate changes in the sampling parameters. A clear dissociation emerges between semantic similarity, which remains around 0.74 to 0.75, and factual correctness, the models produce answers that are stylistically appropriate to the corporate Spanish domain but factually

wrong, which is precisely the most dangerous form of hallucination because it offers no superficial signal of error.

The two models fail in qualitatively different ways. GPT-4o shows a marked tendency to abstain when it does not know the answer, an epistemically honest behaviour that is nevertheless of little practical use in production. Gemini 2.5 Flash, on the contrary, produces elaborate and plausible answers with fabricated content, a riskier failure mode because it conveys a confidence that the data does not support. In multi-turn conversations the errors introduced in early turns contaminate the accumulated history and amplify along the conversation, and the holistic evaluation provides one of the most revealing findings of the study, an external LLM judge without access to the documentation rates the fabricated conversations of Gemini as largely hallucination-free precisely because they are well written, which demonstrates that the only way to guarantee answer reliability is to anchor generation to a verifiable documentary source.

The RAG evaluation confirms that access to the corpus substantially mitigates hallucinations. Median FactualCorrectness rises to 0.80, against values below 0.25 in the baseline, and the median Faithfulness of 1.0 shows that the generator builds its answers on the retrieved context instead of its parametric knowledge. The quality of the answers depends critically on the retriever, whose coverage is good but not perfect (mean ContextRecall of 0.622), and the positive correlation observed between retrieval quality and factual correctness constitutes direct evidence that the generator is not fabricating content. The system also handles trap questions reasonably well, supporting itself on the retrieved context instead of following the false premise embedded in the question. A direct comparison against the GPT-4o baseline on the same set of questions quantifies this gain, the single-turn hallucination rate falls from 93.5 % to 18.0 % (a reduction of 75.5 percentage points) and mean FactualCorrectness rises by 276 %, with an equivalent improvement in the multi-turn setting. The RAG system fails to improve on the baseline in only a small minority of questions (7.5 % in single-turn and 2.8 % in multi-turn), almost all attributable to isolated retrieval failures rather than to the RAG approach itself.

The analysis identifies two relevant structural limitations. The first is the semantic dilution of the embedding, when the indexed chunks are considerably longer than the relevant fragment they contain, the semantic signal of that fragment is attenuated within the vector representation of the chunk, which reduces cosine similarity and complicates retrieval discrimination. The second is the degradation of retrieval when questions contain anaphoric references to the conversational history, as in the Refinement and Recollection patterns, where the query delegates its semantic load to previous turns and gives the retriever little vocabulary to work with. This degradation is aggravated by the tendency of the generator to anchor its answers in the retrieved context rather than in the conversation history, even when the necessary information was available in the latter.

Conclusions and future work

This work provides a complete and reproducible evaluation framework for hallucinations in a real corporate domain, and its results support three main conclusions. Without documentary context, commercial LLMs hallucinate massively on closed corporate document collections and no configuration of the generation parameters corrects this behaviour. Anchoring generation to a retrieved documentary context reduces hallucinations substantially and measurably. The reliability of the resulting system is bounded by the quality of its retrieval component, which becomes the natural target for future improvement. The lines of future work derived from the study include finer-grained chunking strategies to mitigate embedding dilution, late-interaction retrieval models such as ColBERT, the semantic enrichment of queries with conversational history to address anaphoric references, and the extension of the evaluation set to confirm the observed differences between conversational patterns with larger samples. The methodological framework validated in this pilot project will serve as the foundation for a larger-scale RAG implementation over the documentation of AMC Global.

Índice general

1. Introducción	1
1.1. Motivación y contexto	1
1.2. Planteamiento del problema	2
1.3. Metodología	3
1.4. Estructura del documento	3
2. Estado del arte	4
2.1. Alucinaciones en modelos de lenguaje: definición y taxonomía	4
2.2. Detección de alucinaciones: enfoques y paradigmas	5
2.3. Generación aumentada por recuperación como estrategia de mitigación	7
2.4. RAGAS: evaluación automatizada de sistemas RAG	8
2.5. Evaluación en conversaciones multiturno	9
2.6. Tendencias emergentes	10
3. Análisis de objetivos y metodología	12
3.1. Objetivos	12
3.2. Definición formal del problema	12
3.3. Corpus	13
3.4. Marco de evaluación	14
3.5. Entorno de ejecución	17
4. Diseño y resolución del trabajo realizado	18
4.1. Extracción y preprocesamiento del corpus	18
4.2. Construcción del <i>golden dataset</i>	22
4.2.1. Preguntas de turno único (<i>single-turn</i>)	22
4.2.2. Conversaciones multiturno (<i>multi-turn</i>)	25
4.2.3. Composición y validación final del <i>golden dataset</i>	28
4.3. Comparación <i>baseline</i>	29
4.4. Construcción del sistema RAG	32
4.4.1. Preparación del corpus: <i>chunking</i> , indexación y representación semántica	33
4.4.2. <i>Pipeline</i> RAG	36
5. Evaluación: resultados y discusión	40
5.1. Evaluación de la comparación <i>baseline</i>	40
5.1.1. Efecto de los parámetros de generación	40

5.1.2.	Comportamiento diferencial de los modelos	45
5.1.3.	Evaluación conversacional (<i>multi-turn</i>)	49
5.1.4.	Tasa de alucinación global	54
5.2.	Evaluación del sistema RAG	54
5.2.1.	Evaluación sobre preguntas de turno único	55
5.2.2.	Evaluación sobre preguntas multi-turno	63
5.3.	Comparación directa entre el <i>baseline</i> y el sistema RAG	67
5.3.1.	Casos en los que el sistema RAG no mejora al <i>baseline</i>	69
6.	Conclusiones y líneas de trabajo futuro	70
6.1.	Conclusiones	70
6.1.1.	Sobre la comparación <i>baseline</i>	70
6.1.2.	Sobre el sistema RAG	71
6.2.	Líneas de trabajo futuro	72
	Bibliografía	74
A.	Prompts del sistema	79
A.1.	Prompt de extracción de texto mediante visión artificial	79
A.2.	Prompts de generación del <i>golden dataset single-turn</i>	80
A.2.1.	Prompt <i>factual_true</i>	80
A.2.2.	Prompt <i>factual_reasoning</i>	81
A.2.3.	Prompt <i>factual_trap</i>	83
A.2.4.	Prompt <i>out_of_domain</i>	84
A.3.	Prompts de generación del <i>golden dataset multi-turn</i>	85
A.3.1.	Prompt <i>Follow-up</i>	85
A.3.2.	Prompt <i>Expansion</i>	88
A.3.3.	Prompt <i>Refinement</i>	90
A.3.4.	Prompt <i>Recollection</i>	93
A.4.	<i>System prompt</i> del experimento <i>baseline</i>	96
A.5.	<i>System prompt</i> del <i>pipeline</i> RAG	96
B.	Estructuras de datos	97
B.1.	Estructura de los ficheros de salida del preprocesamiento	97
B.2.	Estructura de una entrada del <i>golden dataset single-turn</i>	98
B.3.	Estructura de una entrada del <i>golden dataset multi-turn</i>	100
C.	Autorización de la empresa	103
D.	Análisis de dilución semántica del <i>embedding</i>	105
E.	Degradación conversacional por patrón en el <i>baseline</i>	108

F. Distribución de métricas RAG *single-turn* sin preguntas *out_of_domain* 110

Índice de figuras

3.1.	Ejemplo de uno de los documentos que componen el corpus de AMC Global.	14
4.1.	Diagrama del flujo de procesamiento del texto.	19
4.2.	Diagrama del <i>pipeline</i> RAG implementado.	39
5.1.	<i>Interaction plot</i> de corrección factual por tipo de pregunta y configuración de parámetros (subconjunto <i>single-turn</i>).	42
5.2.	Evolución de <i>FactualCorrectness</i> y <i>AnswerRelevancy</i> a lo largo de las cuatro configuraciones de parámetros para ambos modelos (subconjunto <i>single-turn</i>).	43
5.3.	Evolución de <i>SemanticSimilarity</i> y BLEU a lo largo de las cuatro configuraciones de parámetros para ambos modelos (subconjunto <i>single-turn</i>).	43
5.4.	Evolución de ROUGE y ChrF a lo largo de las cuatro configuraciones de parámetros para ambos modelos (subconjunto <i>single-turn</i>).	44
5.5.	<i>Heatmaps</i> de corrección factual (<i>FactualCorrectness</i>) y similitud semántica (<i>SemanticSimilarity</i>) por modelo y configuración de parámetros.	45
5.6.	<i>Heatmaps</i> de similitud semántica (<i>SemanticSimilarity</i>) y BLEU por modelo y configuración de parámetros.	45
5.7.	<i>Heatmaps</i> de ROUGE y ChrF por modelo y configuración de parámetros.	46
5.8.	Distribución de <i>AnswerRelevancy</i> para Gemini 2.5 Flash (izquierda) y GPT-4o (derecha) en el subconjunto <i>single-turn</i>	47
5.9.	Diagrama de radar con el perfil de métricas de evaluación de ambos modelos en el subconjunto <i>single-turn</i>	49
5.10.	Corrección factual media por categoría de pregunta para ambos modelos (subconjunto <i>single-turn</i>).	49
5.11.	<i>Heatmaps</i> de corrección factual (<i>FactualCorrectness</i>) y similitud semántica (<i>SemanticSimilarity</i>) por modelo y configuración de parámetros (subconjunto <i>multi-turn</i> Enfoque A).	49
5.12.	<i>Heatmaps</i> de BLEU, ROUGE y ChrF por modelo y configuración de parámetros (subconjunto <i>multi-turn</i> Enfoque A).	50
5.13.	Degradación promedio de corrección factual entre el subconjunto <i>single-turn</i> y el <i>multi-turn</i> Enfoque A para cada modelo.	51

5.14.	Evolución de <i>FactualCorrectness</i> y <i>SemanticSimilarity</i> a lo largo de las cuatro configuraciones de parámetros para ambos modelos (subconjunto <i>multi-turn</i> Enfoque A).	51
5.15.	Evolución de BLEU, ROUGE y ChrF a lo largo de las cuatro configuraciones de parámetros para ambos modelos (subconjunto <i>multi-turn</i> Enfoque A).	52
5.16.	Corrección factual media por patrón conversacional para ambos modelos (subconjunto <i>multi-turn</i> Enfoque A).	52
5.17.	Resultados de la evaluación holística (<i>multi-turn</i> Enfoque B) por patrón conversacional: tasa de respuestas libres de alucinaciones (<i>hallucination_free</i>) y puntuación de consistencia conversacional (<i>SimpleCriteriaScore</i>).	53
5.18.	Tasa de alucinación por modelo, configuración y modalidad de evaluación (<i>single-turn</i> y <i>multi-turn</i> Enfoque A). Un valor del 100 % indica que la totalidad de las respuestas se sitúa por debajo del umbral de corrección factual de 0.5.	54
5.19.	Distribución de métricas de generación del sistema RAG para el subconjunto <i>single-turn</i>	55
5.20.	Diagrama de radar con el perfil de métricas del sistema RAG para el subconjunto <i>single-turn</i>	56
5.21.	Distribución de similitudes coseno entre los <i>chunks</i> recuperados y los contextos de referencia del conjunto de evaluación.	58
5.22.	Precision@K recalculada con el umbral adaptativo basado en la mediana empírica de la distribución de similitudes coseno.	58
5.23.	Distribución de similitudes coseno entre todos los pares de <i>chunks</i> del corpus (similitud inter- <i>chunk</i>).	60
5.24.	Faithfulness, FactualCorrectness y ContextRecall medios por categoría de pregunta para el subconjunto <i>single-turn</i>	61
5.25.	<i>Scatter plots</i> de ContextRecall y ContextPrecision frente a FactualCorrectness para el subconjunto <i>single-turn</i> . La tendencia se obtiene mediante regresión lineal por mínimos cuadrados excluyendo las preguntas <i>out_of_domain</i>	62
5.26.	Distribución de métricas de generación y recuperación del sistema RAG para el subconjunto <i>multi-turn</i>	63
5.27.	Faithfulness, FactualCorrectness y ContextRecall medios por patrón conversacional para el subconjunto <i>multi-turn</i>	65
5.28.	Evolución del ContextRecall por turno y patrón conversacional en el subconjunto <i>multi-turn</i>	65
5.29.	FactualCorrectness y Faithfulness medias por tipo de turno conversacional en el subconjunto <i>multi-turn</i>	66

D.1.	Proyección UMAP de los <i>embeddings</i> de la pregunta, la respuesta de referencia, el contexto de referencia y los <i>chunks</i> recuperados para los dos casos seleccionados como representativos del fenómeno de dilución semántica.	106
E.1.	Degradación de corrección factual por patrón conversacional respecto al promedio <i>single-turn</i> (Δ FC, ST $\rightarrow$ MT-A).	108
F.1.	Distribución de métricas del sistema RAG para el subconjunto <i>single-turn</i> excluidas las preguntas <i>out_of_domain</i>	110

Índice de tablas

4.1.	Composición del <i>golden dataset</i>	28
4.2.	Configuraciones de parámetros de generación empleadas en el <i>baseline</i>	31
4.3.	Estadísticas del corpus tras el procesamiento.	34
4.4.	Selección de resultados en el <i>benchmark</i> MTEB Multilingüe. Puntuaciones recuperadas del <i>leaderboard</i> MTEB en junio de 2025 [1]. Tabla adaptada de Zhang et al. [2].	35
4.5.	Comparativa de características arquitectónicas entre Qwen3-Embedding-0.6B y text-embedding-3-large.	35
5.1.	Métricas RAGAS de generación (FactualCorrectness, AnswerRelevancy, SemanticSimilarity) por modelo y configuración de parámetros en el subconjunto <i>single-turn</i>	40
5.2.	Comparación directa de métricas entre el <i>baseline</i> y el sistema RAG sobre el mismo conjunto de preguntas. Los valores de FactualCorrectness, AnswerRelevancy y SemanticSimilarity son medias.	68

1. Introducción

1.1. Motivación y contexto

El auge de los grandes modelos de lenguaje (LLMs, del inglés *Large Language Models*) ha transformado profundamente la forma en la que las organizaciones conciben sus sistemas de gestión del conocimiento y atención al usuario [3]. En el ámbito empresarial, la posibilidad de desplegar asistentes conversacionales capaces de responder preguntas complejas a partir de documentación interna, representa una oportunidad estratégica de primer orden, ya que suponen una reducción de tiempos de respuesta, la democratización del acceso al conocimiento corporativo y una mejora de la experiencia del empleado y del cliente [4]. Sin embargo, esta oportunidad viene acompañada de un riesgo crítico que ha centrado gran parte de la investigación reciente en procesamiento del lenguaje natural, las alucinaciones [5].

Se denomina alucinación al fenómeno por el cual un LLM genera información factualmente incorrecta, inventada o contradictoria con las fuentes disponibles, presentándola con aparente seguridad y coherencia lingüística [6]. Este problema adquiere especial relevancia en entornos corporativos donde la precisión de la información tiene consecuencias directas sobre la toma de decisiones, las garantías al usuario y la reputación de la organización. Un asistente que responda incorrectamente sobre políticas de recursos humanos, procedimientos de calidad o normativas de cumplimiento no es solo inútil, sino potencialmente perjudicial.

Este trabajo surge de una colaboración con AMC Global, empresa líder en la producción y comercialización de zumos y bebidas naturales, con operaciones en España y Países Bajos. AMC Global cuenta con un extenso corpus de documentación interna que abarca desde manuales de procedimiento y políticas de recursos humanos hasta informes de sostenibilidad, certificaciones de calidad, normativas de cumplimiento, recetas y fichas técnicas de producto. La organización planteó la necesidad de evaluar la viabilidad de un asistente conversacional basado en inteligencia artificial que permitiese a sus empleados consultar esta documentación de forma eficiente y fiable, y para ello era necesario responder una pregunta previa, ¿en qué medida los LLMs actuales alucinan cuando se les pregunta por contenido corporativo específico, y cómo puede mitigarse ese problema mediante técnicas de recuperación de información aumentada?

La colaboración que dio lugar a este trabajo fue, en su planteamiento, de beneficio mutuo. AMC Global aportó los recursos necesarios para la investigación, el acceso a su corpus interno de documentación y a las API de modelos de lenguaje comerciales de pago, así como la participación de sus expertos en la validación de los resultados. A

cambio, el trabajo proporcionó a la empresa el marco de evaluación de alucinaciones que puede aplicarse a su propio dominio, con tal de reutilizarse en proyectos futuros de mayor escala. Lo descrito en esta memoria constituye, en este sentido, un primer proyecto piloto que ha permitido validar el enfoque metodológico antes de abordar una implementación RAG de mayor complejidad, con un corpus más amplio y una arquitectura más avanzada puesta en producción.

1.2. Planteamiento del problema

Los LLMs preentrenados poseen un conocimiento paramétrico amplio, pero inevitablemente limitado en la actualidad de la información que contiene y en la especificidad del dominio, así como en la imposibilidad de incorporar información privada o actualizada sin un nuevo proceso de entrenamiento. Cuando se les formula una pregunta sobre contenido corporativo interno, como los procedimientos de gestión de quejas de AMC Global o los elementos básicos de su cadena de custodia de productos Halal, el modelo no dispone de esa información en sus parámetros y tiene esencialmente dos opciones, abstenerse de responder, lo cual resulta inútil, o generar una respuesta plausible basada en patrones aprendidos durante el entrenamiento, lo cual resulta peligroso si esa respuesta es incorrecta. Este segundo comportamiento constituye la alucinación en su forma más problemática para un entorno empresarial.

La arquitectura RAG (*Retrieval-Augmented Generation*), propuesta por Lewis et al. [7], ofrece una solución a este problema mediante la incorporación de un componente de recuperación de información que proporciona al modelo el contexto documental relevante en el momento de la generación de sus respuestas. Así, en lugar de depender exclusivamente de su conocimiento paramétrico, el modelo genera su respuesta a partir de los fragmentos de documentación recuperados, lo que en teoría limita su capacidad de inventar información al restringirla al contenido disponible en el corpus. Sin embargo, la efectividad práctica de esta arquitectura depende de múltiples factores, como son la calidad del proceso de segmentación del corpus, la precisión del sistema de recuperación, la capacidad del modelo generador para apoyarse en el contexto recuperado y no en su conocimiento previo, y por supuesto la idoneidad del marco de evaluación empleado para medir todo lo anterior.

Además, los sistemas RAG han sido evaluados predominantemente en escenarios de pregunta única (*single-turn*), donde cada consulta es independiente y autocontenida. Sin embargo, las interacciones reales con asistentes conversacionales son inherentemente multiturno (*multi-turn*), los usuarios reformulan, amplían, matizan y referencian turnos anteriores a lo largo de la conversación. Este escenario, significativamente más complejo, introduce desafíos adicionales tanto para el sistema de recuperación, que debe interpretar preguntas con referencias anafóricas al historial conversacional pasado, como para el modelo generador, que debe equilibrar la creación de su respuesta entre el contexto recuperado y el historial acumulado. Para capturar esta complejidad propia de

una conversación realista, en este trabajo se contemplan cuatro patrones de interacción posibles que pueden darse dentro de una conversación cualquiera de un usuario con un asistente conversacional. Estos patrones están definidos en la literatura, *recollection*, *expansion*, *refinement* y *follow-up* [8].

1.3. Metodología

Para abordar los objetivos de este proyecto, el trabajo se estructura en torno a tres bloques metodológicos principales. El primero es la construcción de un *golden dataset*, un conjunto de referencia de tripletas pregunta-respuesta-contexto elaborado sobre la documentación interna de AMC Global. El dataset contempla tanto consultas de turno único, que se distinguen en distintas categorías (factuales directas, de razonamiento, con premisas incorrectas y fuera del dominio documental), como conversaciones multiturno, siguiendo los patrones de interacción anteriormente mencionados.

El segundo bloque es la evaluación *baseline*. Se evalúan modelos de lenguaje comerciales de distintos proveedores sobre el *golden dataset* sin proporcionar ningún contexto documental, con el objetivo de cuantificar su nivel de alucinación inicial ante preguntas de dominio específico corporativo, variando además sus parámetros de generación para analizar la influencia de estos sobre el comportamiento del modelo.

El tercer bloque es la implementación y evaluación del sistema RAG. Se construye un *pipeline* completo de recuperación y generación sobre el corpus de AMC Global y se evalúa su capacidad para reducir las alucinaciones detectadas en el *baseline*. Todo el proceso de evaluación emplea el marco RAGAS [9], que permite medir de forma automatizada la fidelidad, la relevancia y la corrección factual de las respuestas generadas. Los detalles metodológicos completos se desarrollan en los Capítulos 3 y 4.

1.4. Estructura del documento

El resto del documento se organiza de la siguiente manera:

- **Capítulo 2: Estado del arte.** Revisa la literatura sobre alucinaciones en LLMs, la arquitectura RAG como estrategia de mitigación y el marco de evaluación RAGAS, así como algunas tendencias emergentes.
 - **Capítulo 3: Análisis de objetivos y metodología.** Define los objetivos del trabajo, el corpus empleado y explica en detalle el marco de evaluación adoptado.
 - **Capítulo 4: Diseño y resolución del trabajo realizado.** Describe la construcción del *golden dataset*, el diseño de la comparación *baseline* y la implementación del *pipeline* RAG.
 - **Capítulo 5: Evaluación: resultados y discusión.** Presenta y discute los resultados de la comparación *baseline* y de la evaluación del sistema RAG.
 - **Capítulo 6: Conclusiones y líneas de trabajo futuro.** Recoge las principales conclusiones del estudio y las líneas de trabajo futuro identificadas.
-

2. Estado del arte

La investigación en torno a la fiabilidad de los grandes modelos de lenguaje ha experimentado un crecimiento acelerado desde la adopción masiva de estos sistemas en entornos corporativos. En paralelo al desarrollo de arquitecturas cada vez más capaces, la comunidad científica ha construido un ecosistema de herramientas para detectar, medir y mitigar el principal obstáculo para su despliegue en producción, la generación de contenido incorrecto o no fundamentado en las fuentes disponibles. Este capítulo revisa el estado del arte en los ámbitos directamente relevantes para este trabajo, comenzando por la definición y taxonomía del fenómeno de la alucinación, continuando por los paradigmas de detección y evaluación automática, pasando por la arquitectura RAG como estrategia de mitigación y su evaluación con RAGAS, abordando la complejidad específica de las conversaciones multiturno, y cerrando con una breve revisión de las tendencias emergentes que marcan el horizonte de la investigación en curso.

2.1. Alucinaciones en modelos de lenguaje: definición y taxonomía

Los grandes modelos del lenguaje generan texto de forma autoregresiva, prediciendo en cada paso el token más probable dado el contexto acumulado. Este mecanismo, optimizado para producir secuencias lingüísticamente fluidas y coherentes, no incorpora ninguna garantía de veracidad, el modelo no distingue entre afirmar algo verdadero y generar algo que estadísticamente resulta plausible, pues en cada paso se limita a muestrear el siguiente token de una distribución de probabilidad sobre el vocabulario, condicionada a la secuencia ya generada [10]. El resultado puede derivar en un fenómeno conocido como alucinación, definido en la literatura como la generación de contenido que no se corresponde con el mundo real, con el contexto proporcionado, o con los hechos verificables, presentado con una apariencia de coherencia lingüística que puede resultar difícil de detectar sin una verificación externa [6]. El problema no se limita a errores manifiestos o absurdos, los casos más peligrosos en entornos de alto riesgo son precisamente aquellos en que la respuesta es casi correcta, mezcla hechos reales con detalles inventados, o reproduce la estructura y el tono del discurso experto sin el contenido factual que lo respaldaría.

La investigación reciente ha superado la concepción de la alucinación como un fallo monolítico, estableciendo una distinción fundamental entre dos categorías que responden a causas distintas y requieren estrategias de mitigación igualmente distintas [6]. La

primera es la alucinación de factualidad, que se produce cuando la respuesta generada diverge de hechos verificables del mundo real. Este tipo de error tiene su origen en las limitaciones del conocimiento paramétrico del modelo, es decir, el conocimiento codificado en sus pesos neuronales durante el preentrenamiento. La memoria paramétrica de un LLM es necesariamente estática y parcial, no se actualiza tras el entrenamiento, está sesgada hacia los contenidos predominantes en los datos con los que se entrenó, y carece por completo de información sobre hechos específicos de dominios corporativos cerrados en los que no fue entrenado [7]. Cuando un modelo responde a una pregunta sobre las políticas internas de una organización o los procedimientos propios de un sector regulado, si no dispone de esa información en sus parámetros, recurre a patrones aprendidos durante el entrenamiento que pueden conducir a respuestas aparentemente plausibles pero incorrectas.

La segunda categoría es la alucinación de fidelidad, que ocurre cuando la respuesta generada diverge del contexto documental proporcionado explícitamente al modelo en el momento de la generación. Los estudios de evaluación identifican tres subtipos dentro de esta categoría [6]. La inconsistencia de instrucción, que se produce cuando el modelo incumple las restricciones de formato o comportamiento impuestas en el prompt, por ejemplo, respondiendo con texto libre cuando se le ha indicado responder únicamente con un formato en específico. La inconsistencia de contexto, que ocurre cuando la respuesta incorpora información adicional no presente en los documentos o contexto recuperados, o contradice directamente el contenido de esos documentos. Y la inconsistencia lógica, que aparece cuando el razonamiento generado contiene contradicciones internas, de modo que las premisas presentes en el contexto realmente no conducen a las conclusiones que el modelo presenta.

Esta dicotomía entre factualidad y fidelidad no es únicamente taxonómica, sino que tiene implicaciones directas sobre el diseño de los marcos de evaluación. La corrección factual de una respuesta debe medirse con respecto a una referencia elaborada por expertos del dominio, mientras que la fidelidad debe medirse con respecto al contexto documental recuperado antes de responder [11]. Utilizar una sola métrica para evaluar ambas propiedades conduciría a resultados engañosos, un sistema puede generar respuestas fieles al contexto recuperado pero factualmente incorrectas si ese contexto contiene errores, o respuestas factualmente correctas pero infieles al contexto si el modelo recurre a su conocimiento paramétrico ignorando los documentos proporcionados. La distinción es, por tanto, el fundamento sobre el que se construye cualquier evaluación rigurosa de un sistema RAG.

2.2. Detección de alucinaciones: enfoques y paradigmas

La detección de alucinaciones en modelos de lenguaje ha seguido una trayectoria de creciente sofisticación metodológica. Los primeros enfoques de evaluación se basaban en métricas de coincidencia de n-gramas como BLEU [12] o ROUGE [13], que miden

la superposición léxica entre la respuesta generada y una referencia. Estas métricas, aunque útiles como indicadores de bajo coste computacional, presentan una correlación reducida con el juicio humano cuando se trata de evaluar factualidad y fidelidad, una respuesta puede parafrasear correctamente el contenido de referencia obteniendo una puntuación BLEU baja, o puede reproducir fragmentos del contexto sin responder realmente la pregunta planteada obteniendo una puntuación alta [11]. Los métodos de caja blanca (*whitebox*), aplicables cuando se dispone de acceso a los estados internos del modelo, parten de la premisa de que la certeza del modelo se refleja en su distribución de probabilidad de salida, si dicha distribución está concentrada en pocos tokens, el modelo opera con alta certeza, si en cambio está dispersa entre múltiples alternativas, la entropía elevada es indicativa de incertidumbre y mayor propensión a la alucinación. Azaria and Mitchell propusieron entrenar un clasificador sobre dichas representaciones internas para predecir si el modelo está generando contenido factualmente incorrecto, demostrando que los estados internos del modelo contienen señales diagnósticas sobre su propia fiabilidad [14]. Este paradigma queda, sin embargo, excluido para los modelos propietarios de acceso restringido, para los que no es posible inspeccionar las probabilidades internas ni los estados intermedios de la red neuronal, lo que impulsó el desarrollo de los enfoques de caja negra que se describen más adelante. Los enfoques basados en similitud semántica mediante representaciones vectoriales mejoran la robustez ante paráfrasis léxicas [15], pero siguen sin modelar la relación de implicación lógica entre afirmaciones. Los modelos de inferencia de lenguaje natural (Natural Language Inference, NLI) dan un paso en esa dirección, verificando explícitamente si una afirmación generada puede inferirse de una fuente documental, aunque presentan dificultades con afirmaciones complejas y contextos extensos, y requieren acceso a pares de texto alineados, es decir, cada afirmación se empareja previamente con el fragmento de fuente que debe verificarla [16].

Un avance metodológico significativo para la evaluación de modelos de caja negra (pesos no accesibles) llegó con SelfCheckGPT [17], que propuso detectar alucinaciones sin necesidad de ningún recurso externo a partir de un principio intuitivo, si un modelo conoce con firmeza un hecho, sus respuestas a la misma pregunta en múltiples muestreos estocásticos serán consistentes entre sí, si en cambio alucina, las respuestas divergirán o se contradirán, revelando que el modelo opera bajo incertidumbre. El estudio evaluó varias variantes de esta idea para medir la consistencia entre muestras, incluyendo comparación directa mediante NLI, detección de contradicciones léxicas y prompting explícito a un LLM para que actuase como verificador. Esta última variante, en la que el LLM evalúa si las muestras respaldan las afirmaciones presentes en la respuesta original, demostró la mayor precisión en la detección de alucinaciones. Este resultado fue especialmente relevante porque abría el camino hacia el paradigma que dominaría los años siguientes, el uso de los propios LLMs como jueces de la calidad y veracidad de las respuestas de otros modelos.

El paradigma LLM-as-a-Judge se consolidó con la publicación de G-EVAL [18], que demostró que un LLM de alta capacidad, instruido con una rúbrica de evaluación

detallada y un razonamiento en cadena de pensamiento (Chain-of-Thought), puede producir evaluaciones que correlacionan significativamente mejor con los anotadores humanos que las métricas basadas en coincidencia de n-gramas. Esta flexibilidad, que permite adaptar los criterios de evaluación al dominio y la tarea sin necesidad de datos anotados específicos, explica la rápida adopción del paradigma en la evaluación de sistemas RAG. Sin embargo, la investigación paralela expuso con precisión los sesgos sistemáticos que afectan a estos jueces. Zheng et al. identificaron tres sesgos principales a través de experimentos controlados [19]. Estos son el sesgo de posición, por el que los jueces LLM tienden a favorecer la respuesta presentada en primer lugar cuando se les pide comparar por pares las salidas de dos modelos distintos, el sesgo de verbosidad, por el que premian respuestas más extensas con independencia de su precisión, y el sesgo de automejora, por el que los modelos tienden a calificar más favorablemente las respuestas generadas por modelos de su misma familia. Estos hallazgos no invalidan el paradigma, pero imponen restricciones metodológicas importantes, el juez debe ser un modelo distinto al evaluado, idealmente de mayor capacidad, y el diseño experimental debe minimizar los efectos de posición y longitud en el protocolo de evaluación [19, 20].

2.3. Generación aumentada por recuperación como estrategia de mitigación

La generación aumentada por recuperación, o RAG (del inglés *Retrieval-Augmented Generation*), propuesta por Lewis et al. [7], representa la estrategia de mitigación más adoptada en la práctica para el problema de las alucinaciones en corpus cerrados. Su premisa fundamental es directa, en lugar de depender exclusivamente del conocimiento paramétrico del modelo generador, el sistema incorpora un componente de recuperación que, ante cada consulta, selecciona los fragmentos más relevantes del corpus y los proporciona al modelo como contexto en el momento de la generación de su respuesta. De este modo, el modelo no necesita recordar los hechos del dominio desde sus parámetros, sino que los tiene disponibles explícitamente en su ventana de contexto, lo que restringe o intenta restringir su capacidad de inventar información al contenido disponible en los documentos recuperados. La eficacia de los sistemas RAG para reducir alucinaciones de factualidad en dominios de conocimiento cerrado es elevada precisamente porque esos dominios son los que presentan mayor ausencia de representación en los datos de entrenamiento de los modelos.

La arquitectura RAG consta de varios componentes cuyo diseño tiene un impacto directo sobre la calidad final de las respuestas. El primero es la segmentación del corpus (chunking), que divide los documentos en unidades de texto manejables. Una segmentación excesivamente fina puede romper la coherencia semántica del documento y dificultar que el modelo generador obtenga el contexto suficiente, una segmentación demasiado gruesa puede incluir información irrelevante que diluya el contexto útil o supere los límites de la ventana de contexto [21]. El segundo componente es el modelo

de embeddings, que transforma cada fragmento y cada consulta en un vector de alta dimensión de modo que los fragmentos semánticamente relacionados con la consulta queden próximos en el espacio vectorial. El tercero es el sistema de recuperación, que identifica los fragmentos más relevantes del índice dada una consulta [22]. Las arquitecturas modernas combinan búsqueda vectorial densa, que captura similitud semántica, con búsqueda léxica dispersa basada en algoritmos como BM25, que captura coincidencia exacta de términos técnicos y nombres propios. La fusión de ambas señales mediante técnicas como la Fusión de Rango Recíproco (Reciprocal Rank Fusion, RRF) produce sistemas de recuperación más robustos que cualquiera de los dos enfoques por separado, compensando los casos en que la búsqueda semántica falla por diferencia de vocabulario y los casos en los que la búsqueda léxica falla por paráfrasis [21]. Finalmente, el reranking permite reordenar los fragmentos recuperados evaluando conjuntamente la consulta y cada fragmento, a diferencia del retriever que codifica consultas y documentos de forma independiente, obteniendo así una estimación de relevancia más precisa a mayor coste computacional.

La evaluación de un sistema RAG requiere medir tanto la calidad del componente de recuperación como la calidad del componente de generación. El primero se evalúa con métricas como el Context Recall (del marco RAGAS), que mide en qué proporción la información necesaria para responder la consulta está contenida entre los fragmentos de contexto recuperados, o la precisión del retriever, que evalúa qué fracción de los fragmentos recuperados son genuinamente relevantes. El segundo se evalúa con métricas de generación que, en el contexto RAG, deben distinguir entre fidelidad al contexto recuperado y corrección factual con respecto a una referencia externa. La separación entre estos dos niveles de evaluación permite diagnosticar con precisión el origen de los errores del sistema, si el retriever recupera los fragmentos correctos pero el generador no los utiliza adecuadamente, el problema es de fidelidad, mientras que si el retriever falla en recuperar los fragmentos relevantes, el problema está en la recuperación.

2.4. RAGAS: evaluación automatizada de sistemas RAG

La evaluación de sistemas RAG plantea un desafío metodológico específico, las métricas generales de generación de lenguaje natural no capturan la naturaleza dual de estos sistemas, compuestos por un recuperador y un generador, que tienen funciones complementarias pero evaluables de forma independiente. Para abordar este problema, Es et al. propusieron RAGAS (*Retrieval Augmented Generation Assessment*), un framework de evaluación automatizada que descompone el rendimiento del sistema en dimensiones diferenciadas [9]. Su innovación principal fue demostrar que estas dimensiones pueden evaluarse de forma automática utilizando un LLM como juez, eliminando el cuello de botella que supone la anotación manual en el ciclo de desarrollo de sistemas RAG. Aun así, en el presente trabajo este marco de evaluación automatizada se

complementa con un conjunto de referencia validado manualmente por expertos del dominio de AMC Global, lo que permite contrastar las puntuaciones obtenidas mediante RAGAS con el juicio humano especializado sobre el corpus específico del proyecto.

El framework articula la evaluación en torno a tres métricas principales. La Fidelidad (Faithfulness) evalúa si la respuesta generada se deriva exclusivamente del contexto recuperado, sin incorporar información externa a él. La Relevancia de la Respuesta (Answer Relevance) mide si la respuesta aborda efectivamente la intención de la consulta, distinguiendo entre respuestas pertinentes y respuestas que, aunque fieles al contexto, esquivan o responden de forma tangencial la pregunta formulada. La Relevancia del Contexto (Context Relevance) evalúa la calidad del recuperador midiendo la relación señal-ruido en los fragmentos recuperados, penalizando la inclusión de información irrelevante que puede degradar la generación. La metodología de cálculo de estas métricas hereda tanto la flexibilidad como las limitaciones del paradigma básico LLM-as-a-Judge, lo que hace especialmente relevantes los hallazgos sobre sesgos de los jueces LLM revisados en la sección anterior, tanto para interpretar correctamente los resultados como para diseñar el protocolo de evaluación con las salvaguardas adecuadas.

2.5. Evaluación en conversaciones multiturno

La mayor parte de la investigación en evaluación de LLMs y sistemas RAG se ha desarrollado en el contexto de consultas de turno único, donde cada pregunta es independiente y autocontenida. Sin embargo, las interacciones reales con asistentes conversacionales son inherentemente multiturno, en una conversación real en cada turno se reformulan preguntas anteriores, se amplían temas ya introducidos, o se solicitan aclaraciones sobre respuestas previas. Esta naturaleza conversacional introduce complejidades que los marcos de evaluación diseñados para el turno único son incapaces de capturar [23], ya que tratan cada consulta como si fuera la primera y no pueden detectar inconsistencias entre turnos ni la degradación progresiva de la calidad de las respuestas a lo largo de la conversación [24].

Kwan et al. caracterizaron este problema a través de MT-Eval, un benchmark diseñado para evaluar las capacidades de los LLMs en contextos conversacionales reales [8]. Su trabajo identifica cuatro patrones de interacción multiturno que capturan la diversidad de comportamientos que un asistente conversacional debe gestionar. El patrón de *recollection* exige que el modelo recupere información mencionada en turnos previos de la conversación, poniendo a prueba su capacidad para mantener el historial conversacional y acceder a él de forma selectiva. El patrón de *expansion* introduce nuevas preguntas que amplían o profundizan en un tema ya tratado, requiriendo que el modelo integre el contexto previo de la conversación con nueva información. El patrón de *refinement* implica correcciones o matizar sobre respuestas anteriores, evaluando la capacidad del modelo para actualizar su comprensión sin caer en contradicciones con

lo afirmado anteriormente. Finalmente, el patrón de *follow-up* plantea preguntas que se sustentan en el contenido de la respuesta anterior, exigiendo coherencia entre turnos consecutivos.

Los experimentos de Kwan et al. revelan que el rendimiento de los modelos en estos patrones multiturno no puede predecirse a partir de su comportamiento en el turno único, modelos con resultados similares en evaluaciones single-turn pueden divergir significativamente en conversaciones extendidas [8]. Dos factores de degradación se destacan en su análisis. El primero es la propagación de errores, una respuesta incorrecta en un turno temprano puede contaminar los turnos siguientes si el modelo incorpora ese error como parte del historial acumulado y lo usa para generar respuestas posteriores, produciendo cadenas de razonamiento aparentemente coherentes pero construidas sobre una premisa incorrecta. El segundo es la degradación por distancia al contexto relevante, a medida que la conversación se alarga, el fragmento de información necesario para responder una pregunta queda progresivamente más lejos en el historial, y los modelos tienden a prestarle menor atención en favor del contenido más reciente. En los sistemas RAG, este fenómeno se traduce en un desafío adicional para el componente de recuperación, que debe interpretar consultas con referencias anafóricas a temas u objetos tratados en el historial conversacional para identificar correctamente los fragmentos del corpus relevantes para el turno actual.

2.6. Tendencias emergentes

Más allá del RAG vectorial clásico y sus variantes, la investigación reciente ha abierto varias líneas de evolución orientadas a superar las limitaciones de la búsqueda por similitud vectorial ante preguntas que requieren síntesis de información dispersa o razonamiento sobre estructuras de conocimiento complejas. GraphRAG, propuesto por Edge et al. [25], sustituye la recuperación por similitud vectorial por una representación estructurada del conocimiento en forma de grafo, en el que un LLM extrae entidades y relaciones del corpus y las organiza en comunidades jerárquicas con resúmenes pregenerados. Este enfoque permite responder preguntas globales del tipo “¿cuáles son los temas transversales de este conjunto de documentos?” o “¿cómo se relacionan las políticas de X con las regulaciones de Y?”, para las que la búsqueda vectorial local falla por la ausencia de proximidad semántica entre la consulta y los fragmentos individuales que contienen la respuesta distribuida. La principal limitación de GraphRAG es su coste de indexación y la dependencia de la calidad de la extracción de entidades, que puede verse afectada por corpus con terminología muy especializada.

En la dirección de los sistemas autónomos, el RAG agéntico [22] extiende la arquitectura RAG con agentes capaces de tomar decisiones dinámicas sobre qué fuentes consultar, cuándo reescribir una consulta o cuándo activar mecanismos de corrección cuando la información recuperada resulta insuficiente o contradictoria. En lugar de un pipeline lineal de recuperación y generación, estos sistemas implementan bucles de

razonamiento iterativo que adaptan su estrategia en función de la complejidad de la consulta y la calidad de los resultados intermedios. Este paradigma es especialmente adecuado para consultas que requieren múltiples pasos de recuperación y síntesis, aunque introduce una complejidad de depuración ante errores considerablemente mayor que los pipelines estáticos.

Finalmente, el Language Model Council [26] aborda el problema de la evaluación proponiendo un paradigma democrático en el que un conjunto diverso de modelos colabora como jurado mediante comparaciones por pares procesadas con el modelo estadístico Bradley-Terry, que asigna a cada sistema evaluado un parámetro latente de calidad y estima, a partir del conjunto de enfrentamientos uno contra uno, la probabilidad de que una respuesta sea preferida frente a otra, lo que permite construir una clasificación global a partir de juicios puramente relativos. Este enfoque mitiga los sesgos inherentes a los jueces individuales revisados en la Sección 2.2 mediante la agregación de votos de un consejo diverso, y ha demostrado una correlación con el juicio humano significativamente superior a la de los benchmarks de juez único en tareas subjetivas. Estas tres líneas de investigación, GraphRAG, RAG agéntico y evaluación por consejo, representan el horizonte técnico natural sobre el que se construirán las siguientes generaciones de sistemas RAG y marcan las direcciones más inmediatas de continuación del trabajo presentado en esta memoria.

3. Análisis de objetivos y metodología

3.1. Objetivos

El objetivo principal de este trabajo es cuantificar el impacto del acceso a contexto documental sobre el comportamiento de los LLMs, comparando un escenario sin contexto externo (*baseline*) con un sistema RAG, de cara a la mitigación de las alucinaciones. A partir de este objetivo principal se derivan los siguientes objetivos específicos:

1. Comparar el comportamiento de modelos de lenguaje comerciales de distintos proveedores cuando se les formulan preguntas sobre información corporativa interna, en ausencia de contexto externo.
2. Analizar la influencia de los parámetros de generación (temperatura y *top-p*) sobre la tendencia a alucinar de los modelos evaluados ante la ausencia de contexto externo.
3. Estudiar el comportamiento de los modelos sin acceso al contexto y del sistema RAG ante distintos tipos de preguntas, factuales directas, de razonamiento, con premisas incorrectas y fuera del dominio documental, así como ante distintos patrones de conversación multiturno.
4. Evaluar la degradación del comportamiento que puede producirse cuando las alucinaciones se acumulan a lo largo de una conversación de múltiples turnos.
5. Identificar y analizar los principales patrones de fallo del sistema RAG y cómo afectan dichos fallos a las respuestas generadas.

3.2. Definición formal del problema

El trabajo se estructura como un experimento controlado que compara dos condiciones de generación sobre un conjunto de preguntas de referencia común y empleando los mismos modelos generadores. La modalidad sin contexto, denominada línea base o *baseline*, somete a los modelos a las consultas del *golden dataset* sin proporcionar ningún contexto documental adicional, de modo que las respuestas dependen exclusivamente del conocimiento paramétrico del modelo. La modalidad con acceso documental aplica la arquitectura RAG, de tal forma que cada consulta activa el componente de recuperación sobre el corpus de AMC Global, y el modelo generador recibe los fragmentos

documentales más relevantes como contexto antes de generar su respuesta. El único factor que varía entre modalidades es, por tanto, el acceso al contexto documental, el conjunto de consultas es idéntico en ambas.

Formalmente, sea $\mathcal{Q} = \{(q_i, r_i^*, C_i^*)\}_{i=1}^N$ el conjunto de referencia o *golden dataset*, donde q_i es la consulta, r_i^* la respuesta de referencia validada por expertos del dominio, y C_i^* el conjunto de fragmentos documentales de referencia que contienen la información necesaria para responder correctamente.

La evaluación se desarrolla en dos fases. En la primera, correspondiente al *baseline*, cada consulta q_i se formula a los modelos sin proporcionar contexto documental y bajo distintas configuraciones de parámetros de generación, obteniendo el conjunto de respuestas $\hat{r}_i^{\text{base}}$. En la segunda fase, las mismas consultas se le plantean al sistema RAG, que recupera los fragmentos C_i del corpus para ayudar al modelo LLM a generar su respuesta $\hat{r}_i^{\text{RAG}}$. El objetivo es cuantificar, mediante el marco de evaluación descrito en la Sección 3.4, en qué medida $\hat{r}_i^{\text{RAG}}$ mejora sobre $\hat{r}_i^{\text{base}}$, reduciendo las alucinaciones y aproximándose a la respuesta de referencia r_i^* , así como evaluar el rendimiento de los distintos componentes del *pipeline* RAG.

3.3. Corpus

El corpus empleado en este trabajo está compuesto por documentos de naturaleza heterogénea, todos ellos relacionados con el ámbito operativo y normativo de AMC Global. Esta heterogeneidad es, en sí misma, un aspecto relevante del diseño del trabajo, ya que introduce variabilidad en las fases de extracción de texto y fragmentación del corpus, lo que puede condicionar tanto la calidad de los chunks generados como la capacidad del sistema para recuperar información relevante.

El corpus abarca distintas tipologías documentales representativas del entorno corporativo. Una parte corresponde a políticas y normativas internas de carácter formal, con estructura de secciones numeradas, definiciones y procedimientos, que cubren áreas como la calidad, la sostenibilidad, la seguridad de la información y el cumplimiento normativo. Otro bloque lo constituyen manuales dirigidos al personal, que combinan contenido procedimental con orientaciones de comportamiento y representan el tipo de consulta más habitual que recibiría un asistente corporativo. El corpus incluye también documentos de naturaleza más declarativa y narrativa, como el Código Ético corporativo, así como documentación de reporting en formato revista, con alta densidad de elementos visuales como gráficos, tablas e imágenes. Además, se incorporan documentos de variada naturaleza y extensión que completan el corpus, como comunicados internos, declaraciones, presentaciones corporativas y normativa laboral de aplicación al personal, que aportan variedad en la densidad semántica y en el grado de estructuración del contenido.

La heterogeneidad del corpus es especialmente relevante para el análisis de resultados, los documentos difieren en longitud (desde comunicados de pocas páginas hasta




Figura 3.1: Ejemplo de uno de los documentos que componen el corpus de AMC Global.

textos de cientos de artículos), en densidad semántica (desde redacción técnica y legal hasta lenguaje divulgativo), y en estructura (desde texto corrido hasta documentos con tablas, gráficos y numeración jerárquica).

3.4. Marco de evaluación

El marco de evaluación principal empleado en este trabajo es RAGAS [9], cuya propuesta conceptual se revisó en el Capítulo 2. En este capítulo se describe su aplicación operativa, qué métricas concretas se calculan, cómo se implementan sobre el *golden dataset* construido y qué diagnostica cada una en el contexto de este experimento. La evaluación no se limita a un único enfoque, las métricas del marco RAGAS, que emplean un LLM como juez, se complementan con métricas léxicas clásicas de superposición de n-gramas y con una métrica de precisión del retriever implementada de forma independiente.

Concretamente, las métricas empleadas las podemos organizar en cuatro grupos según su naturaleza y el componente del sistema que evalúan.

Métricas con juez LLM

1. **FactualCorrectness (Corrección factual).** Métrica principal para la detección de alucinaciones. El LLM juez compara la respuesta generada con la respuesta de referencia del *golden dataset*, evaluando en qué medida los hechos contenidos en la respuesta son correctos y están respaldados por el *ground truth*. Para ello, el LLM juez descompone tanto la respuesta generada como la respuesta de referencia en afirmaciones atómicas y las contrasta entre sí, determinando cuáles

de las afirmaciones de la respuesta están respaldadas por la referencia y cuáles no. Produce una puntuación entre 0 y 1, valores próximos a 1 indican alta corrección factual, mientras que valores bajos señalan la presencia de información incorrecta, inventada o que no se ve reflejada en la respuesta de referencia.

2. **AnswerRelevancy (Pertinencia de la respuesta).** Evalúa si la respuesta generada es pertinente respecto a la pregunta formulada, con independencia de su corrección factual. Su mecanismo de cálculo consiste en generar un conjunto de preguntas sintéticas a partir de la respuesta del modelo y comparar su similitud con la consulta original mediante *embeddings*. Una puntuación baja indica que la respuesta no aborda lo que se preguntaba, sin embargo, una puntuación alta tampoco garantiza corrección factual, una respuesta puede ser plenamente pertinente a la pregunta y contener al mismo tiempo información incorrecta o inventada.
3. **Faithfulness (Fidelidad al contexto).** Mide qué proporción de las afirmaciones presentes en la respuesta generada están soportadas por el contexto recuperado. Es aplicable exclusivamente en la fase RAG, al requerir del contexto recuperado para su cálculo. El LLM juez descompone la respuesta generada en afirmaciones atómicas y verifica si cada una puede inferirse de los fragmentos de contexto recuperados. Produce un *score* entre 0 y 1, valores próximos a 1 indican que la respuesta no introduce información ajena al contexto (respuesta fundamentada mayoritariamente en el contexto recuperado), mientras que valores bajos señalan la presencia de información en la respuesta que no es extraíble del contexto recuperado.

Métricas de coincidencia léxica y semántica

4. **SemanticSimilarity (Similitud semántica).** Mide la similitud coseno entre el *embedding* de la respuesta generada y el *embedding* de la respuesta de referencia. No requiere llamada a un LLM juez, lo que la convierte en una métrica determinista y reproducible y sin coste adicional de API. Captura la proximidad semántica global entre ambos textos, siendo especialmente útil para detectar respuestas que se alejan del significado de la referencia, aunque no contengan afirmaciones explícitamente falsas.
 5. **BLEU Score.** Mide la superposición de n-gramas entre la respuesta generada y la respuesta de referencia del *golden dataset*. Produce un *score* entre 0 y 1. En el contexto de respuestas en lenguaje natural, la métrica es sensible a variaciones de vocabulario y paráfrasis, por lo que se interpreta de forma complementaria a las métricas semánticas.
 6. **ROUGE Score.** Familia de métricas orientadas al *recall* de n-gramas entre la respuesta generada y la referencia. A diferencia de BLEU, prioriza la cobertura
-

sobre la precisión. ROUGE-L, que mide la subsecuencia común más larga, resulta especialmente útil para capturar similitud estructural en respuestas de longitud variable. Al igual que BLEU, su principal limitación es la dependencia de la coincidencia exacta de texto, una respuesta puede expresar el mismo contenido que la referencia con una formulación distinta y obtener una puntuación baja, sin que ello implique un error factual.

7. **ChrF Score.** Métrica basada en superposición de n-gramas a nivel de carácter en lugar de token. Más robusta que BLEU y ROUGE ante variaciones morfológicas y formas flexivas, lo que la hace especialmente adecuada para el español, donde la riqueza morfológica puede penalizar artificialmente las métricas basadas en token. Aunque su operación a nivel de carácter la hace menos sensible a estas diferencias, comparte la misma limitación de fondo, la coincidencia de n-gramas de caracteres no garantiza que una respuesta correctamente formulada de forma distinta a la referencia reciba una puntuación representativa.

Métricas de recuperación

8. **Context Recall (Cobertura del contexto).** Mide en qué proporción el contenido necesario para responder la consulta está contenido en los fragmentos recuperados por el retriever, según la respuesta de referencia del *golden dataset*. El LLM juez verifica para cada parte de la respuesta de referencia si puede atribuirse a alguno de los fragmentos de contexto recuperados. Un valor alto indica que el retriever ha recuperado los fragmentos relevantes, un valor bajo señala problemas de cobertura que limitarán la generación independientemente de la calidad del modelo generador.
 9. **Context Precision (Precisión del contexto).** Mide qué fracción de los fragmentos recuperados son genuinamente relevantes para responder la consulta, teniendo en cuenta además el orden en que aparecen en el ranking. Se implementa como *Average Precision* (AP), una métrica que no solo considera cuántos fragmentos son relevantes, sino en qué posición los devuelve el retriever, a partir de los veredictos binarios de relevancia emitidos por el LLM juez para cada fragmento recuperado, el AP calcula la precisión acumulada en cada posición donde aparece un fragmento relevante y promedia dichos valores. Un retriever que sitúa los fragmentos relevantes en las primeras posiciones obtiene así una puntuación mayor que uno que los devuelve al final, aunque ambos recuperen el mismo número de fragmentos relevantes en total.
 10. **Precision@K.** Mide qué fracción de los K fragmentos recuperados por el retriever son semánticamente similares a los contextos de referencia del *golden dataset*. A diferencia de Context Precision, que emplea un LLM juez, esta métrica se implementa de forma manual calculando la similitud coseno entre los *embeddings*
-

de los fragmentos recuperados y los de referencia mediante el modelo Qwen3. Un fragmento se considera relevante si su similitud con el contexto de referencia más cercano supera un umbral predefinido. Este enfoque evita la necesidad de un juez externo para este componente del *pipeline*.

Métricas conversacionales

11. **AspectCritic (Ausencia de alucinaciones conversacionales)**. Emite un juicio binario (0/1) sobre si la conversación completa, evaluada como unidad de análisis, cumple el criterio de estar libre de alucinaciones. El LLM juez verifica que las respuestas generadas a lo largo de toda la conversación contengan únicamente información factualmente correcta y verificable, sin introducir datos, cifras o afirmaciones no respaldadas por el historial conversacional establecido en turnos anteriores. Su naturaleza binaria la hace especialmente útil para detectar si el modelo falla de forma sistemática a lo largo de la conversación, aunque no cuantifica el grado de fallo. Como limitación metodológica relevante de esta métrica, cabe señalar que, el LLM juez no tiene acceso a las respuestas de referencia ni a los contextos del *golden dataset*, por lo que su veredicto se basa exclusivamente en su propio convencimiento, sin poder contrastar las respuestas del modelo con el *ground truth*.
12. **SimpleCriteriaScore (Consistencia conversacional)**. Evalúa la conversación completa según una rúbrica flexible definida en lenguaje natural, produciendo una puntuación continua en una escala definida por el evaluador. En este trabajo se emplea para medir la consistencia interna de la conversación completa, verificando que las respuestas sucesivas no se contradigan entre sí ni introduzcan información que contradiga lo establecido en turnos anteriores. La escala empleada va de 1 (contradicciones graves o alucinaciones acumuladas) a 5 (consistencia factual completa a lo largo de toda la conversación). Complementa AspectCritic al cuantificar el grado de coherencia conversacional que el juicio binario no puede capturar. Comparte la misma limitación, el LLM juez evalúa la conversación sin acceso al *golden dataset*, por lo que la puntuación refleja su criterio sobre la consistencia interna de la conversación, pero no puede contrastarla con las respuestas de referencia.

3.5. Entorno de ejecución

La ejecución de este trabajo se llevó a cabo sobre Google Colaboratory, utilizando la CPU estándar disponible en el nivel gratuito de la plataforma para la mayor parte del proceso. Las operaciones computacionalmente intensivas, en particular el cálculo de *embeddings* con el modelo Qwen3 para la métrica Precision@K, se ejecutaron sobre GPU NVIDIA Tesla T4 (16 GB de VRAM), disponible en las sesiones de GPU de Google Colab.


4. Diseño y resolución del trabajo realizado

4.1. Extracción y preprocesamiento del corpus

La primera etapa de este trabajo consistió en transformar el corpus documental de AMC Global¹, compuesto por ficheros PDF de naturaleza heterogénea, en texto limpio y estructurado apto para las fases posteriores de construcción del *golden dataset* y desarrollo del *chunking* del sistema RAG. Este proceso de extracción del texto se articuló en torno a un *pipeline* secuencial cuya unidad de procesamiento es la página individual, y no el documento completo. Esta decisión de diseño responde a una importante razón, permite seleccionar el método de extracción más adecuado para cada página según sus características visuales y estructurales, ya que un mismo documento puede contener simultáneamente páginas de texto nativo directamente accesible, junto con páginas escaneadas sin capa de texto, o incluso páginas con tablas cuya extracción directa puede producir resultados inutilizables, por lo que al hacer la extracción por página evitamos así aplicar un mismo criterio a páginas de naturaleza muy dispar. La extracción por página garantiza la trazabilidad del proceso. Cada página del JSON de salida registra el método de extracción empleado, información relevante para la revisión posterior de resultados.

Este flujo de extracción del texto implementa un diseño híbrido que combina la librería PyMuPDF con la API de OpenAI para emplear la funcionalidad de visión artificial (GPT-4o). La elección del método con el que se procesa cada página se realiza automáticamente siguiendo una lógica de dos fases. En la primera, PyMuPDF analiza el *layout* de la página para determinar si contiene tablas. Cuando se detecta una tabla, la página se deriva directamente a la API de visión, ya que PyMuPDF extrae el contenido tabular descompuesto celda a celda, generando una secuencia de valores aislados por línea que pierde completamente la estructura relacional de los datos. En la segunda fase, aplicable únicamente a las páginas sin tablas detectadas, se extrae el texto con PyMuPDF y se evalúa su usabilidad mediante una función `is_text_usable`, diseñada para medir la calidad del texto extraído. Si el texto supera los criterios de calidad, se retiene, en caso contrario, la página se reenvía a la API OpenAI, para volver a extraer el texto por este otro método de visión con GPT-4o.

¹El código desarrollado para este trabajo está disponible en <https://github.com/jaac333/dataScienceDegree/tree/main/TFG>.

**Figura 4.1:** Diagrama del flujo de procesamiento del texto.

La función `is_text_usable` evalúa el texto extraído por PyMuPDF mediante cinco criterios heurísticos, cada uno diseñado para detectar un tipo específico de fallo en la extracción. El primero es la longitud mínima, si el texto extraído no supera los 40 caracteres, la página se entiende como un escaneo o como una página sin contenido textual accesible, por lo que se prefiere la extracción de su texto vía API. El segundo examina el ratio de caracteres válidos, si más del 15% de los caracteres no son alfanuméricos ni pertenecen al conjunto de puntuación habitual en español, el texto se considera basura de codificación resultante de una extracción fallida. El tercero verifica la presencia de espacios, un texto con menos del 5% de espacios se considera que carece de separación real entre palabras, lo que es propio de texto sin mapeo tipográfico correcto. El cuarto aplica la entropía de Shannon como discriminador de calidad, una medida del grado de imprevisibilidad o variedad de la distribución de caracteres de un texto, expresada en bits por carácter, el texto real en español presenta valores de entre 3.5 y 5.5 bits por carácter, por lo que valores inferiores a 2.5 indican texto hiperrepetitivo y valores superiores a 6.0 señalan texto aleatorio característico de errores de codificación. Estos umbrales de rechazo se fijan deliberadamente más allá del rango típico para no descartar texto legítimo que se desvíe de forma leve de los valores habituales. El quinto criterio detecta tablas que PyMuPDF no identificó como tales en la fase anterior, si más del 70% de las líneas no vacías de la página contienen un único token, el patrón es indicativo de una extracción fragmentada por columnas. Si alguno de estos cinco criterios no se cumple, la página es derivada a la API de OpenAI para su extracción mediante visión artificial.

Cuando una página se procesa mediante la API de OpenAI, se convierte a imagen PNG a 300 DPI y se envía al modelo GPT-4o junto con un *prompt* de instrucción estructurado. Dicho *prompt* instruye al modelo para que transcriba el contenido visible en orden de lectura natural, ignorando cabeceras, pies de página y marcas de agua. Para representar el contenido de tablas con las columnas separadas se le pide al modelo que emplee el carácter |, para describir gráficos y figuras informativas, la etiqueta [CHART] :, y que emita la cadena [EMPTY PAGE] cuando la página no contiene contenido extraíble. En ambos métodos de extracción el resultado es texto plano, de modo que el conjunto de páginas del documento queda en un formato homogéneo con independencia del método empleado en cada una. El *prompt* completo empleado se recoge en el Anexo A.1.

Sobre el texto extraído de cada página, se aplica una cadena de cinco transformaciones de limpieza ejecutadas en orden fijo. La primera de estas transformaciones elimina los números de página aislados, suprimiendo las líneas del comienzo o del final de página que contienen exclusivamente un número de entre uno y tres dígitos, la restricción a tres dígitos es deliberada para no eliminar años, importes u otros valores numéricos que puedan aparecer solos en el texto. La segunda normaliza los caracteres tipográficos especiales que los procesadores de texto modernos insertan automáticamente, sustituyendo guiones tipográficos de distinta longitud, comillas tipográficas, puntos suspensivos, *bullets* y espacios de no separación por sus equivalentes ASCII, esta normalización

garantiza la consistencia del tokenizador en etapas posteriores, dado que codepoints tipográficamente similares realmente son tokens distintos para los modelos de lenguaje. La tercera colapsa tabulaciones, espacios múltiples y secuencias de más de dos saltos de línea consecutivos, que se reducen a un máximo de dos. La cuarta señala las URLs y las direcciones de correo electrónico envolviéndolas en etiquetas estructuradas ([URL: ...] y [EMAIL: ...]) preservando el valor original, al ser información de contacto potencialmente recuperable por el sistema RAG ante consultas específicas del usuario resulta útil añadirles este placeholder identificativo. La quinta y última transformación elimina dos tipos de líneas residuales propias de la extracción de índices, como son las líneas que contienen únicamente un identificador de sección con formato numérico N.M. sin texto adicional, y líneas de índice con puntos de relleno del tipo TÍTULO 42.

Una vez disponible el texto procesado de todas las páginas, se aplica un segundo nivel de limpieza que opera sobre el conjunto del documento completo en lugar de sobre páginas individuales. Este paso detecta y elimina las líneas recurrentes que corresponden a cabeceras y pies de página embebidos en el PDF, siguiendo un criterio combinado de frecuencia y posición, una línea se considera candidata a cabecera o pie de página si aparece en las primeras o últimas cinco líneas de al menos el 30% de las páginas del documento. El requisito posicional es lo que diferencia a este método de una simple detección por frecuencia, una frase que se repita en el cuerpo del texto en múltiples páginas no sería eliminada si no aparece sistemáticamente en los extremos. La pertinencia de este paso para la calidad del sistema RAG es directa, sin él, textos recurrentes como el eslogan corporativo de AMC Global o el título completo de documentos aparecerían en muchos de los *chunks* generados, contaminando las búsquedas por similitud semántica del *retriever* con fragmentos sin información única útil.

El resultado final del procesamiento de cada documento es un fichero JSON que recoge los metadatos del proceso y el contenido textual estructurado. El fichero incluye el nombre original del documento, un identificador secuencial asignado durante el procesamiento, la fecha de procesado, el número de páginas y un array con el detalle de cada página. Dicho array de páginas registra por cada una el número de página, el método de extracción empleado, el texto crudo obtenido antes de la limpieza y el texto procesado resultante. Se incluye además un campo `texto_completo` que concatena el texto procesado de todas las páginas no vacías, proporcionando un bloque textual único del documento completo que sirve de entrada a la fase de *chunking*. La estructura completa de un fichero JSON de salida se ilustra en el Anexo B.1.

Conviene precisar que el resultado de esta etapa no es el corpus final fragmentado que se indexa en el sistema RAG, sino el corpus de texto limpio extraído de los documentos PDF, todavía sin segmentar. Este corpus textual constituye la base de dos fases posteriores e independientes, la generación del *golden dataset* de preguntas, descrita en la Sección 4.2, y la segmentación en *chunks* e indexación que alimenta al *retriever*, descrita en la Sección 4.4.1.

4.2. Construcción del *golden dataset*

La construcción del *golden dataset* $\mathcal{Q} = \{(q_i, r_i^*, C_i^*)\}_{i=1}^N$, definido en el Capítulo 3, constituye una fase muy relevante del diseño experimental, ya que la calidad y variabilidad de las métricas de evaluación calculadas posteriormente dependen en parte de la representatividad y rigor de este conjunto de referencia. El *dataset* se compone de dos subconjuntos complementarios, preguntas de turno único (*single-turn*), donde cada consulta es autocontenida e independiente, y conversaciones multiturno (*multi-turn*), donde las preguntas se encadenan en secuencias que simulan una conversación real con el asistente. El proceso de generación de ambos subconjuntos se llevó a cabo mediante llamadas a la API de OpenAI (GPT-4.1) incluyendo en cada *prompt* el texto completo de cada documento del corpus, con posterior validación automática del contexto y curación manual de los registros generados. En la generación de ambos subconjuntos de preguntas se descartó la posibilidad de fragmentar previamente el corpus mediante *chunking*, esto fue una decisión metodológica, ya que si las preguntas se generaran sobre los mismos fragmentos empleados para construir el sistema RAG, se introduciría un sesgo de alineación conocido en la literatura como *chunk-level evaluation bias* [27], por el que un sistema cuya estrategia de fragmentación coincida con la empleada durante la generación de las preguntas obtendría ventaja artificial en las métricas que lo evalúan respecto a sistemas con otra configuración de *chunking*, sesgando la evaluación a favor de ese diseño concreto. Generar las preguntas sobre el texto completo de cada documento garantiza que cualquier estrategia de *chunking* aplicada posteriormente al sistema RAG pueda cubrir los contextos de referencia de forma parcial o completa sin privilegiar artificialmente ninguna configuración. Esta decisión es técnicamente viable gracias a la amplia ventana de contexto de GPT-4.1, que alcanza el millón de tokens y permite incluir en un único *prompt* el texto íntegro incluso del documento más extenso del corpus.

4.2.1. Preguntas de turno único (*single-turn*)

Las preguntas se clasifican en cuatro categorías según el tipo de competencia que evalúan:

1. **Preguntas factuales verificables** (*factual_true*): tienen una respuesta extraíble directamente del texto y evalúan la capacidad del sistema para recuperar y presentar información explícita del corpus.
2. **Preguntas de razonamiento** (*factual_reasoning*): requieren inferencia, síntesis o comparación entre partes distintas del documento, y permiten distinguir sistemas que comprenden el contenido de los que simplemente localizan fragmentos relevantes.
3. **Preguntas con trampa** (*factual_trap*): contienen una premisa falsa o distorsionada que el sistema debe detectar y corregir, evaluando la robustez frente

a suposiciones incorrectas del usuario, uno de los patrones de alucinación más frecuentes en sistemas de RAG corporativo.

4. **Preguntas fuera del dominio** (*out_of_domain*): son consultas plausibles cuya respuesta no se encuentra en ningún documento del corpus. Ante ellas, la respuesta correcta de un sistema de dominio cerrado es la abstención informativa, si el sistema responde con información paramétrica interna del modelo en lugar de abstenerse, incurre en una alucinación [28, 29]. Como decisión de diseño, la respuesta de referencia de estas preguntas se fija de forma uniforme en la cadena “*No se puede responder con la información disponible en la documentación de AMC Global.*”, garantizando así que el *ground truth* de abstención sea homogéneo entre documentos y no esté sujeto a variaciones de formulación que pudieran introducir inconsistencias en la evaluación.

El número de preguntas factuales a generar por documento, dejando al margen las *out_of_domain* por no requerir información extraíble del documento, se determina mediante un ratio de una pregunta por cada 800 palabras, valor adoptado a partir de la práctica descrita en Thakur et al. [27], que establece aproximadamente cinco preguntas para documentos de entre 3.500 y 4.300 palabras. El resultado del ratio se acota con un mínimo de una pregunta y un máximo de 25, de modo que todos los documentos del corpus quedan representados en el *dataset* con independencia de su extensión, sin sobre representar a los más extensos. Cuando el total de preguntas factuales que se determina que pueden extraerse para un documento es igual o superior a tres, la distribución entre los tres tipos de preguntas factuales sigue las proporciones del 34% para *factual_true*, el 33% para *factual_trap* y el resto para *factual_reasoning*, con la restricción de que cada tipo reciba al menos una pregunta. Las preguntas *out_of_domain*, cuya respuesta de referencia no se extrae del documento sino que se fija por diseño como abstención (véase el punto 4 del listado anterior), se calculan de forma independiente como un 15% adicional sobre ese total factual y no compiten por cuota dentro del máximo de 25 con las preguntas factuales, pudiendo elevar el recuento total del documento por encima de dicho límite. Cuando el total factual es de una o dos preguntas, las preguntas *out_of_domain* se suprimen y la asignación entre los tipos factuales se realiza mediante una distribución cíclica determinista, priorizando la diversidad tipológica sobre la proporcionalidad.

Para la generación de cada pregunta, junto con su respuesta de referencia r_i^* y su contexto de referencia C_i^* , se emplearon cuatro *prompts* independientes escritos en inglés, uno por cada categoría. La elección del inglés como idioma de instrucción, con independencia del idioma de los documentos del corpus, responde a la evidencia empírica de que los LLMs ofrecen mayor consistencia y precisión cuando reciben instrucciones en inglés, incluso cuando la salida esperada está en otro idioma [30]. Cada *prompt* define con precisión el tipo de pregunta que debe generarse, el de *factual_true* solicita preguntas con respuesta directamente extraíble del texto, exigiendo que cada una cubra un apartado distinto del documento y emplee una estructura gramatical diferente, el

de *factual_reasoning* requiere preguntas que no puedan responderse desde una única frase, sino que impliquen inferencia, comparación causal o síntesis entre fragmentos del documento, el de *factual_trap* pide preguntas con una premisa falsa o distorsionada incrustada de forma plausible (valor numérico incorrecto, atribución errónea, negación falsa, condición excluida, etc.), y el de *out_of_domain* solicita preguntas temáticamente relacionadas con el documento pero cuya respuesta no figura en él. Todos los *prompts* incluyen además una sección de reglas de lenguaje que prohíben explícitamente el uso de expresiones meta-documentales como «según el documento» o «el documento establece», con el fin de aumentar el realismo del *dataset* y evitar preguntas que solo tendrían sentido en un contexto académico de análisis textual.

La metodología de generación incorpora tres estrategias complementarias para mitigar el riesgo de repetitividad en las preguntas generadas, que es inherente al uso de LLMs cuando se genera un volumen moderado de preguntas sobre un mismo documento. La primera opera a nivel de cada *prompt*, todos incluyen una sección de requisitos de diversidad que instruye explícitamente al modelo para que base cada pregunta en un apartado o fragmento distinto del documento y varíe la estructura gramatical entre preguntas, favoreciendo así una cobertura amplia del contenido documental. La segunda consiste en el uso de cuatro *prompts* separados, uno por categoría, al no requerir que un único *prompt* gestione todos los tipos, se evita el efecto de posición que tiende a manifestarse en *prompts* largos con múltiples instrucciones, donde los LLMs tienden a prestar mayor atención a las primeras instrucciones y a generar las últimas con menor diversidad temática y léxica. La tercera actúa a través de los parámetros de generación, en particular la temperatura, que se describe en el párrafo siguiente. Las cuatro llamadas a la API se ejecutan en paralelo, reduciendo el tiempo total de generación por documento. Los cuatro *prompts* se recogen íntegramente en el Anexo A.2.

La temperatura se configuró de forma diferenciada en función del tipo de pregunta a generar. Las tres categorías factuales se generaron con temperatura 0.7, valor que favorece la diversidad léxica en la formulación sin comprometer la precisión factual de las respuestas. Las preguntas *out_of_domain* se generaron con temperatura 0.85, algo superior, para incentivar una mayor capacidad creativa del modelo a la hora de proponer preguntas plausibles sobre temáticas que, por definición, no aparecen en el documento. En todos los casos se utilizó el parámetro `response_format: json_object` de la API para garantizar que el modelo devuelva siempre un JSON parseable.

Con el fin de verificar que los contextos de referencia generados provienen efectivamente del texto del documento y no son paráfrasis inventadas por el modelo, se implementó una función de validación basada en *fuzzy string matching*. Este tipo de validación cuantifica la similitud textual entre dos cadenas de caracteres como la proporción de caracteres coincidentes entre ellas, en concreto, el algoritmo de Ratcliff/Obershelp, implementado mediante `difflib.SequenceMatcher`, calcula dicha similitud como $S = 2M/T$, donde M es el número total de caracteres coincidentes encontrados de forma recursiva en las subsecuencias comunes y T es el número total de caracteres de ambas cadenas. Antes de la comparación, tanto el contexto generado

como el texto del documento se normalizan (conversión a minúsculas y eliminación de puntuación y espacios redundantes) para no penalizar diferencias superficiales de capitalización o tipografía. La comparación se realiza sobre el texto normalizado, pero el fragmento que finalmente se almacena en el *dataset* como contexto de referencia es el original, un mapa de posiciones registra la correspondencia entre ambas versiones del texto del documento, permitiendo recuperar el fragmento exacto sin normalizar a partir de la posición encontrada en la búsqueda. La función se aplica mediante ventana deslizante sobre el texto normalizado del documento, si la similitud obtenida para un contexto de referencia devuelto es inferior a 0.85, dicho contexto se marca para revisión manual. Finalizada la validación automática, el conjunto completo fue sometido a una revisión humana para verificar la calidad de las preguntas, la corrección de las respuestas de referencia y la coherencia de los contextos seleccionados.

El resultado del proceso es un fichero en formato JSONL donde cada línea contiene una pregunta con los campos requeridos por el marco de evaluación RAGAS: `user_input` (la pregunta), `reference_contexts` (lista de fragmentos del texto original que soportan la respuesta, separados cuando el modelo los devuelve concatenados mediante el separador [...]), `reference` (la respuesta de referencia) y los campos `retrieved_contexts` y `response`, que se dejan vacíos en esta fase y se rellenan durante la evaluación del sistema RAG. Los metadatos de cada ítem (identificador, categoría y documento de procedencia) se agrupan en el campo `metadata` de cada línea del JSONL. El subconjunto *single-turn* resultante comprende 133 preguntas distribuidas entre los 12 documentos del corpus. La estructura de una entrada del fichero se ilustra en el Anexo B.2.

4.2.2. Conversaciones multiturno (*multi-turn*)

El subconjunto de conversaciones multiturno responde a la necesidad de evaluar el experimento en condiciones que van más allá de la consulta puntual. Una batería de preguntas de turno único permite medir la capacidad de recuperación y síntesis ante consultas aisladas, pero no captura fenómenos propios de una interacción real sostenida como la degradación de la calidad de las respuestas a lo largo de la conversación, la capacidad de mantener coherencia referencial entre turnos, o la aparición de alucinaciones por acumulación de contexto conversacional. Las conversaciones multiturno permiten medir estas dimensiones de forma sistemática, y constituyen el vector de evaluación que Kwan et al. [8] identifica como más discriminativo para distinguir sistemas cuyo rendimiento depende del historial conversacional.

La generación de cada conversación multiturno parte de una pregunta semilla extraída del subconjunto *single-turn*. Se excluyeron como candidatas las preguntas de categoría *factual_trap* y *out_of_domain*, las primeras porque contienen una premisa intencionalmente falsa que podría influir en la calidad de la coherencia factual de los turnos generados, y las segundas porque carecen de contexto documental de referencia a partir del cual construir respuestas fundamentadas. De entre las preguntas

restantes, la selección de las diez semillas definitivas se realizó mediante una función de *scoring* automático que asigna una puntuación compuesta a cada pregunta candidata según cuatro criterios ponderados. El primero es la riqueza del contexto de referencia, medida como la longitud en caracteres del **reference_context** (peso del 30%), ya que contextos más extensos ofrecen más material al modelo generador para construir turnos adicionales coherentes. El segundo es la categoría de la pregunta (25%), con *factual_reasoning* preferida sobre *factual_true* por la mayor densidad de relaciones causales en sus contextos. El tercero es la densidad de entidades nombradas en el contexto de referencia (25%), calculada mediante una llamada a GPT-4o-mini con la instrucción «*Count the number of named entities in the following text (organizations, dates, quantities, locations, products). Reply ONLY with an integer.*», dado que un mayor número de entidades abre más ángulos de seguimiento para patrones conversacionales de tipo *Follow-up* y *Expansion*. El cuarto es la diversidad respecto a las semillas ya seleccionadas (20%), calculada como el complemento de la similitud coseno máxima entre el *embedding* del contexto candidato y los de las semillas ya confirmadas, calculados con *text-embedding-3-small*, este criterio toma valor 1.0 para la primera semilla y decrece proporcionalmente a medida que aumenta la similitud con las semillas ya elegidas. La selección sigue un algoritmo *greedy* secuencial, en cada iteración se elige la candidata con mayor puntuación global considerando las semillas ya confirmadas, lo que garantiza que la diversidad temática se evalúe de forma acumulativa.

Cada semilla incorpora un **reference_context** que en la mayoría de los casos comprende entre dos y cuatro frases del documento original. Proporcionar exclusivamente ese fragmento al modelo encargado de generar la conversación completa resulta insuficiente para sostener varios turnos coherentes, ya que el material se agotaría en el segundo turno y el modelo puede recurrir a información no presente en el corpus, sin embargo, proporcionar el documento íntegro introduce el riesgo opuesto, permitiría que el modelo construyese turnos basados en secciones semánticamente alejadas de la semilla. Para resolver este compromiso se empleó una estrategia de ampliación por ventana de caracteres, cada fragmento del **reference_context** de la pregunta semilla se localiza dentro del texto completo del documento y se amplía con una ventana simétrica de ± 1.500 caracteres a su alrededor (1.500 caracteres anteriores y 1.500 caracteres posteriores), obteniendo una sección acotada que incluye el fragmento de referencia y material adicional que puede ser usada por el LLM generador del dataset para construir la conversación. En los casos en que la semilla cuenta con múltiples fragmentos en **reference_contexts**, la ampliación se aplica de forma independiente sobre cada uno y los resultados se concatenan mediante el separador [...], aplicando previamente un mecanismo de deduplicación basado en similitud de secuencias que descarta fragmentos cuyo inicio solapa significativamente con el final del fragmento anterior.

Para la generación automática de las conversaciones se diseñaron cuatro *prompts* en inglés, uno por cada patrón conversacional de MT-Eval [8]: *Follow-up*, *Expansion*, *Refinement* y *Recollection*. Cada *prompt* operacionaliza su patrón mediante instrucciones precisas sobre lo que el modelo generador debe y no debe hacer en cada turno, e incor-

pora las mismas reglas de lenguaje no meta-documentales empleadas en el subconjunto *single-turn*, así como la obligación de incluir un campo `source_fragment` con el fragmento exacto del documento que respalda cada respuesta del asistente, mecanismo que garantiza la trazabilidad de las respuestas generadas. El *prompt* de *Follow-up* fija el turno 1 como la pregunta semilla y solicita turnos adicionales en los que cada pregunta del empleado referencie directamente un elemento específico de la respuesta inmediatamente anterior del asistente, haciendo cada turno semánticamente dependiente del precedente. El de *Expansion* genera turnos que exploran aspectos distintos dentro del mismo dominio temático del turno 1, sin referenciar las respuestas anteriores, cubriendo progresivamente diferentes dimensiones del documento. El de *Refinement* genera turnos en los que el empleado añade progresivamente nuevas restricciones a su petición original (de ámbito, de formato, de actor, de periodo temporal), con la condición de que cada respuesta satisfaga simultáneamente todas las *constraints* acumuladas hasta ese punto, el campo `constraint_added` registra de forma explícita la restricción introducida en cada turno. El *prompt* de *Recollection* constituye la excepción de diseño, dado que el patrón requiere que el turno 1 establezca una instrucción o condición global persistente (como una preferencia de formato o una restricción de ámbito que el asistente debe mantener durante toda la conversación), en lugar de formular una consulta factual, este *prompt* genera todos los turnos desde cero sin utilizar semilla. Las conversaciones de tipo *Recollection* se articulan en tres tipos de turno bien diferenciados: el turno primero de *instruction*, en el que el empleado establece la condición persistente, los turnos puente (*bridge*), que formulan preguntas sobre distintos aspectos del documento sin mencionar explícitamente la instrucción inicial, y el turno de prueba (*recollection-test*), que formula una consulta que solo puede responderse correctamente si el asistente ha retenido y aplicado la instrucción del turno 1. Esta distinción de roles queda registrada en el campo `type` de cada turno de este tipo de patrón. Los cuatro *prompts* se recogen íntegramente en el Anexo A.3.

La temperatura se calibró en función del nivel de restricción estructural de cada patrón. *Refinement* recibió el valor más bajo (0.50) para maximizar la adherencia a las *constraints* acumuladas. *Follow-up* y *Expansion* recibieron valores intermedios (0.70 y 0.75, respectivamente), equilibrando coherencia referencial y diversidad temática. *Recollection* recibió el valor más alto (0.85) para favorecer la naturalidad de la instrucción global generada en el turno 1, cuya credibilidad como petición real de un empleado es determinante para la validez del patrón. El parámetro `top_p` se mantuvo en su valor por defecto de 1.0 en todos los casos. En cuanto al número de turnos, *Follow-up*, *Expansion* y *Refinement* producen 3 turnos adicionales a la semilla (4 turnos en total por conversación), mientras que *Recollection* genera 5 turnos completos, con 3 turnos puente entre la instrucción inicial y el turno de prueba, configuración que supera el umbral de distancia a partir del cual Kwan et al. [8] reporta degradación estadísticamente significativa en este patrón.

De las 40 conversaciones generadas (10 semillas $\times$ 4 patrones), 17 fueron retenidas tras una revisión humana que evaluó la coherencia conversacional, la corrección factual

de las respuestas y la ausencia de información inventada no presente en el corpus. El subconjunto multiturno definitivo comprende 4 conversaciones de cada uno de los patrones *Follow-up*, *Expansion* y *Refinement*, y 5 conversaciones de *Recollection*, con un total de 71 turnos distribuidos entre los documentos del corpus. La estructura de una entrada del fichero se ilustra en el Anexo B.3.

4.2.3. Composición y validación final del *golden dataset*

El *golden dataset* resultante quedó compuesto por 133 preguntas de turno único y 17 conversaciones multiturno, estas últimas con un total de 71 turnos. La Tabla 4.1 detalla su distribución por categoría y por patrón conversacional.

Tabla 4.1: Composición del *golden dataset*.

Subconjunto	Categoría / Patrón	Cantidad
<i>Single-turn</i> (133 preguntas)		
	<i>factual_true</i>	41 (30,8%)
	<i>factual_reasoning</i>	40 (30,1%)
	<i>factual_trap</i>	33 (24,8%)
	<i>out_of_domain</i>	19 (14,3%)
<i>Multi-turn</i> (17 conversaciones, 71 turnos)		
	<i>Follow-up</i>	4
	<i>Expansion</i>	4
	<i>Refinement</i>	4
	<i>Recollection</i>	5

Dado que las preguntas y sus respuestas de referencia se generaron mediante un modelo de lenguaje, su validación resulta imprescindible para mitigar el posible sesgo introducido por el modelo generador, un riesgo que, además, ya se aborda en dos puntos del diseño, las estrategias de diversidad aplicadas durante la generación de las preguntas (página 24) y la exclusión del modelo generador del conjunto de modelos evaluados (página 29). El conjunto se sometió a una validación en dos niveles. En el primero, automático, la función de *fuzzy matching* ya descrita verificó que los contextos de referencia procedían efectivamente del texto de los documentos. En el segundo, manual, los registros fueron curados conjuntamente por el autor y un experto del dominio de AMC Global, su científico de datos más experimentado, que comprobaron la corrección de las respuestas de referencia, la coherencia de los contextos seleccionados, la ausencia de información inventada y la verosimilitud de las preguntas, (en qué medida se asemejaban a consultas que un empleado formularía realmente). Al ser el experto

el único validador externo y dada su mayor experiencia, su criterio prevaleció en los casos de duda, por lo que no se requirió un protocolo de reconciliación entre anotadores, las preguntas señaladas como poco naturales o incoherentes se reformularon o se descartaron.

4.3. Comparación *baseline*

La comparación *baseline* tiene como propósito establecer la línea de referencia del experimento, cuantificando hasta qué punto los modelos son capaces de responder sobre la documentación interna de AMC Global apoyándose exclusivamente en su conocimiento paramétrico, sin acceder a ningún documento durante la inferencia. Esta condición es imprescindible para aislar, en la fase posterior de evaluación del sistema RAG, la ganancia real que el componente de recuperación aporta sobre los modelos sin acceso al contexto, sin ella no sería posible determinar si las mejoras observadas se deben al diseño del *pipeline* RAG o simplemente al conocimiento previo del modelo. El experimento se estructuró como una comparativa entre dos modelos de distintos proveedores, combinada con un estudio paramétrico de cuatro configuraciones de generación.

Los modelos seleccionados son GPT-4o (OpenAI, versión `gpt-4o-2024-11-20`) y Gemini 2.5 Flash (Google DeepMind, versión `gemini-2.5-flash`). La elección responde a tres criterios. El primero es la equiparabilidad de capacidades base, ambos obtienen resultados prácticamente idénticos en el *benchmark* MMLU [31], con GPT-4o en el 88,7% y Gemini 2.5 Flash en el 88,4% de exactitud (porcentaje de respuestas correctas sobre el conjunto de preguntas de opción múltiple del *benchmark*), lo que garantiza que la comparativa no parte de un desequilibrio de capacidades que pudiera enmascarar el efecto de los parámetros de generación estudiados. El segundo es la transparencia paramétrica, ambos modelos exponen públicamente vía API los parámetros `temperature` y `top_p`, condición indispensable para el estudio de configuraciones descrito más adelante. El tercero es la ausencia de sesgo de generación sobre el *golden dataset*, ninguno de los dos modelos escogidos participó en la construcción del conjunto de evaluación. GPT-4o pertenece a la línea de modelos omni de OpenAI, con arquitectura y entrenamiento propios (modelo multimodal nativo diseñado para procesar y generar texto, audio, imagen y vídeo de forma simultánea), e independiente tanto de la familia GPT-4.1 (orientada a programación y seguimiento de instrucciones, que agrupa GPT-4.1, GPT-4.1-mini y sus variantes) como de la familia o-series (modelos de razonamiento extendido como o1, o3 y sus variantes). La familia GPT-4.1, un conjunto de modelos distinto de GPT-4o pese al prefijo compartido, fue descartada por haber sido empleada íntegramente en la generación de las preguntas del *golden dataset*, someter al mismo modelo que generó las preguntas a la evaluación posterior introduciría un sesgo de familiaridad por el que el modelo tendería a reconocer o favorecer sus propias formulaciones [32]. La familia o-series (modelos de razonamiento extendido como o1, o3 y sus variantes), con la que GPT-4o no guarda relación pese a compartir la letra

«o», fue descartada porque no expone los parámetros de generación en su API pública. Gemini 2.5 Flash incorpora de forma nativa un mecanismo de razonamiento extendido, el *thinking mode*, que incrementa significativamente su rendimiento en tareas de razonamiento complejo a costa de mayor latencia y coste por token, en este experimento fue desactivado explícitamente mediante el parámetro `thinking_budget=0`, dado que elevaría artificialmente las capacidades de Gemini sobre GPT-4o al no existir un mecanismo equivalente en este último, además de que cuando está activo la API no expone `temperature` ni `top_p` de forma controlable, lo que haría imposible el estudio paramétrico. La desactivación de este mecanismo de razonamiento sitúa a Gemini 2.5 Flash en su modo de generación estándar, en el que sus capacidades base convergen con las de GPT-4o según los *benchmarks* mencionados y ambos modelos compiten en igualdad de condiciones.

La evaluación de las respuestas mediante RAGAS requiere un modelo juez que actúe como evaluador externo para las métricas que no pueden calcularse mediante solapamiento léxico (conteo de n-gramas compartidos entre respuesta generada y referencia) o similitud de *embeddings*. Según la literatura, la selección del modelo juez debe satisfacer dos condiciones, la primera es que el juez ha de ser más capaz que los modelos evaluados en tareas de razonamiento factual, para garantizar que sus juicios son fiables, y la segunda que ha de pertenecer a una familia diferente a los modelos evaluados, para evitar el sesgo de auto-preferencia por el que los modelos LLM-as-judge tienden a valorar más favorablemente las respuestas generadas por modelos de su misma familia [19, 32]. El modelo juez seleccionado fue GPT-5-mini (versión `gpt-5-mini-2025-08-07`), configurado con nivel de razonamiento *medium*. La elección de este modelo como juez no fue directa, inicialmente se optó por GPT-5 como juez, al superar con claridad a los modelos evaluados en *benchmarks* de razonamiento factual y pertenecer a una generación distinta, sin embargo, su coste por token resultó inasumible a escala del experimento completo, por lo que se sustituyó por GPT-5-mini, que pertenece a la misma familia GPT-5, mantiene la superioridad de razonamiento frente a GPT-4o y Gemini 2.5 Flash, y opera a un coste aproximadamente cinco veces inferior, lo que resulta coherente con la práctica habitual del propio *framework* RAGAS, cuya documentación oficial emplea modelos de la gama *mini* como juez de referencia en sus ejemplos [9].

Llegados a este punto, cabe mencionar explícitamente que los tres papeles desempeñados por modelos de lenguaje en el experimento recaen en familias distintas, la generación del *golden dataset* (GPT-4.1), los modelos evaluados (GPT-4o y Gemini 2.5 Flash) y el modelo juez (GPT-5-mini), de modo que ningún modelo evaluado generó las preguntas ni actúa como su propio juez. No obstante, conviene reconocer una limitación, el generador de las preguntas, el juez y uno de los dos modelos evaluados (GPT-4o) provienen del mismo proveedor, OpenAI, por lo que no puede descartarse del todo una afinidad de proveedor que beneficie sutilmente a GPT-4o frente a Gemini. Esta dependencia se atenúa porque el generador y el juez pertenecen a familias y generaciones distintas de GPT-4o. Además, los resultados del Capítulo 5 muestran que Gemini supera a GPT-4o en corrección factual en el subconjunto *single-turn* pese a

que el juez procede de OpenAI, lo que indica que el juez no favorece sistemáticamente al modelo de su mismo proveedor.

Para estudiar el efecto de los parámetros de generación sobre la tasa de alucinación y la calidad de las respuestas, se definieron cuatro configuraciones que combinan la variación de temperatura y `top_p` de forma coherente, a mayor temperatura, menor `top_p`. Este diseño multivariante responde directamente al objetivo del TFG, si se evaluara una única configuración de parámetros, no sería posible discernir si las diferencias observadas entre modelos se deben a la arquitectura y al entrenamiento del modelo o a una configuración de generación que favorece sistemáticamente a uno de ellos, al recorrer cuatro puntos del espacio temperatura-`top_p` es posible identificar si la brecha entre modelos se mantiene estable o varía en función de la aleatoriedad de la generación, y caracterizar en qué configuración cada modelo exhibe mayor tendencia a alucinaciones. El parámetro `top-k` fue descartado para garantizar la simetría entre ambas APIs, dado que GPT-4o no lo expone públicamente, su inclusión exclusiva en Gemini 2.5 Flash introduciría una variable de control asimétrica que comprometería la validez comparativa. Las cuatro configuraciones se resumen en la Tabla 4.2.

Tabla 4.2: Configuraciones de parámetros de generación empleadas en el *baseline*.

Config	Temperatura	top_p	Descripción
C1	0.0	1.0	Determinista: máximo rigor, mínima creatividad
C2	0.3	0.9	Conservadora: aleatoriedad baja, respuestas estables
C3	0.7	0.8	Estándar: temperatura de referencia habitual, equilibrio entre variedad expresiva y precisión factual
C4	1.0	0.7	Temperatura máxima: escenario de mayor riesgo de imprecisión

La configuración C1 fuerza el comportamiento más determinista, con temperatura 0.0 el modelo selecciona en cada paso el token más probable, sin introducir aleatoriedad, y debería tender a reconocer su desconocimiento antes que elaborar una respuesta incierta. C2 introduce una aleatoriedad moderada (temperatura 0.3) manteniendo el foco en los tokens más probables, con `top_p` a 0.9 que acota el vocabulario candidato, representa el punto de entrada conservador en el rango estocástico. C3 reproduce la temperatura de uso general (0.7) combinada con un `top_p` de 0.8 más restrictivo que C2, equilibrando variedad expresiva y precisión factual. C4 aplica la temperatura máxima (1.0) con el `top_p` más restrictivo de todas las configuraciones (0.7), el incremento global de aleatoriedad queda así parcialmente compensado por la reducción del número

de tokens candidatos, creando el escenario de mayor riesgo de alucinación del estudio y sirviendo como cota superior del *baseline*.

El *pipeline* de inferencia es idéntico para ambos modelos estudiados. Cada llamada a la API incluye un *system prompt* en inglés A.4 que instruye al modelo para que responda de forma concisa y factual, exprese su incertidumbre en lugar de generar información no fundamentada, y no elabore contenido que no esté respaldado por su conocimiento. En el subconjunto *single-turn*, cada pregunta del *golden dataset* se envía como un único mensaje de usuario precedido del *system prompt*, sin historial conversacional previo. En el subconjunto *multi-turn*, los mensajes se acumulan de forma progresiva en el formato estándar de roles de la API (roles **system**, **user** y **assistant**), cada llamada incluye el historial completo de la conversación hasta ese punto, formado por todas las preguntas anteriores del empleado como mensajes de usuario y todas las respuestas generadas por el propio modelo en turnos anteriores como mensajes del asistente (no las respuestas de referencia del *golden dataset*), al que se añade la pregunta del turno actual como nuevo mensaje de usuario. De este modo el modelo dispone en todo momento del hilo completo de la conversación real tal y como él mismo la ha producido. Para garantizar la reproducibilidad de los resultados, se fijaron semillas aleatorias explícitas al inicio de la ejecución. El experimento evaluó 133 preguntas del subconjunto *single-turn* y las 17 conversaciones del subconjunto *multi-turn*, para cada uno de los dos modelos y cada una de las cuatro configuraciones.

El conjunto de métricas evaluado en el *baseline* se restringe a aquellas que no dependen de ningún componente de recuperación. Las métricas Faithfulness, Context-Precision y ContextRecall, descritas en el Capítulo 3, requieren contextos recuperados por un *retriever*, al no existir tal componente en el *baseline*, quedan reservadas para la fase de evaluación del sistema RAG. Las seis métricas calculadas sobre cada respuesta generada son FactualCorrectness en modo F1, que cuantifica la corrección factual de la respuesta generada respecto a la de referencia, AnswerRelevancy, que mide la pertinencia de la respuesta a la pregunta, SemanticSimilarity, que calcula la proximidad semántica entre la respuesta generada y la de referencia y tres métricas léxicas, BleuScore, RougeScore en modo F-measure y ChrfScore, que cuantifican el solapamiento léxico y de caracteres entre respuesta y referencia con independencia del modelo juez. Para el subconjunto *multi-turn* se calculan además dos métricas holísticas a nivel de conversación completa, ya descritas en el Capítulo 3, AspectCritic, métrica binaria que evalúa la ausencia de alucinación en el conjunto de la conversación, y SimpleCriteriaScore, que mide la consistencia conversacional en escala de 1 a 5.

4.4. Construcción del sistema RAG

La comparación *baseline* cuantifica hasta qué punto los modelos son capaces de responder sobre la documentación de AMC Global apoyándose exclusivamente en su conocimiento paramétrico, sin acceso a ningún documento. El sistema RAG se cons-

truye como complemento directo a esa condición, al incorporar un componente de recuperación que localiza fragmentos relevantes del corpus en tiempo de inferencia y los proporciona al LLM como contexto adicional en el *prompt*, el objetivo es reducir la dependencia del modelo respecto a su conocimiento previo y mejorar la corrección factual y la relevancia de las respuestas. La construcción del sistema se articula en dos fases, la primera de preparación del corpus, que comprende la segmentación en fragmentos del texto limpio obtenido en la fase de extracción (Sección 4.1), la generación de representaciones vectoriales para esos fragmentos y la construcción del índice de búsqueda, y la segunda del *pipeline* de inferencia, que orquesta la recuperación de contexto y la generación de respuestas en tiempo real.

4.4.1. Preparación del corpus: *chunking*, indexación y representación semántica

La segmentación del corpus textual en fragmentos indexables se realizó mediante *chunking* semántico, estrategia que, a diferencia del *chunking* por tamaño fijo, determina los puntos de corte en función del contenido y no por imposición de una longitud prefijada, situándolos en las fronteras temáticas naturales del texto, lo que además permite prescindir del solapamiento entre fragmentos. Este enfoque favorece a que cada fragmento indexado represente una unidad de significado completa, reduciendo la probabilidad de que el contexto semántico relevante para una respuesta quede partido entre *chunks* distintos y no pueda ser recuperado de forma íntegra por el *retriever*. El proceso analiza el documento frase a frase calculando la similitud en el espacio de *embeddings* entre cada par de frases consecutivas, cuando esa similitud cae por debajo de un umbral estadístico, el sistema infiere que se ha producido un cambio temático e introduce un corte en ese punto. El umbral de corte se fijó en el percentil 85 de la distribución de similitudes del documento, lo que implica que, de todos los pares de frases consecutivas, solo el 15% más distinto genera una ruptura de segmento. La elección de un umbral basado en percentiles, frente a alternativas como la desviación estándar o el rango intercuartílico, permite que el criterio de corte se adapte a la distribución de similitudes particular de cada documento en lugar de depender de un valor absoluto. El percentil 85 se fijó de forma empírica para evitar una granularidad excesiva, en línea con la importancia que la literatura atribuye a la granularidad de la segmentación para la calidad del *retrieval* [21]. La implementación se realizó mediante la clase `SemanticChunker` del *framework* `LangChain`. El modelo de *embedding* empleado en esta fase para la detección de los puntos de ruptura es `text-embedding-3-small` de OpenAI, cuya función se limita aquí a identificar transiciones temáticas entre frases, sus vectores no se almacenan ni participan en el *retrieval*, es decir, no se emplean para representar semánticamente a los *chunks*, sino únicamente para fragmentar el texto. El tratamiento de las cabeceras y pies de página no corresponde a esta fase, sino que quedó resuelto durante la extracción (Sección 4.1), de modo que el *chunking* opera sobre texto ya limpio y homogéneo. Las tablas, transcritas a texto plano durante esa misma

fase, se procesan como cualquier otro contenido textual, por lo que su permanencia en un único *chunk* o su reparto entre varios queda determinado por el propio criterio de corte semántico.

Tras el *chunking*, se aplicó un filtrado para descartar fragmentos sin valor semántico producidos como artefactos del proceso de extracción desde PDF. Entre ellos figuran líneas compuestas exclusivamente por puntos dispersos, números de sección huérfanos sin texto asociado, o referencias de página aisladas. Su presencia en el índice vectorial introduciría ruido en el *retrieval*, dado que podrían ser recuperados ante consultas con las que comparten similitud superficial sin aportar información útil al modelo generador. Tras aplicar el *chunking* semántico con umbral al percentil 85 y el filtrado posterior sobre los fragmentos conseguidos, se obtuvieron 1.212 *chunks* aptos para su indexación.

El *chunking* semántico produjo 1.212 *chunks* sobre los 12 documentos del corpus, con una media de 92,9 palabras por *chunk*, una granularidad que refleja la naturaleza estructurada de la documentación corporativa, como se recoge en la Tabla 4.3.

Tabla 4.3: Estadísticas del corpus tras el procesamiento.

Métrica	Valor
Número de documentos	12
Número total de <i>chunks</i>	1.212
Media de <i>chunks</i> por documento	101,0
Media de palabras por <i>chunk</i>	92,9
Palabras totales	112.573

Los *embeddings* definitivos que representan a los *chunks*, es decir, los vectores que se almacenan en la base de datos vectorial y sobre los que opera la búsqueda por similitud durante el *retrieval*, se generaron con el modelo Qwen3-Embedding-0.6B [2]. La elección de este modelo frente a `text-embedding-3-large` de OpenAI, la alternativa comercial de mayor rendimiento de ese proveedor, se fundamenta en los resultados del *benchmark* MTEB Multilingüe [1], estándar de referencia en la comunidad científica para la evaluación comparativa de modelos de *embedding* en múltiples lenguas y tareas. La Tabla 4.4 recoge una selección representativa de los resultados del *benchmark* para los modelos más relevantes de cada categoría. A pesar de contar con tan solo 0,6 miles de millones de parámetros, el modelo Qwen3-Embedding-0.6B supera a `text-embedding-3-large` en todas las métricas relevantes, obtiene una media global de 64,33 frente a 58,93 y un rendimiento de 64,64 frente a 59,27 en la tarea de recuperación (*Retrieval*), que es la capacidad que el componente de *retrieval* del sistema RAG requiere directamente. Zhang et al. [2] atribuyen este rendimiento superior a un proceso de entrenamiento multitapa que combina preentrenamiento débilmente supervisado sobre datos sinté-

ticos generados por el propio modelo base Qwen3, ajuste fino supervisado con datos de alta calidad, y técnicas de fusión de modelos. Dado que el corpus documental de AMC Global está íntegramente en español, el rendimiento superior de este modelo en el *benchmark* multilingüe resulta especialmente pertinente para garantizar la calidad del *retrieval*.

Tabla 4.4: Selección de resultados en el *benchmark* MTEB Multilingüe. Puntuaciones recuperadas del *leaderboard* MTEB en junio de 2025 [1]. Tabla adaptada de Zhang et al. [2].

Modelo	Parámetros	Media	Recuperación
<i>Modelos de código abierto de referencia</i>			
BGE-M3	0,6B	59,56	54,60
multilingual-e5-large-instruct	0,6B	63,22	57,12
gte-Qwen2-7b-Instruct	7B	62,51	60,08
<i>APIs comerciales</i>			
text-embedding-3-large (OpenAI)	—	58,93	59,27
Cohere-embed-multilingual-v3.0	—	61,12	59,16
Gemini Embedding	—	68,37	67,71
<i>Familia Qwen3 Embedding [2]</i>			
Qwen3-Embedding-0.6B	0,6B	64,33	64,64
Qwen3-Embedding-4B	4B	69,45	69,60
Qwen3-Embedding-8B	8B	70,58	70,88

La Tabla 4.5 resume las diferencias arquitectónicas más relevantes entre ambos modelos. El mismo modelo **Qwen3-Embedding-0.6B** se empleó tanto para la generación de los vectores de los *chunks* durante la indexación como para la codificación de las consultas en tiempo de inferencia, lo que responde a una necesidad metodológica, la búsqueda por similitud vectorial es semánticamente válida únicamente si los vectores comparados pertenecen al mismo espacio vectorial.

Tabla 4.5: Comparativa de características arquitectónicas entre **Qwen3-Embedding-0.6B** y **text-embedding-3-large**.

Característica	Qwen3-Embedding-0.6B	text-embedding-3-large
Dimensión del <i>embedding</i>	1.024	3.072
Contexto máximo de entrada (<i>tokens</i>)	32.768	8.191

El índice vectorial se construyó en Azure AI Search, una base de datos vectorial ges-

tionada en la nube que soporta búsqueda híbrida sobre un mismo índice, combinando búsqueda léxica mediante BM25 y búsqueda vectorial densa de forma simultánea. El algoritmo de indexación vectorial empleado es HNSW (*Hierarchical Navigable Small World*) [33], que construye un grafo multicapa en el que cada nodo representa un *chunk* del corpus y las aristas conectan los nodos más próximos en el espacio vectorial. La estructura jerárquica del grafo distingue capas superiores con pocas conexiones de largo alcance, que permiten navegar rápidamente entre regiones del espacio vectorial hasta localizar la zona de interés, de capas inferiores con conexiones densas de corto alcance, que garantizan una exploración precisa del vecindario local, ante una consulta, el algoritmo desciende capa a capa hasta localizar el conjunto de candidatos más próximos sin necesidad de comparar el vector de la consulta con todos los elementos del índice. Como métrica de comparación vectorial se empleó la similitud coseno, estándar en los modelos de *embedding* basados en transformers. Definimos los siguientes campos en el esquema del índice, el identificador del *chunk* como clave primaria derivada del *hash* SHA-256 de su texto, el campo de texto indexado con el analizador morfológico en español de Microsoft para la búsqueda BM25, el vector de 1.024 dimensiones para la búsqueda semántica, y siete campos de metadatos filtrables que registran el nombre del documento, el nombre original del fichero fuente, el número de páginas, la fecha de procesado, la estrategia de *chunking* empleada, la posición ordinal del *chunk* dentro del documento y el número total de *chunks* del documento.

4.4.2. Pipeline RAG

El *pipeline* RAG orquesta, para cada pregunta del *golden dataset*, la recuperación de contexto relevante del índice y la generación de respuesta por parte del modelo de lenguaje. El sistema se articula en torno a tres componentes, el *retriever* con búsqueda híbrida en dos etapas, un módulo de *reranking* y un modelo generador. La elección del modelo generador queda diferida al Capítulo 5, donde se justifica a partir de los resultados empíricos obtenidos en el *baseline*.

La recuperación de contexto se realiza en dos etapas complementarias. En la primera, el *retriever* lanza sobre Azure AI Search una búsqueda híbrida que combina simultáneamente la búsqueda vectorial densa mediante HNSW y la búsqueda léxica mediante BM25. Los resultados de ambas búsquedas se fusionan aplicando *Reciprocal Rank Fusion* (RRF), un algoritmo de combinación de rankings que asigna a cada candidato una puntuación proporcional al inverso de su posición en cada lista de resultados parcial (lista de búsqueda semántica y léxica), de modo que los fragmentos bien posicionados en ambas búsquedas reciben una puntuación combinada superior sin necesidad de normalizar las puntuaciones de cada modalidad ($RRF(d) = \sum_{r \in R} \frac{1}{60 + \text{rank}_r(d)}$, donde $\text{rank}_r(d)$ es la posición del candidato d en la lista parcial r). La búsqueda híbrida responde a una motivación metodológica directa, la búsqueda vectorial captura similitud semántica y resulta robusta ante variaciones parafrásticas de la consulta, mientras que BM25 es sensible a la coincidencia léxica exacta y resulta especialmente útil para re-

cuperar fragmentos que contienen términos técnicos o nombres propios del corpus de AMC Global. La combinación de ambas señales es complementaria, un fragmento que puntúa alto en una modalidad puede quedar rezagado en la otra, de modo que su fusión mediante RRF reduce la probabilidad de que un fragmento relevante quede fuera del conjunto de candidatos por resultar semánticamente próximo, pero léxicamente distinto, o viceversa. Esta primera etapa recupera los 20 candidatos de mayor puntuación RRF del índice.

En la segunda etapa, los 20 *chunks* candidatos son reordenados por un *cross-encoder* de *reranking*, el modelo `ms-marco-MiniLM-L-6-v2` [34], entrenado sobre MS MARCO, el corpus de referencia en tareas de reordenación de resultados de búsqueda publicado por Microsoft. La elección de este *cross-encoder* responde a su amplia adopción como modelo de reordenación de referencia y, sobre todo, a su reducido tamaño y baja latencia, que lo hacen idóneo para reordenar el conjunto de 20 candidatos sin penalizar el tiempo de inferencia. Conviene reconocer, no obstante, que MS MARCO, el corpus sobre el que se entrenó, es un corpus en inglés, mientras que el de AMC Global está en español, por lo que su capacidad de reordenación sobre este idioma es presumiblemente inferior a la de un *reranker* multilingüe entrenado sobre recursos como mMARCO, alternativa que se plantea como vía de mejora futura (Sección 6.2). A diferencia del modelo de *embedding*, que representa la consulta y los fragmentos en vectores independientes cuya similitud se calcula a posteriori, el *cross-encoder* recibe la consulta y cada fragmento candidato concatenados como una única entrada, lo que le permite capturar interacciones léxicas y semánticas entre ambos textos que la representación vectorial independiente no detecta, a costa de una mayor latencia que hace inviable su uso sobre el índice completo, pero asumible sobre los 20 candidatos preseleccionados. Esta arquitectura en dos etapas, búsqueda por *embeddings* para filtrado masivo y *cross-encoder* para reordenación precisa sobre un conjunto reducido, es el diseño de recuperación de referencia en la literatura sobre RAG y búsqueda de información densa. El módulo de *reranking* retiene los 5 fragmentos de mayor puntuación, que son los que finalmente se le proporcionan al modelo generador como contexto.

En cuanto al historial conversacional que se le proporciona al modelo generador en el subconjunto *multi-turn*, se genera de la misma forma que en el *baseline*. Esta decisión de diseño responde a mantener el mismo esquema de historial en ambas condiciones, donde se le proporcionan los turnos anteriores como mensajes separados con roles **user** y **assistant**, con las respuestas reales generadas por el propio sistema RAG en turnos previos, no las respuestas de referencia del *golden dataset*, para que el experimento capture los efectos de propagación de posibles errores entre turnos propios de una interacción real. El *retriever* opera exclusivamente sobre la pregunta del turno actual para recuperar contexto, sin incorporar los turnos anteriores de la conversación. El historial de la conversación se gestiona por el modelo generador, decidiendo por sí mismo cuándo ha de usarlo y en qué medida en combinación con el contexto recuperado, para responder a las preguntas.

El modelo generador recibe en cada llamada un *system prompt* en inglés, recogido

en el Anexo A.5, que instruye al modelo para que responda de forma factual a partir del contexto proporcionado y se abstenga de forma explícita cuando dicho contexto no contenga información suficiente para responder. La temperatura de generación se fijó en 0.0 para garantizar el determinismo de las respuestas, condición necesaria para que las métricas de evaluación sean estables entre ejecuciones del *pipeline*.

Respecto a las métricas de evaluación, el *pipeline* RAG habilita el cálculo del conjunto completo de métricas RAGAS descrito en el Capítulo 3, incluyendo las cuatro métricas que requieren contextos recuperados y que quedaron reservadas en el *baseline* por ausencia de *retriever*, como son la Faithfulness, que cuantifica la proporción de afirmaciones de la respuesta generada que pueden verificarse en los fragmentos de contexto recuperados, ContextRecall, que evalúa en qué medida los fragmentos recuperados cubren la información necesaria para generar la respuesta de referencia, el ContextPrecision, que mide la fracción de fragmentos recuperados genuinamente relevantes ponderando además su posición en el ranking y la Precision@K, calculada de forma manual mediante similitud coseno entre los *embeddings* de los fragmentos recuperados y los contextos de referencia del *golden dataset*.




Figura 4.2: Diagrama del *pipeline* RAG implementado.

5. Evaluación: resultados y discusión

Este capítulo presenta los resultados de las dos fases experimentales del trabajo y su discusión. La primera, descrita en la Sección 5.1, analiza el comportamiento de los modelos en la comparación *baseline*, evaluando hasta qué punto son capaces de responder sobre la documentación de AMC Global apoyándose exclusivamente en su conocimiento paramétrico. La segunda, recogida en la Sección 5.2, evalúa el sistema RAG construido y cuantifica la mejora que el acceso a contexto documental introduce sobre los resultados del *baseline*.

5.1. Evaluación de la comparación *baseline*

Los resultados de la evaluación *baseline* revelan que ambos modelos exhiben alucinación sistemática sobre el corpus de AMC Global, los valores de FactualCorrectness no superan 0.25 en ninguna combinación de modelo y configuración de parámetros, situándose muy por debajo del umbral de 0.5 adoptado como referencia interpretativa en este estudio. Este umbral, equivalente a exigir que al menos la mitad de los hechos contenidos en la respuesta sean correctos, es deliberadamente permisivo, en un sistema de producción desplegado sobre documentación interna corporativa, los estándares de corrección factual exigibles serían notablemente más estrictos.

5.1.1. Efecto de los parámetros de generación

Comportamiento ante las configuraciones

Tabla 5.1: Métricas RAGAS de generación (FactualCorrectness, AnswerRelevancy, SemanticSimilarity) por modelo y configuración de parámetros en el subconjunto *single-turn*.

Modelo	C1			C2			C3			C4		
	FC	AR	SS	FC	AR	SS	FC	AR	SS	FC	AR	SS
Gemini 2.5 Flash	0.222	0.525	0.744	0.243	0.511	0.748	0.243	0.509	0.749	0.232	0.510	0.744
GPT-4o	0.185	0.422	0.747	0.181	0.402	0.746	0.181	0.408	0.747	0.159	0.410	0.748

Las cuatro configuraciones evaluadas varían temperatura y `top_p` de forma progresiva desde la configuración determinista (C1: T=0.0, `top_p`=1.0) hasta la de mayor

aleatoriedad (C4: $T=1.0$, $\text{top_p}=0.7$), tal y como se resume en la Tabla 4.2. La conclusión es robusta bajo cualquier configuración de parámetros, ambos modelos obtienen valores bajos de corrección factual en todos los casos, lo que indica que variar temperatura y top_p dentro del rango estudiado no constituye una palanca efectiva para reducir alucinaciones cuando el modelo carece de acceso al corpus relevante.

Si bien existen pequeñas diferencias cualitativas entre los modelos respecto a su respuesta ante la variación de estos parámetros. Desplazarse hacia configuraciones más creativas produce efectos distintos en cada uno. En GPT-4o supone una ligera degradación sostenida y monótona entre C1 y C4, cada incremento de temperatura reduce marginalmente la corrección factual de sus respuestas, siendo C4 su peor resultado. En Gemini, en cambio, la variación de configuración no produce ni mejora ni degradación apreciable, el modelo se comporta de forma prácticamente equivalente en todas las configuraciones, mejora ligeramente al pasar de C1 a C2, se estabiliza en C3 y recupera valores similares a C1 en C4. GPT-4o es, por tanto, algo más sensible a la temperatura que Gemini en este dominio, aunque la magnitud del efecto es marginal en términos absolutos para ambos modelos.

Este resultado es esperable y tiene una explicación estructural doble. Por un lado, GPT-4o y Gemini 2.5 Flash son modelos comerciales con extenso entrenamiento por refuerzo a partir de retroalimentación humana, cuyos mecanismos internos de calibración amortizan el efecto de cambios moderados en los parámetros de muestreo, a diferencia de modelos base sin instrucción, no colapsan hacia salidas caóticas con temperatura alta ni se vuelven drásticamente más precisos con temperatura baja. Por otro lado, el experimento priorizó la comparabilidad entre configuraciones sobre la maximización del contraste, empleando un rango de variación contenido en el que top_p compensa parcialmente el efecto de la variación de temperatura. Ambos factores combinados explican la estabilidad observada y constituyen una limitación reconocida del estudio, que investigaciones futuras podrían abordar con rangos más extremos o con modelos base sin instrucción.

Efecto de la configuración por tipo de pregunta




Figura 5.1: *Interaction plot* de corrección factual por tipo de pregunta y configuración de parámetros (subconjunto *single-turn*).

El *interaction plot* de la Figura 5.1 confirma que la configuración de parámetros no afecta de forma homogénea a todos los tipos de pregunta *single-turn*. En ambos modelos, *out_of_domain* obtiene consistentemente la corrección factual más alta y *factual_trap* es la categoría más sensible al incremento de temperatura.

Las preguntas *out_of_domain* obtienen la corrección factual más alta porque la respuesta correcta para este tipo de consultas es precisamente la abstención informativa. Al tratarse de preguntas cuya respuesta no existe en el corpus de AMC Global, cuando el modelo responde con una formulación de desconocimiento («No dispongo de información suficiente para responder»), esta presenta una similitud elevada con la respuesta de abstención de referencia del *golden dataset*. En esta categoría, la abstención equivale a una respuesta correcta, lo que no ocurre en ninguna otra categoría del conjunto de evaluación, de ahí que la corrección factual sea mayor.

En Gemini, el comportamiento de *factual_trap* es especialmente ilustrativo, parte como la segunda categoría mejor resuelta en C1 y converge con *factual_true* en C4, evidenciando que el incremento de temperatura erosiona específicamente la capacidad del modelo para detectar premisas falsas. GPT-4o muestra el mismo patrón jerárquico entre categorías pero con menor dispersión, efecto atribuible a su mayor tendencia a la abstención ante preguntas cuya respuesta desconoce, como se analiza en la Sección 5.1.2.

En conjunto, aunque las diferencias entre categorías son modestas en términos absolutos, los resultados demuestran que el desempeño de los modelos según el tipo de

pregunta puede variar en función de la configuración de parámetros de generación empleada.




Figura 5.2: Evolución de *FactualCorrectness* y *AnswerRelevancy* a lo largo de las cuatro configuraciones de parámetros para ambos modelos (subconjunto *single-turn*).




Figura 5.3: Evolución de *SemanticSimilarity* y BLEU a lo largo de las cuatro configuraciones de parámetros para ambos modelos (subconjunto *single-turn*).




Figura 5.4: Evolución de ROUGE y ChrF a lo largo de las cuatro configuraciones de parámetros para ambos modelos (subconjunto *single-turn*).

Las Figuras 5.2, 5.3 y 5.4 muestran la evolución de todas las métricas evaluadas en el *baseline* a lo largo de las cuatro configuraciones. La característica más llamativa del conjunto es que ninguna línea presenta una pendiente pronunciada, todas son prácticamente horizontales, confirmando visualmente que la temperatura no es una variable con gran repercusión en este experimento. La única trayectoria con pendiente visible es la de FactualCorrectness, Gemini se mantiene más estable ante la variación de los parámetros, mientras que GPT-4o describe una ligera tendencia decreciente. Aun así, ninguna de las dos trayectorias representa una variación sustancial en términos absolutos.

AnswerRelevancy (relevancia de la respuesta) es la métrica que mejor ilustra la diferencia cualitativa entre modelos, las dos líneas aparecen claramente separadas en todo el eje horizontal, con Gemini estable en torno a 0.51 de media y GPT-4o en torno a 0.41 de media, sin que ninguna configuración reduzca esa brecha. Una línea más alta y plana frente a una línea baja y plana, ambas sin tendencia, reflejan dos estrategias de respuesta estructuralmente distintas que la temperatura no modifica. Este aspecto se analiza en profundidad en la Sección 5.1.2.

La conclusión central de este bloque de análisis es que el factor determinante del fallo no es la configuración de los parámetros de generación sino la ausencia de acceso al corpus de AMC Global para responder de forma adecuada, cuyo efecto sobre la corrección factual se cuantifica en la Sección 5.2.

5.1.2. Comportamiento diferencial de los modelos

Disociación entre similitud semántica y corrección factual




Figura 5.5: Heatmaps de corrección factual (*FactualCorrectness*) y similitud semántica (*SemanticSimilarity*) por modelo y configuración de parámetros.




Figura 5.6: Heatmaps de similitud semántica (*SemanticSimilarity*) y BLEU por modelo y configuración de parámetros.

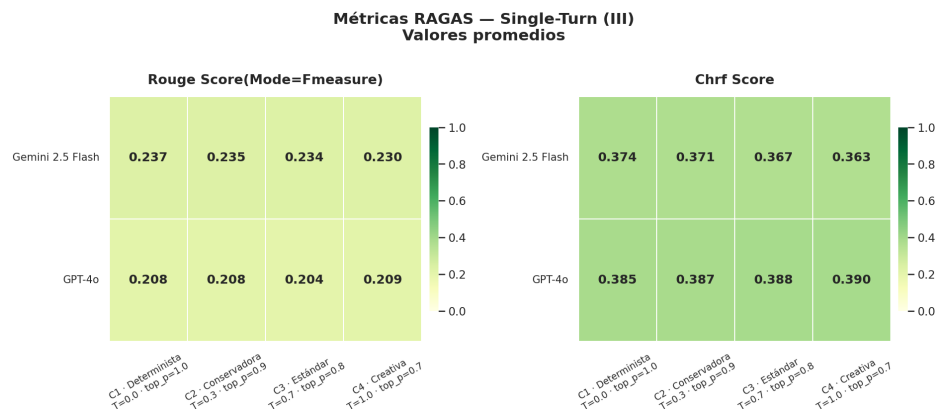


Figura 5.7: Heatmaps de ROUGE y ChrF por modelo y configuración de parámetros.

Ambos modelos mantienen una similitud semántica media en torno a 0.74–0.75 a lo largo de todas las configuraciones, mientras su corrección factual no supera 0.243 en ningún caso. Esta disociación es robusta e independiente de la temperatura, lo que descarta que sea un artefacto de una configuración concreta.

Lo que estos valores revelan es que los modelos generan respuestas formalmente coherentes y semánticamente próximas al dominio de respuesta corporativo de AMC Global que resultan, sin embargo, factualmente incorrectas. Este tipo de alucinación es especialmente peligroso porque la estructura y coherencia aparente de la respuesta puede inducir al lector a asumir que es correcta, sin que exista ninguna señal superficial de error. Es precisamente por esta razón que las principales compañías de inteligencia artificial advierten explícitamente a sus usuarios de que los modelos pueden cometer errores y que sus respuestas deben verificarse.

El hecho de que la similitud semántica sea tan similar en ambos modelos, junto con valores también muy próximos en las métricas léxicas clásicas (ROUGE, ChrF y BLEU), responde a una misma causa estructural, ambos modelos fueron preentrenados sobre corpus masivos similares y comparten el mismo espacio lingüístico del español corporativo. Independientemente de su estrategia de respuesta, ambos conocen cómo se escribe sobre recursos humanos, procedimientos empresariales y políticas corporativas en español, y emplean el mismo vocabulario, las mismas estructuras sintácticas y el mismo registro formal. Lo que no conocen son los datos específicos de AMC Global.

Relevancia de la respuesta y estrategias de fallo




Figura 5.8: Distribución de *AnswerRelevancy* para Gemini 2.5 Flash (izquierda) y GPT-4o (derecha) en el subconjunto *single-turn*.

La métrica *AnswerRelevancy* no mide si la respuesta es correcta, sino si aborda la pregunta formulada. Su mecanismo interno consiste en generar preguntas sintéticas a partir de la respuesta del modelo y comparar su similitud con la pregunta original, una puntuación alta indica que el modelo produjo una respuesta que trata sobre el tema preguntado, con independencia de si lo que afirma es verdad.

Los valores de esta métrica revelan que los dos modelos fallan, aunque tienden a hacerlo de una forma cualitativamente diferente. GPT-4o presenta una mediana de *AnswerRelevancy* de 0.000 en todas las configuraciones, lo que indica que en la mitad de los casos el modelo no produce una respuesta que el mecanismo pueda relacionar con la pregunta formulada. Esto apunta directamente a que su estrategia es más propensa a la abstención, ante preguntas de dominio desconocido, el modelo declina responder. La puntuación de 0.000 encaja con precisión con este comportamiento, puesto que el mecanismo de *AnswerRelevancy* genera preguntas sintéticas a partir únicamente del texto de la respuesta del modelo, si esa respuesta es una formulación de desconocimiento, las preguntas que puedan inferirse de ella difícilmente guardarán similitud con la pregunta original, de modo que la puntuación colapsa a cero. Este comportamiento es epistémicamente honesto, pero funcionalmente inutilizable en un sistema en producción. Gemini, en cambio, mantiene una mediana en torno a 0.82 en todas las configuraciones, lo que significa que en más de la mitad de los casos genera una respuesta que parece pertinente al tema preguntado. Combinado con una corrección factual

media inferior a 0.25, el diagnóstico es claro, Gemini responde sobre el tema correcto, pero con contenido inventado, construyendo respuestas plausibles y aparentemente fundamentadas que resultan factualmente incorrectas.

En consecuencia, ambos modelos fallan de forma masiva en términos de corrección factual, pero la naturaleza del fallo es cualitativamente distinta. Gemini falla por acción, genera respuestas elaboradas, semánticamente plausibles y factualmente incorrectas. GPT-4o falla por omisión, declina responder en buena parte de los casos, produciendo respuestas que son funcionalmente inutilizables en producción aunque técnicamente honestas. Ninguno de los dos comportamientos es aceptable en un sistema corporativo, pero representan riesgos distintos, el fallo de Gemini es más peligroso porque el usuario recibe información incorrecta presentada con aparente confianza, mientras que el de GPT-4o produce una experiencia de usuario degradada al no proporcionar respuesta útil. Conviene matizar que esto no significa que GPT-4o se abstenga siempre, sino que recurre a la abstención con mucha más frecuencia que Gemini, cuando sí responde, al igual que su competidor, lo hace apoyándose en su conocimiento paramétrico, produciendo respuestas que suenan convincentes pero resultan factualmente incorrectas, en línea con la disociación entre similitud semántica y corrección factual analizada en la Sección 5.1.2. Sin acceso al corpus documental de AMC Global, cualquier respuesta correcta solo puede atribuirse a coincidencia con el conocimiento paramétrico del modelo, que no incluye información interna de la empresa.

Métricas léxicas complementarias

Las métricas léxicas clásicas presentan valores bajos y estables en ambos modelos y en todas las configuraciones. Su estabilidad es en sí misma un resultado, descarta que el aumento de temperatura produzca respuestas léxicamente más dispersas o más alejadas del *ground truth* en términos superficiales. El efecto de la configuración no opera sobre la forma de las respuestas sino, en todo caso, sobre su corrección factual.

Entre las tres métricas, ChrF obtiene valores consistentemente superiores a BLEU (ChrF ronda 0.36–0.39 frente al 0.12–0.13 de BLEU), comportamiento esperado y razón principal de su inclusión en el estudio. Al operar a nivel de carácter en lugar de palabra completa, ChrF es más permisivo con las variaciones morfológicas del español (conjugaciones, géneros, plurales) y captura coincidencias parciales que BLEU penaliza como errores totales.

No obstante, la utilidad analítica de estas métricas en el contexto del *baseline* es estructuralmente limitada, miden coincidencia léxica con el *ground truth*, pero los modelos no tienen acceso al corpus de AMC Global, por lo que cualquier coincidencia con el texto de referencia es circunstancial. Incluso con acceso al corpus, un modelo puede reformular una respuesta correcta con un orden de palabras distinto al de la referencia y obtener una puntuación BLEU o ChrF baja pese a ser factualmente correcta. Esta limitación estructural justifica su tratamiento como métricas complementarias en este estudio.




Figura 5.9: Diagrama de radar con el perfil de métricas de evaluación de ambos modelos en el subconjunto *single-turn*.




Figura 5.10: Corrección factual media por categoría de pregunta para ambos modelos (subconjunto *single-turn*).

5.1.3. Evaluación conversacional (*multi-turn*)

Métricas de generación y propagación del error




Figura 5.11: Heatmaps de corrección factual (*FactualCorrectness*) y similitud semántica (*SemanticSimilarity*) por modelo y configuración de parámetros (subconjunto *multi-turn* Enfoque A).




Figura 5.12: *Heatmaps* de BLEU, ROUGE y ChrF por modelo y configuración de parámetros (subconjunto *multi-turn* Enfoque A).

La evaluación *multi-turn* en el Enfoque A aplica las mismas métricas de generación que el bloque *single-turn*, con una diferencia metodológica fundamental, incorpora en cada turno el historial conversacional, que se construye con las respuestas reales generadas por el modelo en turnos anteriores, no con las respuestas de referencia del *golden dataset*. Esta elección es la pertinente para estudiar la propagación de alucinaciones, si el modelo introduce información incorrecta en el turno 2, esa información forma parte del contexto con el que se evalúa el turno 3, capturando el efecto de amplificación del error a lo largo de la conversación. De ahí que el valor promedio global se vea afectado por la degradación conversacional. Al no contar con las respuestas de referencia en el historial sino con las respuestas reales del modelo, se propicia que las alucinaciones se propaguen con mayor rapidez entre turnos.

Un resultado especialmente llamativo es la inversión del desempeño entre modelos respecto al bloque *single-turn*. En *single-turn* Gemini superaba a GPT-4o en todas las configuraciones, pero en el Enfoque A esa ventaja desaparece y GPT-4o (0.166–0.187) supera a Gemini (0.135–0.176). Esta inversión tiene una explicación doble. Por un lado, Gemini, al generar respuestas más elaboradas en cada turno, introduce más material alucinado en el historial acumulado, que retroalimenta los turnos siguientes amplificando el error. GPT-4o, al abstenerse con más frecuencia, introduce menos contenido incorrecto en el historial y se degrada menos, la abstención, que en *single-turn* era una debilidad funcional, actúa en este Enfoque A como mecanismo de contención de la propagación de errores. Por otro lado, GPT-4o parte de una corrección factual inferior en *single-turn*, lo que reduce su margen de degradación posible, un modelo que ya fallaba con frecuencia en preguntas aisladas tiene menos recorrido a la baja en entornos conversacionales.




Figura 5.13: Degradación promedio de corrección factual entre el subconjunto *single-turn* y el *multi-turn* Enfoque A para cada modelo.

La Figura 5.13 cuantifica esta degradación de forma directa. La caída de corrección factual entre *single-turn* y *multi-turn* A es prácticamente nula en GPT-4o ($\Delta -0.004$), que como mencionamos anteriormente responde tanto a su menor margen de caída como a su tendencia a la abstención, que limita la contaminación del historial, frente a una caída más pronunciada de Gemini ($\Delta -0.085$), resultado directo de su propia estrategia de generación, al producir respuestas elaboradas con alucinación en cada turno, que retroalimentan los turnos sucesivos amplificando el error.

Un análisis detallado de la degradación por patrón conversacional se recoge en el Anexo E.




Figura 5.14: Evolución de *FactualCorrectness* y *SemanticSimilarity* a lo largo de las cuatro configuraciones de parámetros para ambos modelos (subconjunto *multi-turn* Enfoque A).




Figura 5.15: Evolución de BLEU, ROUGE y ChrF a lo largo de las cuatro configuraciones de parámetros para ambos modelos (subconjunto *multi-turn* Enfoque A).

La disociación entre similitud semántica y corrección factual persiste en el bloque *multi-turn* pero se estrecha ligeramente, lo que sugiere que el historial alucinado no solo introduce errores factuales sino que también aleja marginalmente las respuestas del espacio semántico de referencia. Las métricas léxicas muestran asimismo valores inferiores a los del bloque *single-turn*, coherentes con que las respuestas generadas sobre un historial contaminado se alejan progresivamente del *ground truth* también en términos superficiales.




Figura 5.16: Corrección factual media por patrón conversacional para ambos modelos (subconjunto *multi-turn* Enfoque A).

El análisis por patrón conversacional confirma que la estructura de la conversación determina el nivel de alucinación de forma algo más pronunciada que la configuración de parámetros. *Refinement*, que exige mantener restricciones acumuladas, produce los valores de corrección factual más bajos de todo el estudio en ambos modelos, mientras que *Follow-up*, apoyado en coherencia local, obtiene los más altos. GPT-4o supera ligeramente a Gemini en todos los patrones, diferencia explicada por la menor contaminación de su historial acumulado derivada de su mayor tendencia a la abstención.

Evaluación holística




Figura 5.17: Resultados de la evaluación holística (*multi-turn* Enfoque B) por patrón conversacional: tasa de respuestas libres de alucinaciones (*hallucination_free*) y puntuación de consistencia conversacional (*SimpleCriteriaScore*).

El Enfoque B evalúa cada conversación completa mediante un juez LLM que emite su juicio sin acceso a las respuestas de referencia del *golden dataset*, valorando únicamente si la conversación es factualmente convincente y si el modelo mantiene coherencia interna entre turnos.

Bajo esta evaluación, Gemini obtiene valores de *hallucination_free* superiores a GPT-4o en tres de los cuatro patrones: *Expansion* (0.875 vs. 0.562), *Refinement* (0.812 vs. 0.750) y *Follow-up* (0.812 vs. 0.688). Sin embargo, los resultados del Enfoque A muestran que la corrección factual real de Gemini es inferior a la de GPT-4o en todos los patrones. La explicación es clara, las respuestas elaboradas y fluidas de Gemini resultan convincentes para el juez, que no dispone de ninguna fuente de verdad externa con la que contrastarlas. Las alucinaciones de Gemini no son detectadas porque están bien formuladas, lo que constituye el escenario más peligroso en aplicaciones reales.

Ambos modelos obtienen puntuaciones de consistencia interna próximas al máximo en todos los patrones, con valores entre 4.55 y 5.0. Esto confirma que los modelos no se contradicen entre turnos, sino que confabulan de forma estable y coherente, lo que hace sus errores especialmente difíciles de detectar sin acceso a una fuente de verdad externa. La única excepción notable es GPT-4o en el patrón *Recollection* (3.850), donde la distancia temporal entre la instrucción inicial y los turnos de prueba genera alguna inconsistencia detectable.

El hallazgo más relevante del bloque *multi-turn* es que los modelos generan conversaciones que suenan coherentes y verídicas pero que contienen información incorrecta, y que un evaluador externo sin acceso a la documentación de AMC Global no es capaz de detectar las alucinaciones precisamente porque están bien formuladas. Este resultado demuestra que la única forma de garantizar la fiabilidad de las respuestas es anclarlas

a una fuente documental verificable, que es exactamente lo que proporciona el sistema RAG.

5.1.4. Tasa de alucinación global




Figura 5.18: Tasa de alucinación por modelo, configuración y modalidad de evaluación (*single-turn* y *multi-turn* Enfoque A). Un valor del 100 % indica que la totalidad de las respuestas se sitúa por debajo del umbral de corrección factual de 0.5.

La Figura 5.18 traduce los resultados de corrección factual al dato más directamente interpretable, el porcentaje de respuestas que no superan el umbral de alucinación establecido en 0.5. Ambos *heatmaps* son muy uniformes en rojo oscuro, lo que significa que en ninguna combinación de modelo, configuración o modalidad de evaluación la tasa de alucinación desciende del 79.6 %. En el peor caso alcanza el 96.6 %. El corpus de AMC Global es completamente opaco para ambos modelos sin acceso a contexto documental.

5.2. Evaluación del sistema RAG

Para la construcción del sistema RAG se seleccionó GPT-4o como modelo generador, por razones técnicas. Desde el punto de vista técnico, GPT-4o muestra una estrategia de respuesta más conservadora que Gemini 2.5 Flash, ante la ausencia de información suficiente, tiene una mayor tendencia a abstenerse en lugar de generar contenido inventado. Este comportamiento resulta más adecuado como base para un sistema RAG corporativo, donde es preferible que el modelo reconozca los límites de su conocimiento antes de incorporar contexto documental verificable. Un modelo que no inventa en ausencia de información ofrece mayores garantías de que, una vez disponga de contexto relevante, sus respuestas estarán efectivamente ancladas a dicho contexto y no a conocimiento paramétrico no verificado.

Las métricas de evaluación del sistema RAG incluyen, además de las empleadas en la comparación *baseline*, cuatro métricas específicas para la evaluación de sistemas de recuperación y generación, cuya definición y mecanismo de cálculo se recogen en el Capítulo 4: Faithfulness, ContextRecall, ContextPrecision y Precision@K.

5.2.1. Evaluación sobre preguntas de turno único

Análisis global de métricas

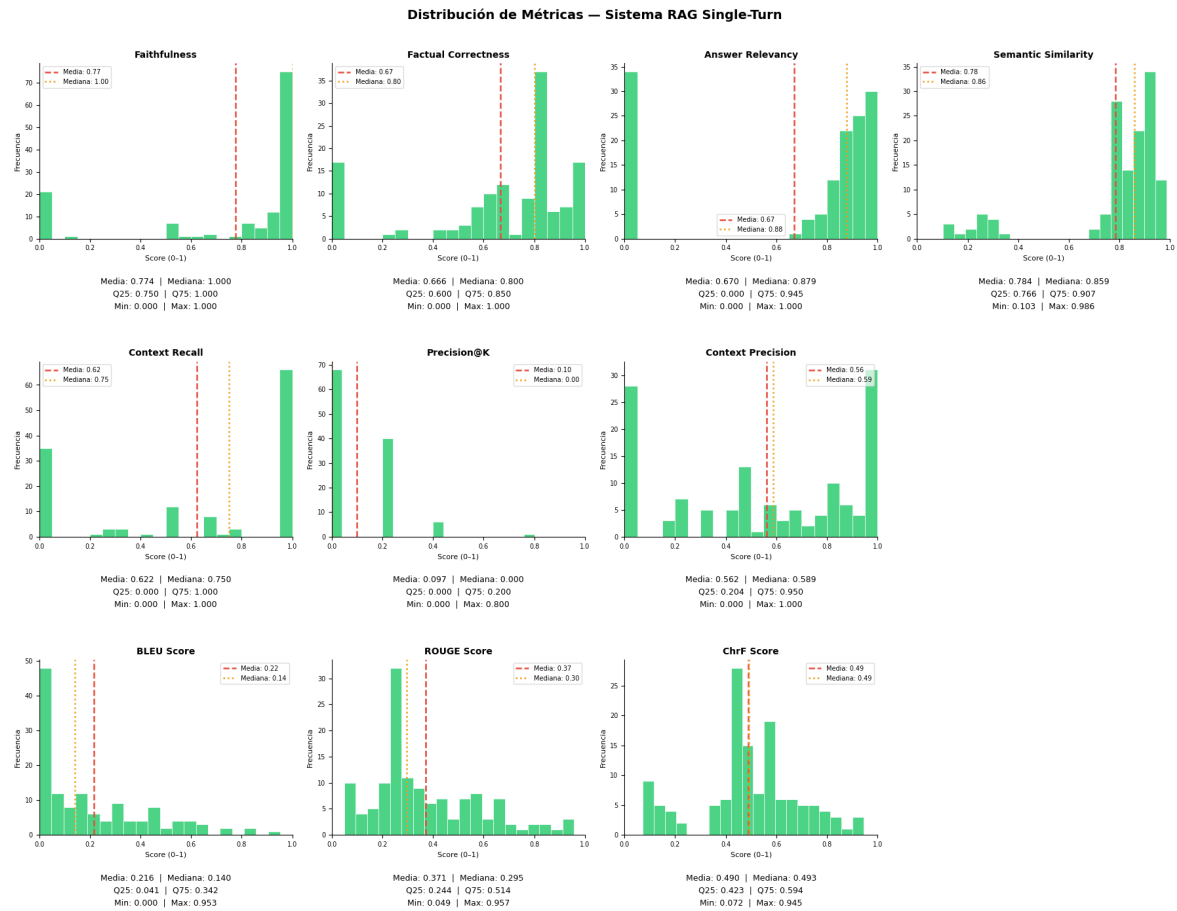


Figura 5.19: Distribución de métricas de generación del sistema RAG para el subconjunto *single-turn*.




Figura 5.20: Diagrama de radar con el perfil de métricas del sistema RAG para el subconjunto *single-turn*.

La FactualCorrectness, principal métrica analizada en la comparación *baseline* para determinar el grado de alucinación, asciende significativamente hasta una media de 0.66 y una mediana de 0.80, frente a valores inferiores a 0.25 en promedio y en mediana registrados en el *baseline* con independencia de la configuración de parámetros de generación empleada. Esta mejora evidencia una reducción sustancial de las alucinaciones respecto al sistema sin contexto documental.

La Faithfulness presenta una mediana de 1.0, lo que refleja una clara tendencia del modelo generador a apoyarse en el contexto recuperado para construir sus respuestas, en contraste con el comportamiento observado en el *baseline* donde el modelo respondía a partir de su conocimiento paramétrico. La brecha entre Faithfulness (mediana 1.0) y FactualCorrectness (mediana 0.80) indica que, si bien el modelo generador es fiel al contexto que recibe, este no siempre cubre con exactitud todo lo que la respuesta de referencia contempla.

Esta brecha tiene su explicación en las métricas de desempeño del retriever. La cobertura del retriever no es perfecta (ContextRecall media 0.622, ContextPrecision media 0.562), lo que significa que en ocasiones el modelo generador no recibe toda la información necesaria para construir una respuesta completa. Aunque el modelo generador se sustente en el contexto recuperado, cuando este contexto es incompleto o no es el más adecuado, la respuesta generada no puede cubrir todo lo que la referencia espera. Conviene matizar que estos fallos del retriever no representan el comportamiento predominante del sistema, sin embargo, su repercusión en la FactualCorrectness es elevada, puesto que el generador, por muy fiel que sea al contexto disponible, carece en esos casos de la información necesaria para construir una respuesta completa. Entre las causas estructurales de esta cobertura imperfecta cabe situar también la etapa de reordenación, por la limitación descrita en la Sección 4.4.2 sobre el *cross-encoder*, dado que el corpus sobre el que se entrenó estaba en inglés, lo que puede llevarle a relegar

de los cinco fragmentos finales algún candidato relevante, que la búsqueda híbrida sí había recuperado.

Cabe destacar también la mejora en la AnswerRelevancy. En el *baseline*, GPT-4o mostraba una tendencia pronunciada a abstenerse ante preguntas cuya respuesta desconocía, lo que se traducía en una mediana de 0.000 para esta métrica. Con el sistema RAG la mediana asciende a 0.88, lo que indica que el modelo, al disponer de contexto relevante, responde con mayor frecuencia y pertinencia a las preguntas planteadas.

La media de AnswerRelevancy (0.670) queda por debajo de la mediana debido a la influencia del subconjunto de preguntas *out_of_domain*, cuya respuesta correcta es la abstención. Cuando el modelo se abstiene correctamente, el juez LLM genera preguntas sintéticas a partir de esa respuesta que difícilmente coinciden con la pregunta original, penalizando artificialmente la métrica. Este mismo comportamiento se observa en la distribución de los valores de Faithfulness, donde existe un pico pronunciado en el valor 0, cuando el modelo se abstiene correctamente al no encontrar contexto suficiente, el juez LLM intenta extraer afirmaciones de esa respuesta de abstención y, al no encontrar ninguna respaldada por el contexto recuperado, asigna un valor de 0. Este comportamiento no debe confundirse con una alucinación, sino que es una consecuencia de aplicar una métrica diseñada para respuestas informativas a casos donde la abstención es la respuesta correcta. Para estas preguntas *out_of_domain*, la única métrica con sentido como indicador primario es la FactualCorrectness, que evalúa la corrección respecto a la respuesta de referencia con independencia del contexto recuperado. Por este motivo, la mediana resulta el estadístico más representativo del comportamiento real del sistema ante las preguntas que sí debe responder.

Dado que las preguntas *out_of_domain* introducen distorsiones en métricas como AnswerRelevancy y Faithfulness por las razones expuestas, se presenta en el Anexo F la distribución de las métricas de generación y recuperación excluyendo dicho subconjunto, con el objetivo de obtener una visión más representativa del comportamiento real del sistema.

Análisis de las métricas de recuperación

El análisis de las métricas del *retriever* muestra que, como regla general, el sistema recupera correctamente los fragmentos relevantes, como refleja la mediana de ContextRecall en 0.750, aunque existen casos puntuales en los que el fallo es pronunciado. La ContextPrecision, al tener en cuenta además la posición de los fragmentos dentro del ranking de contexto recuperado, resulta una métrica más exigente y obtiene valores algo más moderados, con mediana de 0.589. Destaca sobre todo la Precision@K, cuya media de 0.097 y mediana de 0.000 resultan llamativamente bajas en comparación con el resto de métricas de recuperación, lo que requiere una explicación específica sobre cómo fue calculada y qué limitación metodológica introduce este valor.

Para comprender el origen de este valor tan bajo es necesario conocer el mecanismo seguido para el cálculo de la métrica. La Precision@K se obtiene como el cociente entre

el número de *chunks* recuperados considerados relevantes y el total de *chunks* devueltos por el retriever. La relevancia de cada *chunk* se determina calculando la similitud coseno entre el *chunk* recuperado y el contexto de referencia, considerándose relevante únicamente aquel *chunk* cuya similitud supere un umbral fijo de 0.75. Este umbral ha resultado excesivamente restrictivo por dos razones. La primera es que el contexto de referencia está formado por fragmentos mínimos del documento que contienen exclusivamente la información necesaria para sustentar la respuesta, mientras que los *chunks* recuperados son fragmentos considerablemente más extensos que acumulan información adicional. Esta diferencia de granularidad hace que la señal semántica del contexto de referencia pueda quedar diluida dentro del *chunk*, fenómeno que denominamos dilución semántica del *embedding* (*embedding dilution*), relacionado con el *granularity dilemma* descrito por Xu et al. [35], el contenido relevante está presente en el fragmento recuperado, pero el ruido adicional que lo rodea desplaza su representación vectorial, reduciendo la similitud coseno por debajo del umbral aunque la información necesaria sí esté contenida en el *chunk*. La segunda razón es que el propio umbral de 0.75 es intrínsecamente alto para las características del espacio de *embeddings* de este corpus.

Para confirmar que el umbral fijo de 0.75 era excesivamente restrictivo, se analizó la distribución real de similitudes coseno entre los *chunks* recuperados y los contextos de referencia del conjunto de evaluación, con el propósito de encontrar un umbral de discriminación ajustado a las características reales del corpus en lugar de determinarlo de forma arbitraria.




Figura 5.21: Distribución de similitudes coseno entre los *chunks* recuperados y los contextos de referencia del conjunto de evaluación.




Figura 5.22: Precision@K recalculada con el umbral adaptativo basado en la mediana empírica de la distribución de similitudes coseno.

Se tomó un umbral adaptativo consistente en la mediana de esta distribución de similitudes coseno, ya que representa el punto que divide en dos mitades iguales la

distribución. Su uso como umbral tiene una justificación directa, garantiza que exactamente la mitad de los *chunks* recuperados supere el umbral, lo que lo convierte en un criterio de discriminación calibrado sobre los propios datos del experimento.

El impacto del cambio de umbral es considerable. Con el umbral fijo de 0.75, únicamente el 15–20 % de los *chunks* superaban el corte de relevancia, dejando fuera la mayoría de fragmentos que sí contenían información útil y produciendo una Precision@K media artificialmente baja de 0.097. Al adoptar el umbral adaptativo basado en la mediana empírica de la distribución de similitudes (0.53), el valor de Precision@K asciende a 0.5, reflejando con mayor fidelidad el comportamiento real del sistema de recuperación. Para un sistema RAG sobre documentos internos de dominio específico como el de AMC Global, donde la similitud coseno entre *chunks* y contextos de referencia está estructuralmente limitada por la diferencia de granularidad entre ambos, un valor de 0.5 es un resultado razonable.

No obstante, el umbral adaptativo corrige únicamente la agresividad del criterio de discriminación empleado en el cálculo de la Precision@K, pero no la causa estructural que limita los valores de similitud coseno. Los *chunks* recuperados son fragmentos considerablemente más extensos que los contextos de referencia, lo que hace que la señal semántica del contenido relevante quede diluida en el *embedding* del *chunk*. Esta dilución actúa con independencia del umbral aplicado, por permisivo que sea el criterio de relevancia, la similitud coseno seguirá siendo moderada porque el vector del *chunk* representa la totalidad de su contenido y no solamente el fragmento relevante que contiene en su interior.

Resulta importante señalar que un valor moderado de Precision@K no implica necesariamente que la respuesta generada sea de baja calidad. El retriever devuelve cinco *chunks* por consulta, y basta con que uno de ellos contenga la información suficiente para que el generador construya una respuesta precisa. Esto explica que los valores de FactualCorrectness sean considerablemente más altos que los de Precision@K, el generador es capaz de extraer la información relevante del *chunk* adecuado, aunque el resto de fragmentos recuperados no sean óptimos.

Para descartar que los valores moderados de similitud coseno se debiesen a una incapacidad del modelo de *embeddings* para generar representaciones lo suficientemente discriminativas entre *chunks* del corpus, se calculó la similitud inter-*chunk* media entre todos los pares de fragmentos que componen el corpus.




Figura 5.23: Distribución de similitudes coseno entre todos los pares de *chunks* del corpus (similitud inter-*chunk*).

El resultado mostró que esa similitud intra-corpus (0.26) era aproximadamente la mitad de la obtenida entre los *chunks* recuperados y los contextos de referencia (0.54), lo que confirma que el modelo de *embeddings* discrimina correctamente entre fragmentos y que el retriever prioriza los *chunks* más relevantes para cada pregunta. El doble en la similitud promedio que presentan los *chunks* recuperados respecto a cualquier par de *chunks* aleatorios del corpus, evidencia que la recuperación no es aleatoria sino dirigida hacia el contenido relevante.

Un análisis cualitativo detallado de casos representativos de este fenómeno de *embedding dilution*, incluyendo una proyección UMAP de los *embeddings* involucrados, se recoge en el Anexo D.

Análisis por categoría de pregunta




Figura 5.24: Faithfulness, FactualCorrectness y ContextRecall medios por categoría de pregunta para el subconjunto *single-turn*.

La categoría *out_of_domain* merece una lectura diferenciada. La FactualCorrectness alta (0.800) indica que la mayoría de las preguntas de esta categoría están siendo respondidas correctamente mediante la abstención, ya que la respuesta de referencia es precisamente esa. Los valores bajos de Faithfulness y ContextRecall son coherentes con este comportamiento, el generador no se apoya en el contexto recuperado para construir su respuesta, y el juez no encuentra fragmentos recuperados que sustenten una respuesta de abstención. Idealmente ambas métricas deberían ser cero para esta categoría. Los valores residuales observados pueden atribuirse a dos causas: un error puntual del juez LLM, que en algunos casos identifica enunciados de la respuesta de abstención como respaldados por el contexto recuperado, o casos en que el generador respondió parcialmente en lugar de abstenerse por completo, generando enunciados que el juez sí encuentra respaldados en el contexto. Ambas situaciones son excepcionales y explican que el promedio de estas métricas para las preguntas *out_of_domain* no sea exactamente cero.

Entre las tres categorías factuales, destaca que *factual_trap* obtiene el ContextRecall más alto (0.788), lo que indica que el retriever recupera correctamente el contexto para este tipo de preguntas. Su FactualCorrectness (0.658) es además comparable a la de *factual_true* (0.701), lo que sugiere que el generador maneja razonablemente bien las preguntas trampa sin caer en la información incorrecta que contienen, apoyándose en el contexto recuperado para construir una respuesta correcta en lugar de dejarse llevar por el enunciado engañoso de la pregunta.

Relación entre recuperación y corrección factual




Figura 5.25: *Scatter plots* de ContextRecall y ContextPrecision frente a FactualCorrectness para el subconjunto *single-turn*. La tendencia se obtiene mediante regresión lineal por mínimos cuadrados excluyendo las preguntas *out_of_domain*.

La tendencia representada en ambas gráficas se obtiene mediante regresión lineal por mínimos cuadrados calculada excluyendo las preguntas *out_of_domain*. Esta exclusión está metodológicamente justificada, en dicho subconjunto el retriever recupera fragmentos sin relación con la pregunta ni con la respuesta de referencia, por lo que sus métricas de recuperación son cercanas a 0 mientras que su FactualCorrectness es alta al abstenerse el generador correctamente. Incluirlas en el cálculo distorsionaría la pendiente de la tendencia hacia valores no representativos del comportamiento real del sistema.

Las gráficas muestran una tendencia positiva clara en ambos casos, a mayor cobertura y precisión del contexto recuperado, mayor FactualCorrectness de la respuesta generada. El hecho de que esta relación sea positiva demuestra que el generador no está inventándose las respuestas, sino que las construye a partir del contexto que el retriever le proporciona. Si el modelo alucinase de forma sistemática, esa tendencia no existiría, ya que la FactualCorrectness dependería del conocimiento paramétrico del modelo y no de la calidad del contexto recuperado. La existencia de esta tendencia positiva constituye la evidencia más directa de la mitigación de alucinaciones que el sistema RAG introduce respecto al *baseline* sin contexto.

Esta pendiente positiva es más pronunciada en ContextRecall que en ContextPrecision debido a que ambas métricas capturan aspectos distintos del proceso de recuperación. ContextRecall mide qué proporción de la respuesta de referencia está cubierta por los fragmentos recuperados, mientras que ContextPrecision penaliza adicionalmente la posición de los fragmentos relevantes dentro del ranking, si el fragmento útil apare-

ce en posiciones bajas, la métrica lo penaliza, aunque esté presente. Esto hace que ContextPrecision sea intrínsecamente más estricta, aplanando la tendencia observada.

5.2.2. Evaluación sobre preguntas multi-turno

Análisis global de métricas




Figura 5.26: Distribución de métricas de generación y recuperación del sistema RAG para el subconjunto *multi-turn*.

A grandes rasgos, la distribución de métricas del sistema RAG en preguntas *multi-turn* muestra una Faithfulness alta y un ContextRecall también alto, lo que indica que el modelo generador sustenta sus respuestas en los fragmentos recuperados y que el retriever cubre en la mayoría de los casos la información necesaria para construir una respuesta correcta. Sin embargo, la FactualCorrectness presenta una mediana de 0.65, inferior a la obtenida en las preguntas *single-turn* (0.80), lo que resulta llamativo dado que tanto la fidelidad como la cobertura del contexto son elevadas.

Esta combinación sugiere que el generador, siendo fiel al contexto recuperado y contando con fragmentos relevantes, no siempre produce respuestas que cubran exactamente lo que la respuesta de referencia espera, omitiendo información o incluyendo elaboraciones adicionales que no aparecen en ella. Una posible explicación es el efecto del historial conversacional sobre el generador, que podría llevarle a omitir información ya mencionada en turnos previos o a introducir en su respuesta matices adicionales derivados del contexto acumulado de la conversación. No obstante, esta hipótesis no

puede afirmarse con certeza en ausencia de un experimento de ablación que compare el comportamiento del sistema con y sin historial, por lo que debe interpretarse como una explicación plausible y coherente con los datos observados, no como una causa demostrada.

Cabe señalar que la comparación directa de ContextRecall entre preguntas *single-turn* y *multi-turn* debe interpretarse con cautela. Aunque a priori los resultados *multi-turn* podrían sugerir una mejor recuperación, esta diferencia se explica en parte por el menor tamaño muestral del experimento *multi-turn* (71 frente a 133 preguntas). Además, al excluir las preguntas *out_of_domain* en *single-turn*, el ContextRecall alcanza valores similares, por lo que la diferencia real entre ambos experimentos es menos pronunciada de lo que pudiera aparentar a primera vista.

Por otro lado, la combinación de Faithfulness alta y FactualCorrectness media no debe interpretarse como un indicador de alucinación. La Faithfulness evalúa si los enunciados de la respuesta están respaldados por el contexto recuperado, mientras que la FactualCorrectness mide la similitud con la respuesta de referencia, son dos dimensiones distintas. Un modelo puede ser completamente fiel al contexto que recibe y aun así no cubrir exactamente lo que la referencia espera. La alucinación se produce cuando la Faithfulness es baja, no cuando la FactualCorrectness es moderada. La combinación de Faithfulness alta y FactualCorrectness media es, por tanto, la firma de un sistema que no alucina de forma sistemática sino que en ocasiones no cubre con exactitud todo lo que la respuesta de referencia espera, un resultado positivo con margen de mejora, no un síntoma de alucinación sistemática.

La AnswerRelevancy presenta una media ligeramente inferior a la obtenida en *single-turn* (0.655 frente a 0.670), lo que no refleja una pérdida real de pertinencia en las respuestas sino una limitación del propio mecanismo de cálculo de la métrica. Y es que, para el cálculo de la métrica en preguntas de turnos avanzados con referencias anafóricas al historial conversacional, el juez LLM genera preguntas sintéticas a partir de la respuesta que divergen de la pregunta original que contiene las mencionadas referencias a partes anteriores de la conversación, penalizando artificialmente la métrica, aunque la respuesta sea correcta y pertinente.

Análisis por patrón conversacional




Figura 5.27: Faithfulness, FactualCorrectness y ContextRecall medios por patrón conversacional para el subconjunto *multi-turn*.




Figura 5.28: Evolución del ContextRecall por turno y patrón conversacional en el subconjunto *multi-turn*.

Los patrones *Expansion* y *Follow-up* presentan los valores más equilibrados de las tres métricas principales: Faithfulness alta, ContextRecall elevado y FactualCorrectness en torno a 0.75. Esta combinación indica que el retriever recupera correctamente el contexto relevante y que el generador sustenta sus respuestas en él, produciendo respuestas de calidad. La brecha constante de aproximadamente 0.14 puntos entre Faithfulness y FactualCorrectness en ambos patrones es coherente con lo argumentado en la sección anterior, el generador, siendo fiel al contexto recuperado, no siempre cubre con exactitud todo lo que la referencia espera, ya sea por omitir información presente en el contexto o por incluir elaboraciones adicionales que no aparecen en ella.

El patrón *Recollection*, en el que el usuario presenta consultas que requieren recupe-

rar información de interacciones previas apoyándose en el historial de la conversación, muestra una caída moderada del ContextRecall promedio (0.662) respecto a los patrones *Expansion* y *Follow-up*. La gráfica de evolución por turnos (Figura 5.28) revela que esta caída se concentra exclusivamente en el turno 5, que corresponde siempre a una pregunta de tipo *recollection-test*. Los turnos intermedios de este patrón son suficientemente informativos para el retriever y mantienen una recuperación aceptable, pero el último turno, diseñado para simular situaciones en las que el usuario solicita información ya tratada referenciando explícitamente momentos anteriores de la conversación, con expresiones como «*como lo hemos hecho hasta ahora*» o «*resume lo que hemos comentado*», delega en la conversación previa la carga semántica de la consulta, aportando escaso vocabulario nuevo al retriever para orientar la búsqueda.

Esta caída en la recuperación del contexto arrastra directamente a la FactualCorrectness (0.612), lo que no responde a alucinaciones del generador sino a que el contexto recuperado es incompleto y, por tanto, el generador no dispone de suficiente material para producir una respuesta tan similar a la de referencia. Con este resultado se evidencia además una limitación arquitectónica relevante, el generador tiende a anclar su respuesta en el contexto que el retriever le proporciona antes que en el historial conversacional, incluso cuando la información necesaria estaba disponible en él. En preguntas de tipo *recollection-test* lo idóneo sería que el generador se apoyase principalmente en el historial, pero el modelo prioriza el contexto recuperado incompleto, produciendo respuestas factualmente menos exactas que las que podría haber construido a partir de la conversación previa.




Figura 5.29: FactualCorrectness y Faithfulness medias por tipo de turno conversacional en el subconjunto *multi-turn*.

La combinación de Faithfulness alta y FactualCorrectness baja en los turnos de tipo *recollection-test* es la evidencia visual más directa de que cuando el generador debería construir la respuesta guiándose más por el historial, la respuesta resulta menos precisa al haberse apoyado principalmente en el contexto recuperado.

El patrón *Refinement*, en el que el usuario clarifica o modifica sus instrucciones previas introduciendo restricciones adicionales o reformulando la pregunta original,

presenta los valores más bajos de las tres métricas analizadas. La gráfica de ContextRecall por turno (Figura 5.28) revela la causa estructural de este deterioro, el turno 1 parte de un valor alto (0.875) porque la pregunta inicial es autocontenida y el retriever puede identificar los *chunks* relevantes con facilidad, pero a partir del segundo turno las preguntas comienzan a reformular o acotar la pregunta original con expresiones que hacen referencia implícita al turno anterior sin aportar vocabulario nuevo, como «¿y si me centro solo en los no manager?» o «¿podrías indicar solo los pasos que corresponden específicamente al Equipo Halal?». Estas referencias anafóricas empobrecen semánticamente la consulta que recibe el retriever, que no tiene acceso al historial para resolver la referencia, lo que provoca una degradación progresiva de la recuperación hasta el mínimo de 0.167 en el turno 3. La recuperación parcial en el turno 4 se debe a que algunas preguntas de ese turno retoman vocabulario más explícito, confirmando que el problema no es estructural del patrón sino dependiente de la carga semántica de cada pregunta individual.

Esta degradación del ContextRecall arrastra directamente a la FactualCorrectness, cuando el retriever no trae el contexto adecuado, el generador no tiende a compensar ese fallo apoyándose en el historial conversacional. El resultado es una respuesta que no cubre lo que la referencia espera.

La bajada de Faithfulness en este patrón responde además a un segundo fenómeno que se solapa con el anterior. En el conjunto de datos existe una conversación (Q033_refinement) en la que el retriever no recupera contexto suficientemente relevante en ninguno de sus turnos para que el generador pueda construir una respuesta. Ante esta situación, el generador opta por abstenerse sistemáticamente en lugar de inventar la respuesta, produciendo valores de Faithfulness de 0.0 en todos sus turnos que arrastran significativamente la media del patrón hacia abajo. Este comportamiento, aunque penaliza la métrica, evidencia que el sistema prefiere la abstención a la alucinación cuando el contexto disponible no es suficiente, que es el comportamiento deseable en un sistema corporativo.

Estos resultados en las preguntas *multi-turn* deben interpretarse teniendo en cuenta el reducido número de conversaciones por patrón, reflejan el comportamiento del sistema sobre este conjunto de datos, y su extrapolación a otros contextos conversacionales requeriría una validación con muestras de mayor tamaño.

5.3. Comparación directa entre el *baseline* y el sistema RAG

Las dos fases experimentales se han analizado hasta aquí por separado. Esta sección las confronta directamente sobre el mismo conjunto de preguntas y con las métricas comunes a ambos sistemas, para cuantificar la ganancia neta que aporta el acceso a contexto documental. La mejora se calcula respecto al *baseline* de GPT-4o, ya que este es también el modelo generador del sistema RAG, así esta comparación aísla el

efecto de incorporar exclusivamente la recuperación sin cambiar de modelo, el *baseline* de Gemini 2.5 Flash se incluye únicamente como referencia. Los valores del *baseline* corresponden al promedio de las cuatro configuraciones de parámetros, cuyo efecto, como se ha mostrado, es marginal. La Tabla 5.2 recoge la comparación.

Tabla 5.2: Comparación directa de métricas entre el *baseline* y el sistema RAG sobre el mismo conjunto de preguntas. Los valores de FactualCorrectness, AnswerRelevancy y SemanticSimilarity son medias.

Métrica	Baseline			Mejora	
	Gemini	GPT-4o	RAG	abs.	rel.
<i>Single-turn</i>					
FactualCorrectness	0,235	0,177	0,666	+0,489	+276,3 %
AnswerRelevancy	0,514	0,411	0,670	+0,259	+63,0 %
SemanticSimilarity	0,746	0,747	0,784	+0,037	+5,0 %
Tasa de alucinación	81,5 %	93,5 %	18,0 %	-75,5 pp	-80,7 %
<i>Multi-turn</i> (Enfoque A)					
FactualCorrectness	0,150	0,172	0,622	+0,450	+261,6 %
AnswerRelevancy	0,579	0,536	0,655	+0,119	+22,2 %
SemanticSimilarity	0,725	0,724	0,784	+0,060	+8,3 %
Tasa de alucinación	95,0 %	92,2 %	27,3 %	-64,9 pp	-70,4 %

La mejora es contundente en las dos métricas que capturan la fiabilidad factual. En *single-turn*, la FactualCorrectness media pasa de 0,177 a 0,666 (un incremento relativo del 276 %) y la tasa de alucinación cae 75,5 puntos porcentuales, del 93,5 % al 18,0 %. En mediana, la FactualCorrectness del RAG alcanza 0,80 frente a 0,135 del *baseline*, lo que refleja todavía mejor la magnitud del salto. El mismo patrón se repite en *multi-turn*, con una caída de la tasa de alucinación de casi 65 puntos.

La AnswerRelevancy mejora de forma apreciable (+63 % en *single-turn*), coherente con que el acceso al contexto reduce la abstención de GPT-4o que penalizaba esta métrica en el *baseline*. La SemanticSimilarity, en cambio, apenas varía (+0,037 en *single-turn*), un resultado esperable, ya que en el *baseline* las respuestas, aun siendo factualmente incorrectas, eran semánticamente próximas al dominio corporativo, como se analizó en la Sección 5.1.2. La ganancia del RAG no reside, por tanto, en acercarse al espacio semántico de la referencia, que ya estaba próximo, sino en corregir el contenido factual, que es precisamente lo que reflejan la FactualCorrectness y la tasa de alucinación. Por último, el sistema RAG supera con holgura no solo al *baseline* de GPT-4o sino también al de Gemini 2.5 Flash en todas las métricas, lo que confirma que la mejora procede del acceso al corpus y no del modelo generador concreto.

5.3.1. Casos en los que el sistema RAG no mejora al *baseline*

Aunque el sistema RAG supera al *baseline* en el agregado, no lo hace en todas las preguntas. Una comparación pregunta a pregunta en el subconjunto *single-turn* revela que el RAG obtiene una FactualCorrectness inferior a la del *baseline* de GPT-4o en 10 de las 133 preguntas comparables (un 7,5 %), repartidas entre las categorías factuales y ninguna de ellas *out_of_domain*. El examen de las métricas de recuperación en ese subconjunto identifica con claridad la causa predominante, el recuperador, cuyo ContextRecall medio es de apenas 0,15 y nulo en la mayoría de los casos, lo que indica que el fragmento con la información necesaria no llegó a recuperarse. No puede descartarse tampoco que, en parte de estos casos, el fragmento relevante figurase entre los candidatos iniciales pero quedara fuera de los cinco seleccionados al ser descartado por el *reranker* en la etapa de reordenación, escenario coherente con la limitación del *cross-encoder* monolingüe descrita en la Sección 4.4.2. Privado del contexto adecuado, el generador no pudo construir una respuesta correcta, mientras que el *baseline* obtuvo una puntuación parcial a partir de su conocimiento paramétrico. Un número menor de casos presenta una recuperación adecuada pero una FactualCorrectness igualmente baja, lo que sitúa el fallo en la generación, como en una pregunta trampa cuyo contexto se recuperó íntegramente (ContextRecall = 1,0) pero cuya respuesta no quedó anclada en él (Faithfulness = 0,0).

En el subconjunto *multi-turn* los casos desfavorables son todavía más escasos, solo 2 de los 71 turnos comparables (un 2,8 %), y ambos pertenecen a las conversaciones generadas a partir de la pregunta semilla Q033, en las que el retriever no recuperó contexto relevante (ContextRecall de 0,5 y 0,0) y el generador optó por abstenerse en lugar de inventar, un comportamiento deseable que, no obstante, penaliza la FactualCorrectness. Este caso, ya descrito en la Sección 5.2.2, vuelve a apuntar al recuperador como origen del fallo.

La tercera causa posible, la fragmentación del corpus, se examina en detalle en el Anexo D, donde se muestra cómo el *chunker* separó en fragmentos distintos una lista que debía recuperarse íntegra. En conjunto, estos casos desfavorables son minoritarios y obedecen mayoritariamente a fallos puntuales del mecanismo de recuperación, no a una degradación introducida por el propio enfoque RAG, que incluso en su peor escenario conserva la mejora agregada recogida en la Tabla 5.2.

6. Conclusiones y líneas de trabajo futuro

Este capítulo recoge las principales conclusiones derivadas de los experimentos descritos en el Capítulo 5, organizadas en torno a los dos bloques de evaluación del estudio: la comparación *baseline* y la evaluación del sistema RAG construido sobre el corpus de AMC Global.

6.1. Conclusiones

6.1.1. Sobre la comparación *baseline*

1. **Sin acceso al corpus, los modelos alucinan de forma masiva y sistemática.** Ninguna combinación de modelo y configuración de parámetros produce una FactualCorrectness superior a 0.25, muy por debajo del umbral permisivo de 0.5 adoptado como referencia en este estudio. La tasa de alucinación no desciende del 79.6 % en ninguna condición experimental, lo que evidencia que el corpus de AMC Global es completamente opaco para ambos modelos sin contexto documental.
2. **Variar los parámetros de generación no constituye una palanca efectiva para mitigar las alucinaciones.** Modificar temperatura y `top_p` dentro del rango estudiado no produce variaciones apreciables en la corrección factual de las respuestas. Ambos modelos son productos comerciales con extenso entrenamiento por refuerzo a partir de retroalimentación humana, cuyos mecanismos internos de calibración amortiguan el efecto de cambios moderados en los parámetros de muestreo, no colapsan hacia salidas caóticas con temperatura alta ni se vuelven drásticamente más precisos con temperatura baja. GPT-4o muestra una sensibilidad algo mayor que Gemini ante la variación de temperatura dentro del rango estudiado, aunque la magnitud del efecto es marginal en términos absolutos para ambos modelos.
3. **Los modelos generan respuestas formalmente coherentes y semánticamente plausibles que resultan, sin embargo, factualmente incorrectas.** La similitud semántica media se mantiene en torno a 0.74–0.75 mientras que la corrección factual no supera 0.243. Esta disociación responde a que ambos modelos comparten el mismo espacio lingüístico del español corporativo, conocen

el registro formal, el vocabulario y las estructuras propias de los documentos de recursos humanos y procedimientos empresariales en español, pero no los datos específicos de AMC Global, de modo que las respuestas parecen adecuadas en estilo pero no contienen información correcta.

4. **Los dos modelos presentan estrategias de fallo cualitativamente distintas.** GPT-4o tiene una tendencia a abstenerse ante preguntas cuya respuesta desconoce, un comportamiento epistémicamente honesto pero funcionalmente inutilizable en producción. Gemini, en cambio, genera en la mayoría de los casos respuestas pertinentes al tema preguntado pero con contenido inventado, construyendo respuestas plausibles y aparentemente fundamentadas que resultan factualmente incorrectas. Ambos modelos fallan, pero el fallo de Gemini es más peligroso porque el usuario recibe información incorrecta presentada con aparente confianza, sin ninguna señal superficial de error. Esto no quiere decir que GPT-4o siempre se abstenga a responder, de hecho cuando lo hace, al igual que Gemini, las respuestas suenan convincentes pero no son correctas factualmente (como mencionamos en el punto anterior de este capítulo), pero sí que es cierto que tiene una tendencia pronunciada a ser honesto y a exponer que no conoce la respuesta, que no se ve tanto en su competidor.
5. **En conversaciones multi-turno, las alucinaciones se propagan y degradan la calidad de las respuestas sucesivas.** Al construir el historial conversacional con las respuestas reales del modelo, los errores factuales introducidos en turnos tempranos contaminan el contexto acumulado y amplifican el error en los turnos siguientes.

6.1.2. Sobre el sistema RAG

1. **El acceso al corpus documental mitiga sustancialmente las alucinaciones.** La FactualCorrectness mediana asciende hasta 0.80, frente a valores inferiores a 0.25 en el *baseline*. El sistema RAG demuestra que anclar las respuestas a una fuente documental reduce de forma efectiva la generación de contenido factualmente incorrecto.
 2. **La calidad de las respuestas depende de forma crítica del desempeño del retriever.** Cuando el retriever recupera correctamente el contexto relevante, el generador produce respuestas de calidad. Cuando falla o devuelve fragmentos incompletos, el generador tiende a construir su respuesta apoyándose en ese contexto deficiente, produciendo respuestas que no cubren todo lo que la referencia espera. Esta dependencia hace que los fallos del retriever tengan una repercusión directa y desproporcionada sobre la corrección factual del sistema.
 3. **El generador tiende a anclar sus respuestas en el contexto recuperado antes que en el historial conversacional.** Esto constituye una ventaja cuando
-

el retriever funciona correctamente, pero supone una limitación en conversaciones largas, en las que la información necesaria para responder está disponible en el historial y no tanto en el contexto recuperado, lo que puede producir respuestas menos precisas que las que habría construido aprovechando la conversación previa.

4. **La dilución semántica del *embedding* puede limitar la precisión del retriever.** Cuando los *chunks* indexados son considerablemente más extensos que simplemente el contenido que aborda la consulta, la señal semántica del fragmento relevante queda diluida en la representación vectorial del *chunk* por la información adicional que lo rodea. Este fenómeno reduce la similitud coseno con la *query* y dificulta la discriminación que el retriever hace a la hora de recuperar el contexto.
5. **Las referencias anafóricas en las preguntas hacia momentos previos de la conversación degradan la calidad de la recuperación y, con ella, la de las respuestas generadas.** Cuando una pregunta delega en el historial la carga semántica de la consulta sin nombrar explícitamente los conceptos relevantes, la *query* enviada al retriever es semánticamente pobre y la búsqueda resulta menos precisa. Dado que el generador tiende a apoyarse en el contexto recuperado antes que en el historial, esta degradación de la recuperación se traslada directamente a la corrección factual de la respuesta final.

6.2. Líneas de trabajo futuro

Los resultados del estudio permiten identificar varias líneas de trabajo cuya exploración podría mejorar el desempeño del sistema y ampliar el alcance de las conclusiones obtenidas:

- ***Chunking* más granular.** Reducir la extensión de los fragmentos indexados mitigaría el fenómeno de dilución semántica del *embedding*, tanto en la fase de recuperación como en la de evaluación. Una estrategia de segmentación que preserve la coherencia semántica de los fragmentos sin acumular información ajena al contenido principal aumentaría la precisión del retriever.
 - **Modelos de *late interaction*.** El uso de modelos como ColBERT [36], que comparan *embeddings* a nivel de *token* en lugar de representar el fragmento completo en un único vector, eliminaría estructuralmente el problema de la dilución semántica y permitiría una discriminación más precisa de los fragmentos relevantes.
 - ***Reranker* multilingüe.** El *cross-encoder* de reordenación empleado se entrenó sobre un corpus en inglés (MS MARCO), mientras que el corpus de AMC Global
-

está en español. Sustituirlo por un *reranker* multilingüe, entrenado sobre recursos como mMARCO, mejoraría presumiblemente la calidad de la reordenación sobre texto en español.

- **Recuperación enriquecida con historial conversacional.** Diseñar un mecanismo que enriquezca semánticamente la *query* con información de turnos previos mejoraría la recuperación en preguntas con referencias a momentos anteriores de la conversación, abordando esta limitación identificada en el experimento *multi-turn*.
 - **Ampliación del conjunto de evaluación.** Validar los resultados con muestras de mayor tamaño permitiría confirmar si las diferencias observadas entre patrones conversacionales son estadísticamente estables o están condicionadas por el reducido tamaño muestral del estudio.
-

Bibliografía

- [1] Kenneth Enevoldsen, Isaac Chung, Imene Kerboua, Márton Kardos, Ashvini Mathur, David Stap, Jay Gala, Wissam Siblini, Dominic Sisneros, Lasse Hansen, Sara Hooker, Kenneth Church, Fabian Gröger, Herumb Shandilya, Orion Weller, Diganta Misra, Shreeya Dhakal, Jonathan Rystrom, Roman Solomatin, Ömer Veysel Çağatan, Akash Ghosh, Marko Miok, Niklas Muennighoff, Nouamane Tazi, Tianhao Li, Mihail Chendov, Hongjin Su, Liang Wang, Nan Yang, Furu Wei, Jonit Levi, Roei Herzig, Amir Ben-David, Ariel Gera, Marek Šuppa, Crystina Zhang, Chunwei Ma, Jose Monteiro, Aleksandr Abramov, Serge Jaborek, Aleksei Vatolin, Dawei Zhu, Jimmy Lin, Goran Glavaš, Miloš Krstić, Ivan Vulic, Anna Korhonen, Isabelle Augenstein, and Iryna Gurevych. MMTEB: Massive multilingual text embedding benchmark. arXiv preprint arXiv:2502.13595, 2025. URL <https://arxiv.org/abs/2502.13595>.
- [2] Yanzhao Zhang, Ming Li, Dingkun Long, Xin Zhang, Huan Lin, Baosong Yang, Pengjun Xie, Aohan Yang, Dayiheng Liu, Junyang Lin, Fei Huang, and Jingren Zhou. Qwen3 embedding: Advancing text embedding and reranking through foundation models. arXiv preprint arXiv:2506.05176, 2025. URL <https://arxiv.org/abs/2506.05176>.
- [3] Ehlullah Karakurt and Akhan Akbulut. Retrieval-augmented generation (RAG) and large language models (LLMs) for enterprise knowledge management and document automation: A systematic literature review. *Applied Sciences*, 16(1): 368, 2026. doi: 10.3390/app16010368. URL <https://www.mdpi.com/2076-3417/16/1/368>.
- [4] Erik Brynjolfsson, Danielle Li, and Lindsey Raymond. Generative AI at work. NBER Working Paper No. 31161, National Bureau of Economic Research, 2023. URL <https://www.nber.org/papers/w31161>.
- [5] Ziwei Ji, Nayeon Lee, Rita Frieske, Tiezheng Yu, Dan Su, Yan Xu, Etsuko Ishii, Ye Jin Bang, Andrea Madotto, and Pascale Fung. Survey of hallucination in natural language generation. *ACM Computing Surveys*, 55(12):1–38, 2023. doi: 10.1145/3571730. URL <https://arxiv.org/abs/2202.03629>.
- [6] Lei Huang, Weijiang Yu, Weitao Ma, Weihong Zhong, Zhangyin Feng, Haotian Wang, Qianglong Chen, Weihua Peng, Xiaocheng Feng, Bing Qin, and Ting Liu. A survey on hallucination in large language models: Principles, taxonomy, challenges,

- and open questions. *ACM Transactions on Information Systems*, 1(1):1–58, 2024. doi: 10.1145/3703155. URL <https://arxiv.org/abs/2311.05232>.
- [7] Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Küttler, Mike Lewis, Wen tau Yih, Tim Rocktäschel, Sebastian Riedel, and Douwe Kiela. Retrieval-augmented generation for knowledge-intensive NLP tasks. *Advances in Neural Information Processing Systems*, vol. 33, pp. 9459–9474. Curran Associates, Inc., 2020. URL <https://arxiv.org/abs/2005.11401>.
- [8] Wai-Chung Kwan, Xingshan Zeng, Yuxin Jiang, Yufei Wang, Liangyou Li, Lifeng Shang, Xin Jiang, Qun Liu, and Kam-Fai Wong. MT-Eval: A multi-turn capabilities evaluation benchmark for large language models. *arXiv preprint arXiv:2401.16745*, 2024. URL <https://arxiv.org/abs/2401.16745>.
- [9] Shahul Es, Jithin James, Luis Espinosa-Anke, and Steven Schockaert. RAGAS: Automated evaluation of retrieval augmented generation. *arXiv preprint arXiv:2309.15217*, 2023. URL <https://arxiv.org/abs/2309.15217>.
- [10] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. *Advances in Neural Information Processing Systems*, vol. 30. Curran Associates, Inc., 2017. URL <https://arxiv.org/abs/1706.03762>.
- [11] Joshua Maynez, Shashi Narayan, Bernd Bohnet, and Ryan McDonald. On faithfulness and factuality in abstractive summarization. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pages 1906–1919, 2020. doi: 10.18653/v1/2020.acl-main.173. URL <https://aclanthology.org/2020.acl-main.173>.
- [12] Kishore Papineni, Salim Roukos, Todd Ward, and Wei-Jing Zhu. BLEU: a method for automatic evaluation of machine translation. In *Proceedings of the 40th Annual Meeting of the Association for Computational Linguistics*, pages 311–318, 2002. doi: 10.3115/1073083.1073135. URL <https://aclanthology.org/P02-1040>.
- [13] Chin-Yew Lin. ROUGE: A package for automatic evaluation of summaries. In *Text Summarization Branches Out*, pages 74–81, 2004. URL <https://aclanthology.org/W04-1013>.
- [14] Amos Azaria and Tom Mitchell. The internal state of an LLM knows when it’s lying. *Findings of the Association for Computational Linguistics: EMNLP 2023*, pp. 967–976. Association for Computational Linguistics, 2023. URL <https://arxiv.org/abs/2304.13734>.
-

-
- [15] Tianyi Zhang, Varsha Kishore, Felix Wu, Kilian Q. Weinberger, and Yoav Artzi. BERTScore: Evaluating text generation with BERT. In *International Conference on Learning Representations*, 2020. URL <https://openreview.net/forum?id=SkeHuCVFDr>.
- [16] Anshuman Mishra, Dhruvesh Patel, Aparna Vijayakumar, Xiang Lorraine Li, Pavan Kapanipathi, and Kartik Talamadupula. Looking beyond sentence-level natural language inference for question answering and text summarization. In *Proceedings of the 2021 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, pages 1322–1336, 2021. doi: 10.18653/v1/2021.naacl-main.104. URL <https://aclanthology.org/2021.naacl-main.104>.
- [17] Potsawee Manakul, Adian Liusie, and Mark J. F. Gales. SelfCheckGPT: Zero-resource black-box hallucination detection for generative large language models. *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*, pp. 9525–9550. Association for Computational Linguistics, 2023. URL <https://arxiv.org/abs/2303.08896>.
- [18] Yang Liu, Dan Iter, Yichong Xu, Shuohang Wang, Ruochen Xu, and Chenguang Zhu. G-EVAL: NLG evaluation using GPT-4 with better human alignment. *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*, pp. 2511–2522. Association for Computational Linguistics, 2023. URL <https://arxiv.org/abs/2303.16634>.
- [19] Lianmin Zheng, Wei-Lin Chiang, Ying Sheng, Siyuan Zhuang, Zhanghao Wu, Yonghao Zhuang, Zi Lin, Zhuohan Li, Dacheng Li, Eric P. Xing, Hao Zhang, Joseph E. Gonzalez, and Ion Stoica. Judging LLM-as-a-judge with MT-Bench and Chatbot Arena. *Advances in Neural Information Processing Systems*, vol. 36. Curran Associates, Inc., 2023. URL <https://arxiv.org/abs/2306.05685>.
- [20] Peiyi Wang, Lei Li, Liang Chen, Zefan Cai, Dawei Zhu, Binghuai Lin, Yunbo Cao, Qi Liu, Tianyu Liu, and Zhifang Sui. Large language models are not fair evaluators. *arXiv preprint arXiv:2305.17926*, 2023. URL <https://arxiv.org/abs/2305.17926>.
- [21] Bhaskarjit Sarmah, Benika Hall, Rohan Rao, Sunil Patel, Stefano Pasquali, and Dhagash Mehta. HybridRAG: Integrating knowledge graphs and vector retrieval augmented generation for efficient information extraction. *arXiv preprint arXiv:2408.04948*, 2024. URL <https://arxiv.org/abs/2408.04948>.
- [22] Aditi Singh, Abul Ehtesham, Saket Kumar, and Tala Talaei Khoei. Agentic retrieval-augmented generation: A survey on agentic RAG. *arXiv preprint arXiv:2501.09633*, 2025. URL <https://arxiv.org/abs/2501.09633>.
-

-
- [23] Ge Bai, Jie Liu, Xingyuan Bu, Yancheng He, Jiaheng Liu, Zhanhui Zhou, Zhuoran Lin, Wenbo Su, Tiezheng Ge, Bo Zheng, and Wanli Ouyang. MT-Bench-101: A fine-grained benchmark for evaluating large language models in multi-turn dialogues. In *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics*, 2024. doi: 10.18653/v1/2024.acl-long.401. URL <https://arxiv.org/abs/2402.14762>.
- [24] Philippe Laban, Hiroaki Hayashi, Yingbo Zhou, and Jennifer Neville. LLMs get lost in multi-turn conversation. arXiv preprint arXiv:2505.06120, 2025. URL <https://arxiv.org/abs/2505.06120>.
- [25] Darren Edge, Ha Trinh, Newman Cheng, Joshua Bradley, Alex Chao, Apurva Mody, Steven Truitt, Dasha Metropolitansky, Robert Osazuwa Ness, and Jonathan Larson. From local to global: A GraphRAG approach to query-focused summarization. arXiv preprint arXiv:2404.16130, 2024. URL <https://arxiv.org/abs/2404.16130>.
- [26] Justin Zhao, Flor Miriam Plaza-del-Arco, Benjamin Genchel, and Amanda Cercas Curry. Language model council: Democratically benchmarking foundation models on highly subjective tasks. arXiv preprint arXiv:2406.08598, 2024. URL <https://arxiv.org/abs/2406.08598>.
- [27] Nandan Thakur, Luiz Bonifacio, Xinyu Zhang, Odunayo Ogundepo, Ehsan Kammalloo, David Alfonso-Hermelo, Xiaoguang Li, Qun Liu, Boxing Chen, Mehdi Rezagholizadeh, and Jimmy Lin. Can we evaluate RAGs with synthetic data? arXiv preprint arXiv:2408.05547, 2024. URL <https://arxiv.org/abs/2408.05547>.
- [28] Shangbin Feng, Weijia Shi, Yike Wang, Wenxuan Ding, Vidhisha Balachandran, and Yulia Tsvetkov. Don’t hallucinate, abstain: Identifying LLM knowledge gaps via multi-LLM collaboration. In *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics*, 2024. doi: 10.18653/v1/2024.acl-long.786. URL <https://arxiv.org/abs/2402.00367>.
- [29] Hadas Orgad, Michael Toker, Zorik Gekhman, Roi Reichart, Idan Szpektor, Hadas Kotek, and Yonatan Belinkov. LLMs know more than they show: On the intrinsic representation of LLM hallucinations. arXiv preprint arXiv:2410.02707, 2025. URL <https://arxiv.org/abs/2410.02707>.
- [30] Freda Shi, Mirac Suzgun, Markus Freitag, Xuezhi Wang, Suraj Srivats, Soroush Vosoughi, Hyung Won Chung, Yi Tay, Sebastian Ruder, Denny Zhou, Dipanjan Das, and Jason Wei. Language models are multilingual chain-of-thought reasoners. In *International Conference on Learning Representations*, 2023. URL <https://arxiv.org/abs/2210.03057>.
-

-
- [31] Dan Hendrycks, Collin Burns, Steven Basart, Andy Zou, Mantas Mazeika, Dawn Song, and Jacob Steinhardt. Measuring massive multitask language understanding. In *International Conference on Learning Representations*, 2021. URL <https://arxiv.org/abs/2009.03300>.
 - [32] Arjun Panickssery, Samuel R. Bowman, and Shi Feng. LLM evaluators recognize and favor their own generations. arXiv preprint arXiv:2404.13076, 2024. URL <https://arxiv.org/abs/2404.13076>.
 - [33] Yury A. Malkov and Dmitry A. Yashunin. Efficient and robust approximate nearest neighbor search using hierarchical navigable small world graphs. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 42(4):824–836, 2020. doi: 10.1109/TPAMI.2018.2889473. URL <https://arxiv.org/abs/1603.09320>.
 - [34] Rodrigo Nogueira and Kyunghyun Cho. Passage re-ranking with BERT. arXiv preprint arXiv:1901.04085, 2019. URL <https://arxiv.org/abs/1901.04085>.
 - [35] Liyan Xu, Zhenlin Su, Mo Yu, Jiangnan Li, Fandong Meng, and Jie Zhou. Dense retrievers can fail on simple queries: Revealing the granularity dilemma of embeddings. In *Findings of the Association for Computational Linguistics: EMNLP 2025*, 2025. doi: 10.48550/arXiv.2506.08592. URL <https://arxiv.org/abs/2506.08592>.
 - [36] Omar Khattab and Matei Zaharia. ColBERT: Efficient and effective passage search via contextualized late interaction over BERT. In *Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval*, pages 39–48, 2020. doi: 10.1145/3397271.3401075. URL <https://arxiv.org/abs/2004.12832>.
 - [37] OpenAI. API reference — chat completions. OpenAI Platform Documentation, 2024. URL <https://platform.openai.com/docs/api-reference/chat/create>.
-

A. Prompts del sistema

A.1. Prompt de extracción de texto mediante visión artificial

El siguiente *prompt* se emplea en la fase de extracción de texto del corpus (Sección 4.1) cuando una página se procesa mediante la API de visión artificial de OpenAI (GPT-4o). Se envía como mensaje de usuario junto con la imagen de la página convertida a formato PNG.

The user will provide you an image of a document file.
Perform the following actions:

1. Transcribe the text on the page.
****TRANSCRIPTION OF THE TEXT:****
2. If there is a chart, describe the image and include the text
****DESCRIPTION OF THE IMAGE OR CHART****
3. If there is a table, transcribe the table and include the text
****TRANSCRIPTION OF THE TABLE****

Transcribe the full content of this document page as plain text.
Follow these rules strictly:

1. Transcribe all visible text exactly as it appears, preserving the logical reading order.
2. Ignore and do not transcribe: page headers, page footers, watermarks, page numbers, and any text that appears as a repeated document title or version label.
3. If the page contains a table, transcribe its content row by row, separating columns with a pipe character (|).
4. If the page contains a chart or graph, describe its type, axes, legend and main values in a single paragraph starting with [CHART]:
5. If the page contains a decorative image with no informational value, write [IMAGE: non-informative] and skip it.
6. Do not add explanations, comments or formatting such as Markdown.
7. If the page is blank or has no extractable content, return [EMPTY PAGE].

A.2. Prompts de generación del *golden dataset* *single-turn*

Los siguientes cuatro *prompts* se emplean en la fase de generación del subconjunto *single-turn* del *golden dataset* (Sección 4.2.1). Cada *prompt* corresponde a una categoría de pregunta y se envía en una llamada independiente a la API de OpenAI (GPT-4.1). Las variables {n_preguntas} y {texto_completo} se sustituyen en tiempo de ejecución por los valores correspondientes a cada documento.

A.2.1. Prompt *factual_true*

You are an expert dataset designer for RAG evaluation systems.

USE CONTEXT:

The document below belongs to the internal knowledge base of AMC Global, a company specialized in natural juices and beverages. Employees from any department or role (production, logistics, HR, quality, sustainability, legal, administration, etc.) consult this knowledge base to resolve day-to-day work questions. The questions you generate must reflect realistic queries that any of these employees might ask in a natural work situation.

Your task is to generate exactly {n_preguntas} factual questions based on the document provided below.

DEFINITION:

A factual question must meet ALL of the following criteria:

- It has a clear, verifiable answer that can be found directly in the document.
- It asks about a specific fact, datum, procedure, rule, date, quantity, or named entity present in the text.
- It does NOT require inference or reasoning beyond reading the relevant fragment.

DIVERSITY REQUIREMENTS - MANDATORY:

- Each question must be based on a DIFFERENT section or topic of the document. Do NOT generate multiple questions about the same paragraph or subject.
 - Each question must use a DIFFERENT grammatical structure and formulation style. Vary between: direct questions (¿Qué...?), indirect questions (¿Cuál es...?), procedural questions (¿Cómo se...?), conditional questions (¿En qué caso...?), and quantitative
-

questions (¿Cuántos/as...?).

- Do NOT repeat the same sentence pattern across different questions.

LANGUAGE RULES - STRICTLY ENFORCED:

- NEVER use expressions like "según el documento", "según el manual", "el documento establece", "de acuerdo con el texto", or any similar meta-documentary reference.
- Questions must be written as if the employee does NOT know the answer.
BAD: "¿Qué tipo de ingredientes deben evitarse según el documento?"
GOOD: "¿Qué ingredientes no pueden llevar los productos de AMC?"

OUTPUT FORMAT:

Return ONLY a valid JSON object with exactly ONE key: "questions", whose value is an array of objects with exactly these three fields:

- "question": the question in the same language as the document.
- "answer_reference": a complete and informative answer that fully addresses the question. Include ALL relevant details present in the document needed to give a thorough response.
- "context_gold": the EXACT and MINIMAL literal fragment from the document that supports the answer. Must be verbatim.

```
{
  "questions": [
    {
      "question": "...",
      "answer_reference": "...",
      "context_gold": "..."
    }
  ]
}
```

DOCUMENT:

{texto_completo}

A.2.2. Prompt *factual_reasoning*

You are an expert dataset designer for RAG evaluation systems.

USE CONTEXT:

The document below belongs to the internal knowledge base of AMC Global, a company specialized in natural juices and beverages. Employees from any department or role consult this knowledge base to resolve day-to-day work questions. The questions you generate must reflect realistic queries that require connecting or reasoning about information from this document.

Your task is to generate exactly {n_preguntas} reasoning-based questions from the document provided below.

DEFINITION:

A reasoning question must meet ALL of the following criteria:

- Its answer CANNOT be found in a single literal sentence of the document.
- It requires the reader to: compare two or more elements, infer a cause or consequence, apply a rule to a specific case, synthesize information from different parts of the text, or reason about an implicit relationship described in the document.
- The answer must still be grounded exclusively in the document content.

VALID REASONING SUBTYPES (use a variety of them):

- Comparison: "¿En qué se diferencia el procedimiento X del Y en AMC?"
- Causal: "¿Por qué AMC exige que...?"
- Conditional: "Si como empleado me encuentro en la situación X, ¿qué debo hacer?"
- Multi-fragment synthesis: questions whose answer requires combining two or more separate sections.
- Consequence: "¿Qué implicaciones tendría para un trabajador que...?"

LANGUAGE RULES - STRICTLY ENFORCED:

- NEVER use expressions like "según el documento", "el documento establece", or any similar meta-documentary reference.
BAD: "¿Por qué razón el documento establece que los proveedores deben certificarse?"
GOOD: "¿Por qué AMC exige que sus proveedores estén certificados?"

OUTPUT FORMAT:

Return ONLY a valid JSON object with exactly ONE key: "questions", whose value is an array of objects with exactly these three fields:

- "question": the question in the same language as the document.
- "answer_reference": a complete answer (3-5 sentences) that explicitly shows the reasoning chain. Include ALL relevant details.
- "context_gold": the EXACT and MINIMAL literal fragment or fragments necessary to construct the answer. If multiple fragments are needed, separate them with " [...] ".

```
{{"questions": [{"question": "...", "answer_reference": "...",  
"context_gold": "..."}]}}
```

DOCUMENT:

```
{texto_completo}
```

A.2.3. Prompt *factual_trap*

You are an expert dataset designer for RAG evaluation systems.

USE CONTEXT:

The document below belongs to the internal knowledge base of AMC Global, a company specialized in natural juices and beverages. The trap questions you generate must simulate realistic misconceptions or wrong assumptions that a real AMC Global employee might genuinely hold.

Your task is to generate exactly {n_preguntas} trap questions based on the document provided below.

DEFINITION:

A trap question must meet ALL of the following criteria:

- It contains a FALSE or MISLEADING premise embedded in the question.
- The false premise must directly contradict or distort information that IS present in the document.
- The question must sound plausible - a real user could genuinely ask it believing the premise is true.
- The correct answer must CORRECT the false premise and provide the accurate information from the document.

TYPES OF TRAPS TO USE (vary between them):

- False numerical value: the question states a wrong quantity or date.
- False attribution: the question assigns a responsibility to the wrong person or department.
- False negation: the question implies something is NOT required when the document says it IS, or vice versa.
- False condition: the question implies a rule applies where the document explicitly excludes it.
- Invented element: references a procedure or role that does not exist.

LANGUAGE RULES - STRICTLY ENFORCED:

- NEVER use expressions like "según el documento", "es cierto que", or any similar meta-documentary reference.

BAD: "¿Es correcto que, según el documento, los empleados tienen 30 días de vacaciones?"

GOOD: "Tengo entendido que en AMC nos corresponden 30 días de vacaciones al año, ¿es correcto?"

OUTPUT FORMAT:

Return ONLY a valid JSON object with exactly ONE key: "questions", whose value is an array of objects with exactly these three fields:

- "question": the trap question in the same language as the document.
- "answer_reference": an answer that explicitly corrects the false premise and provides the full accurate information (3-4 sentences).
- "context_gold": the EXACT and MINIMAL literal fragment from the document that allows the false premise to be identified and corrected.

```
{{"questions": [{"question": "...", "answer_reference": "...",  
"context_gold": "...}]}}
```

DOCUMENT:
{texto_completo}

A.2.4. Prompt *out_of_domain*

You are an expert dataset designer for RAG evaluation systems.

USE CONTEXT:

The document below belongs to the internal knowledge base of AMC Global, a company specialized in natural juices and beverages. The out-of-domain questions you generate must simulate realistic questions that an AMC Global employee might ask but whose answers are not covered in this particular document.

Your task is to generate exactly {n_preguntas} out-of-domain questions based on the document provided below.

DEFINITION:

An out-of-domain question must meet ALL of the following criteria:

- Its answer is NOT present anywhere in the document, not even partially.
- It is a PLAUSIBLE and NATURAL question a real AMC Global employee might ask, thematically related to the document's general domain but addressing a specific aspect the document does not cover.
- It must NOT be answerable by inference or reasoning from the content.
- It must NOT be an obviously absurd or unrelated question.

TYPES OF OUT-OF-DOMAIN QUESTIONS (vary between them):

- Information about related processes not mentioned in the document.
 - Specific data (figures, dates, names) not included in the text.
 - Regulations from external bodies referenced but not explained.
-

- Operational details that would naturally complement the document.
- Follow-up questions whose answers are not in the document.

LANGUAGE RULES - STRICTLY ENFORCED:

- NEVER use meta-documentary references.
BAD: "¿Qué información no cubre el documento sobre selección?"
GOOD: "¿Cuánto dura el proceso de selección habitual en AMC Global?"

OUTPUT FORMAT:

Return ONLY a valid JSON object with exactly ONE key: "questions", whose value is an array of objects with exactly these TWO fields:

- "question": the out-of-domain question in the same language as the document.
- "answer_reference": always and exactly this fixed string:
"No se puede responder con la información disponible en la documentación de AMC Global."

```
{
  "questions": [
    {
      "question": "...",
      "answer_reference": "No se puede responder con la información disponible en la documentación de AMC Global."
    }
  ]
}
```

DOCUMENT:

```
{texto_completo}
```

A.3. Prompts de generación del *golden dataset multi-turn*

Los siguientes cuatro *prompts* se emplean en la fase de generación del subconjunto *multi-turn* del *golden dataset* (Sección 4.2.2), uno por cada patrón conversacional de MT-Eval. Las variables entre llaves se sustituyen en tiempo de ejecución: {seed_question} y {seed_answer} por la pregunta y respuesta de referencia de la semilla seleccionada, {n_turns} por el número de turnos adicionales configurado para el patrón, y {generation_context} por la sección del documento amplificada mediante la ventana de ± 1.500 caracteres descrita en la Sección 4.2.2. El *prompt* de *Recollection* no emplea {seed_question} ni {seed_answer}, ya que genera todos sus turnos desde cero.

A.3.1. Prompt *Follow-up*

You are an expert dataset designer for RAG (Retrieval-Augmented

Generation) evaluation systems specialized in multi-turn conversational benchmarks.

USE CONTEXT:

The document below belongs to the internal knowledge base of AMC Global, a company specialized in natural juices and beverages. The conversation you generate must simulate a realistic interaction between an AMC Global employee and an internal knowledge assistant. The employee initiated the conversation with a genuine work-related question and now continues asking follow-up questions based on the answers they receive.

CONVERSATION SO FAR (Turn 1 is fixed - do NOT modify it):

Turn 1 (Employee): {seed_question}

Turn 1 (Assistant): {seed_answer}

YOUR TASK:

Generate exactly {n_turns} additional conversation turns (Turn 2 onwards) of type FOLLOW-UP.

DEFINITION OF FOLLOW-UP TURN:

A Follow-up turn is one where the employee asks a question that directly references something specific mentioned in the IMMEDIATELY PRECEDING assistant response.

- The question must be impossible to understand without reading the previous assistant response.
- The question must NOT be answerable from general knowledge alone
 - it must require the document.
- Each turn must build naturally on the previous one, creating a coherent conversational chain.

DIVERSITY REQUIREMENTS - MANDATORY:

- Each follow-up question must focus on a DIFFERENT specific element from the preceding response (e.g., a different entity, quantity, date, or process mentioned).
- Do NOT generate two questions that ask about the same detail.
- Vary the grammatical structure: use direct questions, clarification requests, consequence questions ("¿Y qué ocurre si...?"), and quantitative questions.

LANGUAGE RULES - STRICTLY ENFORCED:

- NEVER use expressions like "según el documento", "el texto indica",
-

- "de acuerdo con el fragmento" or any meta-documentary reference.
- The employee must sound like a real AMC worker asking natural follow-up questions, not like an academic formulating questions about a text.
 - Questions must reference the assistant's previous answer naturally.
- BAD: "¿Según el documento, cuál es el plazo mencionado antes?"
- GOOD: "¿Y ese plazo de 4 semanas se aplica también a los envases de vidrio?"

ANSWER RULES:

- Each assistant answer must be fully grounded in the reference document fragment.
- Do NOT invent information not present in the fragment.
- If a follow-up question cannot be answered from the fragment, generate a question that CAN be answered.
- Answers must be complete and actionable, as if a knowledgeable AMC colleague is responding.

OUTPUT FORMAT:

Return ONLY a valid JSON object. Do not include any explanation, commentary, or text outside the JSON.

The JSON object must have exactly TWO keys:

- "conversation_type": a string with the fixed value "follow-up".
- "turns": an array of objects. Each object must have exactly FOUR fields and no others:
 - "turn": an integer indicating the turn number, starting at 2.
 - "user": the employee's question, following ALL LANGUAGE RULES.
 - "assistant": the assistant's answer, fully grounded in the document fragment.
 - "source_fragment": the EXACT verbatim sentence or sentences from the DOCUMENT SECTION that directly support the answer. Must be a literal extract, not a paraphrase. If the answer draws from multiple non-contiguous sentences, separate them with " [...] ".

```
{
  "conversation_type": "follow-up",
  "turns": [
    {
      "turn": 2,
      "user": "...",
      "assistant": "...",
```

```
    "source_fragment": "..."  
  },  
  {  
    "turn": 3,  
    "user": "...",  
    "assistant": "...",  
    "source_fragment": "..."  
  }  
]  
}
```

DOCUMENT SECTION:
{generation_context}

A.3.2. Prompt *Expansion*

You are an expert dataset designer for RAG (Retrieval-Augmented Generation) evaluation systems specialized in multi-turn conversational benchmarks.

USE CONTEXT:

The document below belongs to the internal knowledge base of AMC Global, a company specialized in natural juices and beverages. The conversation you generate must simulate a realistic interaction between an AMC Global employee and an internal knowledge assistant. The employee initiated the conversation exploring a specific topic and now continues asking about different aspects of that same topic, progressively covering the full breadth of the document fragment.

CONVERSATION SO FAR (Turn 1 is fixed - do NOT modify it):

Turn 1 (Employee): {seed_question}

Turn 1 (Assistant): {seed_answer}

YOUR TASK:

Generate exactly {n_turns} additional conversation turns (Turn 2 onwards) of type EXPANSION.

DEFINITION OF EXPANSION TURN:

An Expansion turn is one where the employee explores a DIFFERENT subtopic or aspect within the same general subject introduced in Turn 1.

- The question must NOT reference anything specific from the previous assistant response.
- The question must stand on its own but remain within the same thematic domain.
- Each turn must cover a genuinely different dimension: causes, consequences, actors, procedures, quantities, timelines, exceptions, or related entities.

DIVERSITY REQUIREMENTS - MANDATORY:

- Each expansion question must address a DIFFERENT section or data point of the document fragment.
- Do NOT generate questions that partially overlap in topic.
- Vary the angle of inquiry: operational questions, regulatory questions, quantitative questions, procedural questions, and exception questions.

LANGUAGE RULES - STRICTLY ENFORCED:

- NEVER use expressions like "según el documento", "el texto menciona", "el fragmento indica" or any meta-documentary reference.
- The employee must sound like a real AMC worker naturally curious about different aspects of a work topic.
BAD: "¿Qué más menciona el texto sobre los certificados?"
GOOD: "¿Y qué certificaciones necesitan los proveedores que trabajen con AMC?"

ANSWER RULES:

- Each assistant answer must be fully grounded in the reference document fragment.
- Do NOT invent information not present in the fragment.
- Answers must be complete and actionable, as if a knowledgeable AMC colleague is responding.

OUTPUT FORMAT:

Return ONLY a valid JSON object. Do not include any explanation, commentary, or text outside the JSON.

The JSON object must have exactly TWO keys:

- "conversation_type": a string with the fixed value "expansion".
- "turns": an array of objects. Each object must have exactly FOUR fields and no others:
 - "turn": an integer indicating the turn number, starting at 2.
 - "user": the employee's question, following ALL LANGUAGE RULES.
 - "assistant": the assistant's answer, fully grounded in the

```
document fragment.
- "source_fragment": the EXACT verbatim sentence or sentences
  from the DOCUMENT SECTION that directly support the answer.
  Must be a literal extract, not a paraphrase. If the answer
  draws from multiple non-contiguous sentences, separate them
  with " [...] ".

{
  "conversation_type": "expansion",
  "turns": [
    {
      "turn": 2,
      "user": "...",
      "assistant": "...",
      "source_fragment": "..."
    },
    {
      "turn": 3,
      "user": "...",
      "assistant": "...",
      "source_fragment": "..."
    }
  ]
}
```

```
DOCUMENT SECTION:
{generation_context}
```

A.3.3. Prompt Refinement

You are an expert dataset designer for RAG (Retrieval-Augmented Generation) evaluation systems specialized in multi-turn conversational benchmarks.

USE CONTEXT:

The document below belongs to the internal knowledge base of AMC Global, a company specialized in natural juices and beverages. The conversation you generate must simulate a realistic interaction between an AMC Global employee and an internal knowledge assistant. The employee initiated the conversation with a broad question and now progressively narrows and refines their query, adding specific

constraints, formats, or conditions as they process the answers.

CONVERSATION SO FAR (Turn 1 is fixed - do NOT modify it):

Turn 1 (Employee): {seed_question}

Turn 1 (Assistant): {seed_answer}

YOUR TASK:

Generate exactly {n_turns} additional conversation turns (Turn 2 onwards) of type REFINEMENT.

DEFINITION OF REFINEMENT TURN:

A Refinement turn is one where the employee modifies, narrows, or adds a constraint to their ORIGINAL question (Turn 1), not to the previous assistant response.

- The employee must explicitly reference the original request and add a new condition.
- Each turn must introduce ONE new constraint or specification (format, scope, actor, time period, exception, output style, etc.).
- Constraints must accumulate: Turn 3 must honor all constraints introduced in Turn 2.

DIVERSITY REQUIREMENTS - MANDATORY:

- Each refinement must add a GENUINELY DIFFERENT type of constraint. Example: Turn 2 adds a scope restriction → Turn 3 adds a format requirement → Turn 4 adds a temporal condition.
- Do NOT generate two refinements that add constraints of the same category.

LANGUAGE RULES - STRICTLY ENFORCED:

- NEVER use expressions like "según el documento", "el texto indica", "el fragmento menciona" or any meta-documentary reference.
- The employee must sound like an AMC worker progressively clarifying what they need, as naturally happens in real workplace conversations.
BAD: "¿Puedes modificar tu respuesta según las restricciones?"
GOOD: "Gracias, ¿y podrías decirme lo mismo pero solo para el turno de noche?"
GOOD: "Perfecto, ¿y me lo puedes resumir en una lista de puntos?"

ANSWER RULES:

- Each assistant answer must comply with ALL constraints introduced up to that turn.
 - Each answer must be fully grounded in the reference document.
-

- Do NOT invent information not present in the fragment.
- If a cumulative constraint cannot be satisfied by the document, adjust the constraint in the question so it CAN be satisfied, maintaining the refinement logic.

OUTPUT FORMAT:

Return ONLY a valid JSON object. Do not include any explanation, commentary, or text outside the JSON.

The JSON object must have exactly TWO keys:

- "conversation_type": a string with the fixed value "refinement".
- "turns": an array of objects. Each object must have exactly FIVE fields and no others:
 - "turn": an integer indicating the turn number, starting at 2.
 - "constraint_added": a short string (max 10 words) describing the new constraint introduced in this turn.
Example: "scope: solo turno de noche".
 - "user": the employee's refinement request, following ALL LANGUAGE RULES.
 - "assistant": the assistant's answer, satisfying ALL constraints accumulated up to and including this turn, fully grounded in the document fragment.
 - "source_fragment": the EXACT verbatim sentence or sentences from the DOCUMENT SECTION that directly support the answer. Must be a literal extract. Separate non-contiguous sentences with " [...] ".

```
{
  "conversation_type": "refinement",
  "turns": [
    {
      "turn": 2,
      "constraint_added": "...",
      "user": "...",
      "assistant": "...",
      "source_fragment": "..."
    },
    {
      "turn": 3,
      "constraint_added": "...",
      "user": "...",
      "assistant": "...",
      "source_fragment": "..."
    }
  ]
}
```

```
}  
]  
}
```

DOCUMENT SECTION:
{generation_context}

A.3.4. Prompt *Recollection*

You are an expert dataset designer for RAG (Retrieval-Augmented Generation) evaluation systems specialized in multi-turn conversational benchmarks.

USE CONTEXT:

The document section below belongs to the internal knowledge base of AMC Global, a company specialized in natural juices and beverages. The conversation you generate must simulate a realistic interaction between an AMC Global employee and an internal knowledge assistant.

YOUR TASK:

Generate a complete multi-turn conversation of type RECOLLECTION with exactly {n_turns} turns (Turn 1 included). You must generate ALL turns from scratch, including Turn 1.

STRUCTURE - MANDATORY:

- Turn 1 (Employee): establish a GLOBAL INSTRUCTION or PERSISTENT CONDITION that the assistant must remember and apply throughout the entire conversation. This must be a realistic request that an AMC employee would make, such as specifying an output format, a scope restriction, a role perspective, or a cumulative constraint. Examples of valid global instructions:
 - "Respóndeme siempre en formato de lista numerada."
 - "Necesito que todas tus respuestas sean desde el punto de vista del departamento de calidad."
 - "Tenlo en cuenta: solo me interesa la información relativa a proveedores externos."
- Turn 1 (Assistant): acknowledge the global instruction explicitly and provide a first relevant answer applying it, fully grounded in the document section.
- Turns 2 to {n_turns}-1 (bridge turns): ask about different aspects of the document section. These turns must NOT explicitly reference

the global instruction from Turn 1. The assistant must silently continue applying it in every response.

- Turn {n_turns} (recollection-test turn): ask something that can ONLY be answered correctly if the assistant has retained and applied the global instruction from Turn 1. The user must NOT remind the assistant of the instruction - it is assumed to apply.

DEFINITION OF RECOLLECTION PATTERN:

A Recollection conversation tests whether the assistant retains a global instruction established at the beginning and continues applying it correctly after several intervening turns have created distance from it. The recollection test must be subtle: the failure mode is an assistant that answers correctly in content but ignores the persistent condition established in Turn 1.

LANGUAGE RULES - STRICTLY ENFORCED:

- NEVER use expressions like "según el documento", "el texto indica", "como se menciona" or any meta-documentary reference.
 - The employee must sound like a real AMC worker having a natural workplace conversation.
 - The global instruction in Turn 1 must sound like a genuine work preference or need, not like a test condition.
- BAD: "Para esta conversación, recuerda que debes responder en formato JSON."
- GOOD: "Oye, para este tipo de consultas me ayuda mucho cuando me das la info en una tabla, ¿puedes hacerlo así?"

ANSWER RULES:

- ALL assistant answers must be fully grounded in the document.
- Do NOT invent information not present in the document section.
- The assistant's answer in EVERY turn must apply the global instruction from Turn 1, without the user needing to repeat it.
- The answer to the recollection-test turn must make the application of Turn 1's instruction explicit and unambiguous.

OUTPUT FORMAT:

Return ONLY a valid JSON object. Do not include any explanation, commentary, or text outside the JSON.

The JSON object must have exactly TWO keys:

- "conversation_type": a string with the fixed value "recollection".
 - "turns": an array of objects representing ALL turns including Turn 1. Each object must have exactly FIVE fields and no others:
-

- "turn": an integer indicating the turn number, starting at 1.
 - "type": a string with exactly ONE of these three fixed values:
 - "instruction": ONLY for Turn 1.
 - "bridge": for intermediate turns.
 - "recollection-test": for the final turn. There must be exactly ONE such turn, placed last in the array.
 - "user": the employee's message, following ALL LANGUAGE RULES.
 - "assistant": the assistant's answer, fully grounded in the document and applying the global instruction in every turn.
 - "source_fragment": the EXACT verbatim sentence or sentences from the DOCUMENT SECTION supporting the answer.
- For the "instruction" turn: use the fixed string
"N/A - global instruction acknowledgement".

```
{
  "conversation_type": "recollection",
  "turns": [
    {
      "turn": 1, "type": "instruction",
      "user": "...", "assistant": "...",
      "source_fragment": "N/A - global instruction acknowledgement"
    },
    {
      "turn": 2, "type": "bridge",
      "user": "...", "assistant": "...", "source_fragment": "..."
    },
    {
      "turn": 3, "type": "bridge",
      "user": "...", "assistant": "...", "source_fragment": "..."
    },
    {
      "turn": 4, "type": "recollection-test",
      "user": "...", "assistant": "...", "source_fragment": "..."
    }
  ]
}
```

DOCUMENT SECTION:
{generation_context}

A.4. *System prompt* del experimento *baseline*

El siguiente *system prompt* se emplea en la fase de inferencia del experimento *baseline* (Sección 4.3), tanto en el subconjunto *single-turn* como en el *multi-turn*. Se envía como mensaje de sistema en todas las llamadas a la API de GPT-4o y Gemini 2.5 Flash, con independencia de la configuración de parámetros empleada.

```
You are a helpful and precise assistant.  
Answer concisely and factually based only on what you know.  
If you are not certain about something, say so explicitly  
instead of guessing or fabricating information.
```

A.5. *System prompt* del *pipeline RAG*

El siguiente *system prompt* se emplea en la fase de inferencia del *pipeline RAG* (Sección 4.4.2), tanto en el subconjunto *single-turn* como en el *multi-turn*. Se envía como mensaje de sistema en todas las llamadas al modelo generador, con el contexto recuperado concatenado en el mensaje de usuario del turno actual.

```
You are a precise and reliable internal assistant for AMC Global,  
specialized in answering questions based on the provided document  
context. Answer concisely and factually using the information  
present in the context. If the context contains partial  
information, use it to provide the best possible answer and  
indicate what aspects are not covered. Only respond with  
'No dispongo de información suficiente en los documentos  
proporcionados para responder a esta pregunta.' when the context  
is completely unrelated to the question. Do not fabricate  
information not present in the context. Always respond in Spanish.
```

B. Estructuras de datos

B.1. Estructura de los ficheros de salida del preprocesamiento

El siguiente ejemplo ilustra la estructura del fichero JSON generado para cada documento tras la fase de extracción y preprocesamiento del corpus (Sección 4.1). Los valores de texto son representativos y se han abreviado con puntos suspensivos para facilitar la lectura.

```
{
  "nombre_original": "CodigoEtico.pdf",
  "ruta": "/content/drive/.../CodigoEtico.pdf",
  "nombre_procesado": "D-3-CodigoEtico.pdf",
  "fecha_procesado": "2026-02-22 19:53:02",
  "num_paginas": 14,
  "paginas": [
    {
      "num_pagina": 1,
      "metodo_extraccion": "pymupdf",
      "texto_crudo": "Código Ético AMC-FTN-CE-13...",
      "texto_procesado": "Código Ético AMC-FTN-CE-13..."
    },
    {
      "num_pagina": 2,
      "metodo_extraccion": "openai_vision",
      "texto_crudo": "Nuestra Misión AMC Natural Drinks...",
      "texto_procesado": "Nuestra Misión AMC Natural Drinks..."
    }
  ],
  "texto_completo": "Código Ético...\n\nNuestra Misión..."
}
```

B.2. Estructura de una entrada del *golden dataset* *single-turn*

El fichero JSONL del subconjunto *single-turn* (Sección 4.2.1) contiene una entrada por línea. A continuación se muestra una entrada representativa de cada categoría, con los campos de texto abreviados para facilitar la lectura. Los campos `retrieved_contexts` y `response` se dejan vacíos en el fichero de referencia y se completan durante la fase de evaluación del sistema RAG.

```
// Categoría factual_true
{
  "user_input": "¿Cómo se define la cadena de suministro en AMC?",
  "reference_contexts": [
    "Cadena de Suministro: Conjunto de actividades, instalaciones
    y medios de distribución necesarios para llevar a cabo el
    proceso de venta de un producto en su totalidad. Esto es,
    desde la búsqueda de materias primas y material auxiliar,
    su posterior transformación, y hasta la fabricación,
    transporte y entrega al consumidor final."
  ],
  "reference": "La cadena de suministro se entiende como el conjunto
  de actividades, instalaciones y medios de distribución
  necesarios para llevar a cabo el proceso de venta de
  un producto en su totalidad. Esto abarca desde la
  búsqueda de materias primas y material auxiliar,
  su posterior transformación, y hasta la fabricación,
  transporte y entrega al consumidor final.",
  "retrieved_contexts": null,
  "response": null,
  "metadata": {"id": "Q027", "category": "factual_true",
    "doc_name": "POL-CALI-9.0 V1_Politica de Calidad...pdf"}
}

// Categoría factual_reasoning
{
  "user_input": "¿Cómo se relacionan el ciclo PHVA y el pensamiento
  basado en riesgos dentro del SGC&SA del Grupo?",
  "reference_contexts": [
    "El SGC&SA utilizado del Grupo se basa en el enfoque a procesos,
    que incorpora el ciclo Planificar-Hacer-Verificar-Actuar (PHVA)"
  ]
}
```

```
y el pensamiento basado en riesgos. [...] el pensamiento basado
en riesgos permite al Grupo identificar los eventos que pueden
alejarse al SGC&SA del resultado previsto [...]",
"El PHVA es un proceso cíclico que utiliza el aprendizaje de las
fases de hacer y verificar como información de entrada en las
siguientes fases de planificación y actuación."
],
"reference": "El ciclo PHVA y el pensamiento basado en riesgos se
              integran en el SGC&SA del Grupo para asegurar la
              mejora continua y la prevención de desviaciones. [...]",
"retrieved_contexts": null,
"response": null,
"metadata": {"id": "Q028", "category": "factual_reasoning",
             "doc_name": "POL-CALI-9.0 V1_Politica de Calidad...pdf"}
}

// Categoría factual_trap
{
  "user_input": "¿No es el departamento de Recursos Humanos el encargado
                de implantar la Política de Calidad en AMC?",
  "reference_contexts": [
    "El Departamento de Sistemas de Calidad y Sostenibilidad es
    responsable de la implantación y gestión efectiva de esta
    Política y del resto de normativa relacionada."
  ],
  "reference": "La responsabilidad recae en el Departamento de Sistemas
                de Calidad y Sostenibilidad, no en Recursos Humanos.
                Este departamento asegura la aplicación efectiva de
                la política y de toda la normativa relacionada.",
  "retrieved_contexts": null,
  "response": null,
  "metadata": {"id": "Q030", "category": "factual_trap",
               "doc_name": "POL-CALI-9.0 V1_Politica de Calidad...pdf"}
}

// Categoría out_of_domain
{
  "user_input": "¿Cuáles son los principales mercados internacionales
                a los que AMC Global exporta sus productos?",
  "reference_contexts": [],
  "reference": "No se puede responder con la información disponible
                en la documentación de AMC Global.",
```

```

"retrieved_contexts": null,
"response": null,
"metadata": {"id": "Q031", "category": "out_of_domain",
             "doc_name": "POL-CALI-9.0 V1_Politica de Calidad...pdf"}
}

```

B.3. Estructura de una entrada del *golden dataset* *multi-turn*

El fichero JSONL del subconjunto *multi-turn* (Sección 4.2.2) contiene una conversación completa por línea, con los campos `conversation_id`, `pattern`, `seed_id` y `turns`. A continuación se muestra una entrada representativa del patrón *Follow-up*, con los campos de texto más extensos truncados al final para facilitar la lectura. En los patrones *Refinement* y *Recollection*, los turnos incluyen respectivamente los campos adicionales `constraint_added` (restricción introducida en ese turno) y `type` (tipo de turno: `instruction`, `bridge` o `recollection-test`).

```

{
  "conversation_id": "Q033_follow-up",
  "pattern": "follow-up",
  "seed_id": "Q033",
  "turns": [
    {
      "turn": 1,
      "user": "¿Qué consecuencias puede enfrentar un empleado si  
no informa sobre una conducta irregular que  
conoce o sospecha dentro de AMC?",
      "assistant": "Si un empleado no informa sobre una conducta  
irregular de la que tiene conocimiento o  
sospecha, incumple una obligación fundamental  
establecida por AMC: todo el Personal tiene la  
obligación de informar y denunciar posibles  
riesgos o incumplimientos de la normativa  
interna o cualquier actuación antijurídica  
o delictiva a través del Canal de Denuncias.  
Esta omisión puede conllevar sanciones  
disciplinarias, ya que AMC cuenta con un  
régimen disciplinario aplicable a todo el

```

```
        Personal en caso de incumplimiento ...",
"source_fragment": "Todo el Personal tiene la obligación de
                    informar y denunciar los posibles riesgos
                    o incumplimientos de la normativa interna
                    del Grupo y/o de cualquier actuación que
                    pudiera ser considerada antijurídica o
                    delictiva de la que se tenga conocimiento
                    o sospecha, a través del Canal de
                    Denuncias de AMC. En caso de verificarse
                    dichas conductas ilícitas ...",
"metadata": {"pattern": "follow-up", "seed_id": "Q033",
             "seed_doc": "PoliticaDeCumplimiento.pdf",
             "generation_context_length": 787}
},
{
  "turn": 2,
  "user": "¿Las sanciones disciplinarias siempre se aplican
           igual o AMC las adapta según la gravedad?",
  "assistant": "Las sanciones disciplinarias se aplican de forma
               proporcionada y ajustada, es decir, AMC las
               adapta según la gravedad de la conducta
               verificada.",
  "source_fragment": "En caso de verificarse dichas conductas
                     ilícitas, AMC deberá aplicar, de forma
                     proporcionada y ajustada, las sanciones
                     disciplinarias correspondientes",
  "metadata": {"pattern": "follow-up", "seed_id": "Q033",
               "seed_doc": "PoliticaDeCumplimiento.pdf",
               "generation_context_length": 787}
},
{
  "turn": 3,
  "user": "¿Y si alguien denuncia de buena fe pero luego se
           demuestra que no era cierto, puede sufrir
           represalias?",
  "assistant": "No, no se pueden tomar represalias contra quienes
               denuncian de buena fe, aunque después se
               demuestre que la irregularidad no era cierta.",
  "source_fragment": "sin que en ningún caso puedan tomarse
                     represalias con aquellos denunciantes
                     de buena fe",
  "metadata": {"pattern": "follow-up", "seed_id": "Q033",
```

```
        "seed_doc": "PoliticaDeCumplimiento.pdf",
        "generation_context_length": 787}
    },
    {
        "turn": 4,
        "user": "¿El régimen disciplinario aplica solo a ciertos
                puestos o es obligatorio para todo el Personal
                de la empresa?",
        "assistant": "El régimen disciplinario es aplicable a todo el
                    Personal, sin distinción de puesto o función
                    dentro de la empresa.",
        "source_fragment": "La Entidad cuenta con un régimen
                            disciplinario aplicable a todo el Personal
                            en caso de incumplimiento del Modelo o de
                            la normativa interna de aplicación",
        "metadata": {"pattern": "follow-up", "seed_id": "Q033",
                    "seed_doc": "PoliticaDeCumplimiento.pdf",
                    "generation_context_length": 787}
    }
]
}
```

C. Autorización de la empresa



UNIVERSIDAD DE
MURCIA

APROBADA EN JUNTA DE
FACULTAD DE 19/6/2025



Facultad
de Informática

Anexo III. Autorización de Empresa colaboradora

Visto bueno de empresa a la presentación de TFG/TFM realizado por estudiantes de la UMU en colaboración con la entidad.

De acuerdo con el Reglamento por el que se regulan los Trabajos Fin de Grado y de Fin de Máster en la Universidad de Murcia (aprobado en Consejo de Gobierno el día 28 de junio de 2022), así como la normativa interna para la oferta, asignación, elaboración y defensa de los Trabajos Fin de Grado y Fin de Máster de las titulaciones impartidas en la Facultad de Informática de la Universidad de Murcia (aprobada en Junta de Facultad el 19 de junio de 2025)

D. Salvador García Ortuño, con DNI 23030515-V, representante de la empresa: AMC GLOBAL
vista la memoria del TFG/TFM que se cita más adelante,

OTORGA SU VISTO BUENO PARA QUE,

D. Juan Andrés Álvarez Cascales, con DNI 58469474-R., estudiante de la titulación de **Grado en Ciencia e Ingeniería de Datos** de la Universidad de Murcia y autor del TFG/TFM titulado:

ESTUDIO DE LAS ALUCINACIONES EN LOS LLMs

pueda presentar el trabajo y la correspondiente memoria.

Murcia, a 11 de junio de 2026

Firmado por GARCIA ORTUÑO SALVADOR -
***3051** el día 15/06/2026 con un
certificado emitido por AC FNMT Usuarios

Fdo.:

Representante de la empresa

D. Análisis de dilución semántica del *embedding*

Para evidenciar visualmente el fenómeno de la dilución semántica del *embedding* (*embedding dilution*), se presenta un análisis UMAP para los casos donde este fenómeno fue más pronunciado. Conviene señalar que la dilución semántica no afecta únicamente a la fase de evaluación, donde se comparaba el *chunk* recuperado contra el fragmento de referencia, sino que puede afectar también a la propia fase de recuperación, la pregunta genera un *embedding* semánticamente denso y preciso, mientras que los *chunks* del corpus que contienen la respuesta pueden acumular información adicional que diluye la señal semántica que los relacionaría con la pregunta. Esto reduce la similitud coseno entre ambos, pudiendo provocar que el retriever sitúe ese *chunk* en posiciones bajas del ranking o directamente no lo recupere.

Para seleccionar los casos más representativos de la dilución semántica se aplicó un filtro sobre el conjunto de evaluación, identificando aquellas preguntas con Faithfulness alta, FactualCorrectness baja y ContextRecall bajo simultáneamente. Esta combinación de métricas constituye la señal característica del fenómeno, el generador se ciñó al contexto que recibió (Faithfulness alta), pero ese contexto no contenía la información necesaria para construir una respuesta correcta (ContextRecall bajo), lo que se tradujo en una respuesta factualmente alejada de la referencia (FactualCorrectness baja). Con esos requisitos se seleccionaron dos preguntas representativas.

El análisis UMAP proyecta en dos dimensiones los *embeddings* de la pregunta, la respuesta de referencia, el contexto de referencia y los *chunks* recuperados para ambas preguntas. En los dos casos se observa que los *chunks* recuperados quedan alejados en el espacio de *embeddings* respecto a la pregunta, la respuesta y el contexto de referencia, evidenciando que el retriever no logró recuperar los fragmentos semánticamente más próximos a la información necesaria para construir la respuesta correcta.

Destaca, sin embargo, en el caso P121 un *chunk* recuperado que sí aparece agrupado junto a la pregunta, la respuesta y el contexto de referencia. La pregunta era:

«¿Cuáles son los elementos básicos que forman parte de la cadena de custodia en AMC Global?»

El *chunk* semánticamente más próximo, que es el que aparece agrupado con la pregunta en el espacio de *embeddings*, contenía el siguiente fragmento del documento:

«Por eso, involucramos a nuestros trabajadores y colaboradores en el buen desempeño ambiental, y promovemos las buenas prácticas ambientales entre




Figura D.1: Proyección UMAP de los *embeddings* de la pregunta, la respuesta de referencia, el contexto de referencia y los *chunks* recuperados para los dos casos seleccionados como representativos del fenómeno de dilución semántica.

nuestros proveedores.

FICHA INFORMATIVA N.º 29

Última versión 27-06-2022

INTEGRIDAD, SEGREGACIÓN Y SEGURIDAD

EN LA CADENA DE SUMINISTRO

¿QUÉ ES LA INTEGRIDAD EN LA CADENA DE CUSTODIA? La ca-

dena de custodia se define como un sistema de

seguimiento de los productos desde su origen hasta el

consumidor final, a través de los procesos de transporte,

almacenamiento, transformación y comercialización. Teniendo control so-

bre todos estos pasos, podemos asegurar la

integridad de nuestros productos, garantizando la seguridad,

la autenticidad y la calidad de los alimentos a lo largo de toda

la cadena de suministro, evitando así posibles alteraciones,

sustituciones, contaminaciones y adulteraciones. ELEMENTOS BÁSICOS

DE LA CADENA DE CUSTODIA:

- Identificación y etiquetado de los materiales.

- Separación física de materiales según sus especificaciones genéricas.»

La respuesta de referencia del *golden dataset* para esta pregunta era:

«Los elementos básicos de la cadena de custodia son: identificación y etiquetado de los materiales; separación física de materiales según sus especificaciones genéricas; sistema de garantía del origen en cada etapa de producción; documentación y registros de control; sistema de procesado y mantenimiento de la información; identificación del producto final; y formación de los trabajadores.»

Al examinar directamente los *chunks* devueltos por el retriever para P121, se observó que ninguno de los cinco contenía la lista completa de los siete elementos. El *chunk* semánticamente más próximo recogía únicamente los dos primeros, lo que explica que el generador, fiel al contexto recibido, produjese una respuesta parcialmente correcta que no cubría la totalidad de lo que la referencia esperaba.

El análisis de este caso revela que el problema puede originarse más allá de la recuperación. Los cinco elementos restantes no aparecieron entre los demás *chunks* recuperados. Una posible explicación es que el *chunker* semántico empleado durante la indexación fragmentase la lista completa en *chunks* distintos al detectar un cambio semántico entre el texto introductorio y la lista estructurada, de forma que únicamente el *chunk* con los primeros elementos fuese recuperado mientras que el que contenía el resto de la información quedó fuera del ranking. No es posible confirmarlo sin examinar directamente la segmentación del corpus, pero lo que sí queda evidenciado es que el retriever, afectado por la dilución semántica, no fue capaz de traer todos los fragmentos necesarios para construir una respuesta completa, y el generador, fiel al contexto recibido, produjo una respuesta parcial con la información disponible.

La dilución semántica del *embedding* no implica que la recuperación sea sistemáticamente deficiente, sino que introduce principalmente una limitación en la precisión con la que la Precision@K puede medirla. Los resultados obtenidos en FactualCorrectness y ContextRecall demuestran que el retriever funciona razonablemente bien en la mayoría de los casos, y que la dilución semántica representa un margen de mejora identificado más que un fallo generalizado del sistema. Como línea de trabajo futuro, una estrategia de *chunking* más granular que reduzca la extensión de los fragmentos indexados permitiría mitigar este fenómeno tanto en la recuperación como en la evaluación. En esta misma dirección, el uso de modelos de *late interaction* como ColBERT [36], que comparan *embeddings* a nivel de *token* en lugar de representar el documento completo en un único vector, eliminaría estructuralmente el problema de la dilución semántica.

E. Degradación conversacional por patrón en el *baseline*




Figura E.1: Degradación de corrección factual por patrón conversacional respecto al promedio *single-turn* (Δ FC, ST $\rightarrow$ MT-A).

La Figura E.1, que muestra la degradación por patrón conversacional respecto al promedio global *single-turn*, debe interpretarse como una aproximación orientativa. El delta se calcula respecto al promedio global *single-turn* sin distinguir entre categorías de pregunta, asumiendo comparabilidad entre ambos conjuntos de evaluación. Las diferencias de magnitud entre patrones son informativas, pero no deben tomarse como medidas precisas de degradación atribuible exclusivamente a cada estructura conversacional.

Refinement es el patrón más destructivo para ambos modelos, con caídas de -0.132 en Gemini y -0.070 en GPT-4o. Cada turno de refinamiento añade una nueva condición sobre la respuesta previa y, si esa respuesta contenía información incorrecta, el modelo debe construir sobre una base ya sesgada, amplificando el error acumulado. Este resultado es coherente con lo documentado por Kwan et al. [8] en MT-Eval, donde los modelos tienden a ignorar las restricciones acumuladas de turnos anteriores, cumpliendo únicamente la instrucción más reciente y perdiendo las condiciones establecidas previamente.

Follow-up es el único patrón en el que ambos modelos mejoran respecto al *baseline*

single-turn, con incrementos de +0.072 en GPT-4o y +0.009 en Gemini. En *Follow-up* cada pregunta se construye sobre la respuesta inmediatamente anterior del propio modelo, generando un efecto de *in-context learning* en el que el historial reciente actúa como guía para la siguiente respuesta. Kwan et al. [8] documentan explícitamente este fenómeno, observando que todos los modelos evaluados en su estudio obtienen mejor rendimiento en *Follow-up* en entornos *multi-turn* que en *single-turn*.

F. Distribución de métricas RAG *single-turn* sin preguntas *out_of_domain*




Figura F.1: Distribución de métricas del sistema RAG para el subconjunto *single-turn* excluidas las preguntas *out_of_domain*.

La Faithfulness sube de 0.774 a 0.870 en media al excluir las preguntas *out_of_domain*, porque se eliminan los casos en los que el juez penalizaba la respuesta de abstención al no encontrar enunciados que respaldaran dicha abstención en el contexto recuperado, la mediana se mantiene en 1.0, confirmando que una Faithfulness alta es el comporta-

miento predominante real del sistema. La AnswerRelevancy sube de 0.670 a 0.775 en media y de 0.879 a 0.895 en mediana, corroborando exactamente la penalización que esta métrica introduce sobre la categoría *out_of_domain*.

La FactualCorrectness, en cambio, baja de 0.666 a 0.645 en media y de 0.800 a 0.750 en mediana. Esto confirma que las preguntas *out_of_domain* presentan una FactualCorrectness alta cuando el modelo responde correctamente absteniéndose, ya que la respuesta de referencia es precisamente la abstención. Al excluirlas se pierden esos valores altos que incrementaban la media.

La exclusión de las preguntas *out_of_domain* tiene también un efecto directo sobre las métricas del retriever, ContextRecall y ContextPrecision aumentan al retirarlas porque el retriever, por diseño, siempre devuelve fragmentos de contexto con independencia de si la pregunta tiene respuesta posible anclada en el corpus. Ante preguntas fuera del dominio, esos *chunks* recuperados son inevitablemente irrelevantes, y el juez no puede atribuir ningún fragmento del contexto recuperado a la respuesta de referencia, que es precisamente la abstención. Esto penaliza artificialmente ambas métricas, explicando su incremento al excluir ese subconjunto. No obstante, incluso sin las preguntas *out_of_domain* estas métricas no alcanzan valores perfectos, lo que evidencia fallos reales del retriever que, aunque no son la norma, tienen una repercusión directa en la FactualCorrectness cuando ocurren.

La Precision@K, en cambio, no experimenta variación al excluir las preguntas *out_of_domain*, dado que dichas preguntas no disponían de contexto de referencia contra el que evaluar la afinidad de los *chunks* recuperados, por lo que fueron registradas como valores ausentes durante el cálculo y no contribuyen al promedio.
